


Argumentos causales e incertidumbres

Unidad 1.1



Argumentos causales e incertidumbres

Unidad 1.1

Verdad y mentira. Acuerdos intersubjetivos: máxima incertidumbre dada la información disponible. Distribución de creencias honesta entre los universos paralelos de los argumentos causales. Preservación de la creencia previa compatible con el dato y predicción como suma de universos paralelos compatibles con lo que se quiere predecir. Sistema de razonamiento en contextos de incertidumbre: las reglas de la probabilidad. Métodos gráficos de especificación matemática de argumentos causales probabilísticos: redes bayesianas. Las propiedades básicas de los modelos gráficos: estructura, independencia y factorización. Medición de incertidumbre sobre espacio de hipótesis internas a los modelos, $P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$. La evaluación de argumentos causales alternativos en datos observados sin intervenciones, $P(\text{Modelo}|\text{Datos})$. La evidencia, $P(\text{Datos}|\text{Modelo})$, y sus transformaciones (media geométrica y logaritmo).

Verdad

La ciencia tiene pretensión de verdad, de alcanzar
acuerdos intersubjetivos que valgan para todas las personas

Verdad

La ciencia tiene pretensión de verdad, de alcanzar
acuerdos intersubjetivos que valgan para todas las personas

Ciencias formales

Sistemas axiomáticos **cerrados** sin incertidumbre

Verdad

La ciencia tiene pretensión de verdad, de alcanzar
acuerdos intersubjetivos que valgan para todas las personas

Ciencias formales

Sistemas axiomáticos **cerrados** sin incertidumbre

Ciencias con datos

Sistemas naturales **abiertos** con incertidumbre

Verdad

La ciencia tiene pretensión de verdad, de alcanzar **acuerdos intersubjetivos que valgan para todas las personas**

Ciencias formales

Sistemas axiomáticos **cerrados** sin incertidumbre

Ciencias con datos

Sistemas naturales **abiertos** con incertidumbre

¿Qué es una verdad en
contextos de incertidumbre?

¿Todo vale lo mismo?


Ouch!.. Me estás pisando el cuello!



Bueno, es un punto de vista. Se podría decir que me querés hacer tropezar.



En la posmodernidad ya no hay objetividad, toda historia es igualmente válida



Pero me sigues pisando el cuello!

Nunca fuiste a la universidad?



¿Puede haber una verdad si justamente
tenemos incertidumbre sobre su valor real?

Al menos sabemos cómo no mentir

Al menos sabemos cómo no mentir

- No afirmar más de lo que se conoce


Al menos sabemos cómo no mentir

- No afirmar más de lo que se conoce
- Sin ocultar aquello que sí se conoce

Al menos sabemos cómo no mentir

- No afirmar más de lo que se conoce
- Sin ocultar aquello que sí se conoce

¿Cómo exactamente?



Detrás de una de estas caja hay un regalo.
¿Dónde está el regalo?

Certeza absoluta

0




1



0



Distribución de creencias



Distribución de creencias

Honesta

$1/3$



$1/3$




$1/3$



Distribución de creencias


Honesta



Acuerdo intersubjetivo (no mentir)

1. **Maximizar incertidumbre** (dividiendo en partes iguales)
2. **Dada la información disponible** (no asignamos creencia por fuera de las cajas)

¿Cómo preservamos los acuerdos intersubjetivos?




Modelos causales

Modelo gráfico

Regalo: R 

$1/3$



$1/3$




$1/3$



Modelos causales

Modelo gráfico



$1/3$



$1/3$





$1/3$



Modelos causales



Modelo gráfico



Modelos causales

Máxima incertidumbre dado el modelo



Modelo gráfico



Modelos causales

Máxima incertidumbre dado el modelo



Modelo gráfico



Modelos causales

Máxima incertidumbre dado el modelo

Modelo gráfico




Modelos causales

Máxima incertidumbre dado el modelo

Creencia($R, S|\text{Modelo}$)

	r_1	r_2	r_3	
s_1				
s_2				
s_3				




Modelos causales

Máxima incertidumbre dado el modelo

Creencia($R, S|\text{Modelo}$)

	r_1	r_2	r_3	
s_1	0			
s_2				
s_3				




Modelos causales

Máxima incertidumbre dado el modelo

Creencia($R, S|\text{Modelo}$)

	r_1	r_2	r_3	
s_1	0	$1/6$	$1/6$	
s_2				
s_3				




Modelos causales

Máxima incertidumbre dado el modelo

Creencia($R, S|\text{Modelo}$)

	r_1	r_2	r_3	
s_1	0	$1/6$	$1/6$	
s_2	$1/6$	0	$1/6$	
s_3				




Modelos causales

Máxima incertidumbre dado el modelo

Creencia(R, S |Modelo)

	r_1	r_2	r_3	
s_1	0	$1/6$	$1/6$	
s_2	$1/6$	0	$1/6$	
s_3	$1/6$	$1/6$	0	




Modelos causales

Máxima incertidumbre dado el modelo

Creencia($R, S|\text{Modelo}$)

	r_1	r_2	r_3	
s_1	0	$1/6$	$1/6$	
s_2	$1/6$	0	$1/6$	
s_3	$1/6$	$1/6$	0	

Creencia conjunta
intersubjetiva inicial



Máxima incertidumbre dado el modelo

De ambas variables
 $\overbrace{\text{Creencia}(R, S|M)}$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	
s_2	1/6	0	1/6	
s_3	1/6	1/6	0	

Máxima incertidumbre dado el modelo

De ambas variables
 $\overbrace{\text{Creencia}(R, S|M)}$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	
s_2	1/6	0	1/6	
s_3	1/6	1/6	0	

$\text{Creencia}(R|M) =$

Máxima incertidumbre dado el modelo

De ambas variables

$$\overbrace{\text{Creencia}(R, S|M)}$$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	
s_2	1/6	0	1/6	
s_3	1/6	1/6	0	
	1/3	1/3	1/3	

$$\text{Creencia}(R|M) = \sum_s \text{Creencia}(R, s|M)$$

Máxima incertidumbre dado el modelo

De ambas variables
 $\text{Creencia}(R, S|M)$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	1/3
s_2	1/6	0	1/6	1/3
s_3	1/6	1/6	0	1/3
	1/3	1/3	1/3	

$$\text{Creencia}(R|M) = \sum_s \text{Creencia}(R, s|M)$$

$$\text{Creencia}(S|M) = \sum_r \text{Creencia}(r, S|M)$$

Máxima incertidumbre dado el modelo

De ambas variables
 $\overbrace{\text{Creencia}(R, S|M)}$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	1/3
s_2	1/6	0	1/6	1/3
s_3	1/6	1/6	0	1/3
	1/3	1/3	1/3	

$$\text{Creencia}(R|M) = \sum_s \text{Creencia}(R, s|M)$$

$$\text{Creencia}(S|M) = \sum_r \text{Creencia}(r, S|M)$$

Máxima incertidumbre dado el modelo y el dato

De ambas variables
 $\overbrace{\text{Creencia}(R, s_2|M)}$

	r_1	r_2	r_3	
s_2	1/6	0	1/6	1/3

Creencia compatible
 $\overbrace{\text{Creencia}(R, s_2|M)}$

Máxima incertidumbre dado el modelo y el dato

De ambas variables

$$\overbrace{\text{Creencia}(R, s_2|M)}$$

	r_1	r_2	r_3	
s_2	1/6	0	1/6	1/3

Creencia compatible

$$\overbrace{\text{Creencia}(R, s_2|M)}$$
$$\overbrace{\text{Creencia}(s_2|M)}$$

Creencia total que compatible

Máxima incertidumbre dado el modelo y el dato

$$\overbrace{\text{Creencia}(R|s_2, M)}^{\text{Nueva creencia}}$$

	r_1	r_2	r_3	
s_2	$\frac{1}{6}/\frac{1}{3}$	0	$\frac{1}{6}/\frac{1}{3}$	$\frac{1}{3}/\frac{1}{3}$

$$\underbrace{\text{Creencia}(R|s_2, M)}_{\text{Nueva creencia}} = \frac{\overbrace{\text{Creencia}(R, s_2|M)}^{\text{Creencia compatible}}}{\underbrace{\text{Creencia}(s_2|M)}_{\text{Creencia total que compatible}}}$$

Máxima incertidumbre dado el modelo y el dato

$$\overbrace{\text{Creencia}(R|s_2, M)}^{\text{Nueva creencia}}$$

	r_1	r_2	r_3	
s_2	1/2	0	1/2	1

$$\underbrace{\text{Creencia}(R|s_2, M)}_{\text{Nueva creencia}} = \frac{\overbrace{\text{Creencia}(R, s_2|M)}^{\text{Creencia compatible}}}{\underbrace{\text{Creencia}(s_2|M)}_{\text{Creencia total que compatible}}}$$

Máxima incertidumbre dado el modelo y el dato

Nueva creencia

$\overbrace{\text{Creencia}(R|s_2, M)}$

	r_1	r_2	r_3	
s_2	1/2	0	1/2	1

1/2



0



1/2



Las reglas de la probabilidad

Principio de coherencia (regla del producto)

$$P(\text{Hipótesis}|\text{Dato}) = \frac{P(\text{Hipótesis}, \text{Dato})}{P(\text{Dato})}$$

Preservamos la creencia previa que sigue siendo compatible con el dato

Principio de integridad (regla de la suma)

$$P(\text{Dato}) = \sum_{\text{Hipótesis}} P(\text{Hipótesis}, \text{Dato})$$

Predecimos con la contribución de todas las hipótesis. No perdemos ni creamos creencia.

El costo computacional

Problema histórico de la probabilidad

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).
- Siglo 20: Estimadores puntuales (evitan evaluar todo el espacio de hipótesis).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).
- Siglo 20: Estimadores puntuales (evitan evaluar todo el espacio de hipótesis).
- Siglo 21: Comienza a ser posible evaluar todo el espacio de hipótesis mediante la (aproximación a) la aplicación estricta de las reglas de la probabilidad de forma general

Lógica booleana

no era binaria, sino probabilística

PRINCIPLE 1st. If p be the probability of the occurrence of any event, $1 - p$ will be the probability of its non-occurrence.

2nd. The probability of the concurrence of two independent events is the product of the probabilities of those events.

3rd. The probability of the concurrence of two dependent events is equal to the product of the probability of one of them by the probability that if that event occur, the other will happen also.

4th. The probability that if an event, E , take place, an event, F , will also take place, is equal to the probability of the concurrence of the events E and F , divided by the probability of the occurrence of E .

George Boole (1854) *An Investigation of the Laws of Thought*

El problema de la lógica extendida

La complejidad computacional

Tenemos $n = 27$ variables, las letras del alfabeto

El problema de la lógica extendida

La complejidad computacional

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones.

El problema de la lógica extendida

La complejidad computacional

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.

El problema de la lógica extendida

La complejidad computacional

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos los posibles combinaciones de valores de verdad.

El problema de la lógica extendida

La complejidad computacional

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos los posibles combinaciones de valores de verdad.

Necesitamos guardar $2^{27} - 1$ números reales

$$1: P(A, B, \dots, Z) = \dots$$

El problema de la lógica extendida

La complejidad computacional

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos los posibles combinaciones de valores de verdad.

Necesitamos guardar $2^{27} - 1$ números reales

1: $P(A, B, \dots, Z) = \dots$

2: $P(\neg A, B, \dots, Z) = \dots$

El problema de la lógica extendida

La complejidad computacional

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos los posibles combinaciones de valores de verdad.

Necesitamos guardar $2^{27} - 1$ números reales

$$1: P(A, B, \dots, Z) = \dots$$

$$2: P(\neg A, B, \dots, Z) = \dots$$

$$\vdots \dots$$

$$2^{27}: (\neg A, \neg B, \dots, \neg Z) = 1 - \sum_i^{2^{27}-1} P(\dots)$$

Redes bayesianas

Descomposiciones condicionales

$$P(L, E, T, R, A)$$

Redes bayesianas

Descomposiciones condicionales

$$P(L, E, T, R, A) = P(L)P(E, T, R, A|L)$$

Redes bayesianas


Descomposiciones condicionales

$$P(L, E, T, R, A) = P(L)P(E, T, R, A|L) = \cancel{P(L)} \frac{P(L, E, T, R, A)}{\cancel{P(L)}}$$

Redes bayesianas

Descomposiciones condicionales


$$P(L, E, T, R, A) = P(L)P(E, T, R, A|L)$$



Redes bayesianas

Descomposiciones condicionales


$$P(L, E, T, R, A) = P(L)P(E|L)P(T, R, A|L, E)$$



Redes bayesianas

Descomposiciones condicionales


$$P(L, E, T, R, A) = P(L)P(E|L)P(T, R, A|L, E) = \cancel{P(L)} \frac{\cancel{P(L, E)}}{\cancel{P(L)}} \frac{P(L, E, T, R, A)}{\cancel{P(L, E)}}$$



Redes bayesianas

Descomposiciones condicionales


$$P(L, E, T, R, A) = P(L)P(E|L)P(T, R, A|L, E)$$



Redes bayesianas

Descomposiciones condicionales


$$P(L, E, T, R, A) = P(L)P(E|L)P(T|L, E)P(R, A|L, E, T)$$



Redes bayesianas

Descomposiciones condicionales


$$P(L, E, T, R, A) = P(L)P(E|L)P(T|L, E)P(R, A|L, E, T) = \cancel{P(L)} \frac{\cancel{P(L, E)}}{\cancel{P(L)}} \frac{\cancel{P(L, E, T)}}{\cancel{P(L, E)}} \frac{P(L, E, T, R, A)}{\cancel{P(L, E, T)}}$$



Redes bayesianas

Descomposiciones condicionales


$$P(L, E, T, R, A) = P(L)P(E|L)P(T|L, E)P(R, A|L, E, T)$$



Redes bayesianas

Descomposiciones condicionales

$$P(L, E, T, R, A) = P(L)P(E|L)P(T|L, E)P(R|L, E, T)P(A|L, E, T, R)$$




Redes bayesianas

Descomposiciones condicionales

$$P(L, E, T, R, A) = P(L)P(E|L)P(T|L, E)P(R|L, E, T)P(A|L, E, T, R)$$

Hay $5! = 120$ posibles descomposiciones




Redes bayesianas

Descomposiciones condicionales

$$P(L, E, T, R, A) = P(L)P(E)P(T)P(R)P(A)$$

Hay $5! = 120$ posibles descomposiciones

Si tenemos en cuenta las independencias hay aún muchas más!



Redes bayesianas

Descomposiciones condicionales

$$P(L, E, T, R, A)$$

¿Cuál de todas usar para definir la conjunta?

Argumentos causales

La **alarma** (A) de una casa se activa cuando alguien **entra** (E) sin apagarla. Si la alarma se activa, la dueña recibe una **llamada** (L) de la central de seguridad. La alarma se puede activar por otros motivos, como los **terremotos** (T) que no son infrecuentes en la ciudad. Siempre que se produce un terremoto, en las **redes** (R) se habla casi exclusivamente de eso.

Argumentos causales

La **alarma** (A) de una casa se activa cuando alguien **entra** (E) sin apagarla. Si la alarma se activa, la dueña recibe una **llamada** (L) de la central de seguridad. La alarma se puede activar por otros motivos, como los **terremotos** (T) que no son infrecuentes en la ciudad. Siempre que se produce un terremoto, en las **redes** (R) se habla casi exclusivamente de eso.

Mecanismos causales probabilísticos

$$P(A|E, T)$$

Argumentos causales

La **alarma** (A) de una casa se activa cuando alguien **entra** (E) sin apagarla. Si la alarma se activa, la dueña recibe una **llamada** (L) de la central de seguridad. La alarma se puede activar por otros motivos, como los **terremotos** (T) que no son infrecuentes en la ciudad. Siempre que se produce un terremoto, en las **redes** (R) se habla casi exclusivamente de eso.

Mecanismos causales probabilísticos

$$P(A|E, T) P(E)$$

Argumentos causales

La **alarma** (A) de una casa se activa cuando alguien **entra** (E) sin apagarla. Si la alarma se activa, la dueña recibe una **llamada** (L) de la central de seguridad. La alarma se puede activar por otros motivos, como los **terremotos** (T) que no son infrecuentes en la ciudad. Siempre que se produce un terremoto, en las **redes** (R) se habla casi exclusivamente de eso.

Mecanismos causales probabilísticos

$$P(A|E, T) P(E) P(L|A)$$

Argumentos causales

La **alarma** (A) de una casa se activa cuando alguien **entra** (E) sin apagarla. Si la alarma se activa, la dueña recibe una **llamada** (L) de la central de seguridad. La alarma se puede activar por otros motivos, como los **terremotos** (T) que no son infrecuentes en la ciudad. Siempre que se produce un terremoto, en las **redes** (R) se habla casi exclusivamente de eso.

Mecanismos causales probabilísticos

$$P(A|E, T) P(E) P(L|A) P(T)$$


Argumentos causales

La **alarma** (A) de una casa se activa cuando alguien **entra** (E) sin apagarla. Si la alarma se activa, la dueña recibe una **llamada** (L) de la central de seguridad. La alarma se puede activar por otros motivos, como los **terremotos** (T) que no son infrecuentes en la ciudad. Siempre que se produce un terremoto, en las **redes** (R) se habla casi exclusivamente de eso.


Mecanismos causales probabilísticos

$$P(A|E, T) P(E) P(L|A) P(T) P(R|T)$$

Argumentos causales




Argumentos causales




Cada variable resumen el comportamiento de un sistema complejo

Argumentos causales



Cada variable resumen el comportamiento de un sistema complejo

Argumentos causales



Cada variable resumen el comportamiento de un sistema complejo

Redes Bayesianas Causales

Menor complejidad computacional

Los mecanismos causales son útiles para definir distribuciones conjuntas en espacios de alta dimensión.

Redes Bayesianas Causales

Menor complejidad computacional

$$P(L, E, T, R, A) =$$

Redes Bayesianas Causales

Menor complejidad computacional

$$P(L, E, T, R, A) = P(E) P(T|E) P(A|E, T) P(R|E, T, A) P(L|E, T, R, A)$$

Redes Bayesianas Causales

Menor complejidad computacional

$$P(L, E, T, R, A) = P(E) P(T|\neg E) P(A|E, T) P(R|\neg E, T, \neg A) P(L|\neg E, \neg T, \neg R, A)$$

Redes Bayesianas Causales

Menor complejidad computacional

$$P(L, E, T, R, A) = P(E) P(T) P(A|E, T) P(R|T) P(L|A)$$

Redes Bayesianas Causales

Menor complejidad computacional

$$\underbrace{P(L, E, T, R, A)}_{\text{Complejidad } 2^n} = P(E) P(T) P(A|E, T) P(R|T) P(L|A)$$

Redes Bayesianas Causales

Menor complejidad computacional

$$\underbrace{P(L, E, T, R, A)}_{\text{Complejidad } 2^n} = \underbrace{P(E)}_2 \underbrace{P(T)}_2 \underbrace{P(A|E, T)}_{2^3} \underbrace{P(R|T)}_{2^2} \underbrace{P(L|A)}_{2^2}$$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

Los mecanismos causales probabilísticos se pueden definir intuitivamente.
Las distribuciones condicionales generales son más difíciles de definir.

$$P(L|A) \text{ vs } P(T|L).$$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

Los mecanismos causales probabilísticos se pueden definir intuitivamente.
Las distribuciones condicionales generales son más difíciles de definir.

$$P(L|A) \text{ vs } P(T|L).$$

Con la definición de los mecanismos causales probabilísticos

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

Los mecanismos causales probabilísticos se pueden definir intuitivamente.
Las distribuciones condicionales generales son más difíciles de definir.

$$P(L|A) \text{ vs } P(T|L).$$

Con la definición de los mecanismos causales probabilísticos
y
las reglas de la probabilidad

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

Los mecanismos causales probabilísticos se pueden definir intuitivamente.
Las distribuciones condicionales generales son más difíciles de definir.

$$P(L|A) \text{ vs } P(T|L).$$

Con la definición de los mecanismos causales probabilísticos
y
las reglas de la probabilidad
podemos
derivar todas las distribuciones marginales y condicionales
(todas las conclusiones)

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(E)$$

e^0	e^1

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$P(E)$	
e^0	e^1

- Una vez cada 3 años
- Una casa cada 1000 por día

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(E)$$

e^0	e^1
999/1000	1/1000

- Una vez cada 3 años
- Una casa cada 1000 por día

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(T)$$

t^0	t^1

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(T)$$

t^0	t^1

- Hay 3 terremotos (leves) por años

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(T)$$

t^0	t^1
362/365	3/365

- Hay 3 terremotos (leves) por años

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(R|T)$$

	r^0	r^1
(t^0)		
(t^1)		

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(R|T)$$

	r^0	r^1
(t^0)		
(t^1)		

- Siempre que hay un terremoto, en alguna de mis redes sociales (whatsapp, facebook, twitter, instagram), se habla del tema.

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(R|T)$$

	r^0	r^1
(t^0)	1	0
(t^1)	0	1

- Siempre que hay un terremoto, en alguna de mis redes sociales (whatsapp, facebook, twitter, instagram), se habla del tema.

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(R|T)$$

	r^0	r^1
(t^0)	1	0
(t^1)	0	1

- Siempre que hay un terremoto, en alguna de mis redes sociales (whatsapp, facebook, twitter, instagram), se habla del tema.
- También puedo mirar mal, o por algún momento no haya nada, o que por algún otro motivo nadie pueda comunicarse

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(R|T)$$

	r^0	r^1
(t^0)	0.99	0.01
(t^1)	0.01	0.99

- Siempre que hay un terremoto, en alguna de mis redes sociales (whatsapp, facebook, twitter, instagram), se habla del tema.
- También puedo mirar mal, o por algún momento no haya nada, o que por algún otro motivo nadie pueda comunicarse

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(L|A)$$

	l^0	l^1
(a^0)		
(a^1)		

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(L|A)$$

	l^0	l^1
(a^0)		
(a^1)		

- Siempre que se activa la alarma, me llaman desde el call center de la empresa (si no pasa nada raro)

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(L|A)$$

	l^0	l^1
(a^0)	0.99	0.01
(a^1)	0.01	0.99

- Siempre que se activa la alarma, me llaman desde el call center de la empresa (si no pasa nada raro)

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)		
(e^1, t^0)		
(e^0, t^1)		
(e^1, t^1)		

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)		
(e^1, t^0)		
(e^0, t^1)		
(e^1, t^1)		

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)		
(e^1, t^0)		
(e^0, t^1)		
(e^1, t^1)		

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	$P(\bar{\alpha})$	$P(\alpha)$
(e^1, t^0)		
(e^0, t^1)		
(e^1, t^1)		

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	$P(\bar{\alpha})$	$P(\alpha)$
(e^1, t^0)		$P(\alpha \cup \varepsilon)$
(e^0, t^1)		
(e^1, t^1)		

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	$P(\bar{\alpha})$	$P(\alpha)$
(e^1, t^0)	$P(\bar{\alpha} \cup \bar{\varepsilon})$	$P(\alpha \cup \varepsilon)$
(e^0, t^1)		
(e^1, t^1)		

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	$P(\bar{\alpha})$	$P(\alpha)$
(e^1, t^0)	$P(\bar{\alpha} \cap \bar{\varepsilon})$	$P(\alpha \cup \varepsilon)$
(e^0, t^1)		
(e^1, t^1)		

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	$P(\bar{\alpha})$	$P(\alpha)$
(e^1, t^0)	$P(\bar{\alpha} \cap \bar{\varepsilon})$	$P(\alpha \cup \varepsilon)$
(e^0, t^1)	$P(\bar{\alpha} \cap \bar{\tau})$	$P(\alpha \cup \tau)$
(e^1, t^1)		

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	$P(\bar{\alpha})$	$P(\alpha)$
(e^1, t^0)	$P(\bar{\alpha} \cap \bar{\varepsilon})$	$P(\alpha \cup \varepsilon)$
(e^0, t^1)	$P(\bar{\alpha} \cap \bar{\tau})$	$P(\alpha \cup \tau)$
(e^1, t^1)	$P(\bar{\alpha} \cap \bar{\varepsilon} \cap \bar{\tau})$	$P(\alpha \cup \varepsilon \cup \tau)$

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	0.99	$P(\alpha)$
(e^1, t^0)	$P(\bar{\alpha} \cap \bar{\varepsilon})$	$P(\alpha \cup \varepsilon)$
(e^0, t^1)	$P(\bar{\alpha} \cap \bar{\tau})$	$P(\alpha \cup \tau)$
(e^1, t^1)	$P(\bar{\alpha} \cap \bar{\varepsilon} \cap \bar{\tau})$	$P(\alpha \cup \varepsilon \cup \tau)$

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	0.99	0.01
(e^1, t^0)	$P(\bar{\alpha} \cap \bar{\varepsilon})$	$P(\alpha \cup \varepsilon)$
(e^0, t^1)	$P(\bar{\alpha} \cap \bar{\tau})$	$P(\alpha \cup \tau)$
(e^1, t^1)	$P(\bar{\alpha} \cap \bar{\varepsilon} \cap \bar{\tau})$	$P(\alpha \cup \varepsilon \cup \tau)$

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	0.99	0.01
(e^1, t^0)	$0.99 \cdot 0.01$	$P(\alpha \cup \varepsilon)$
(e^0, t^1)	$P(\bar{\alpha} \cap \bar{\tau})$	$P(\alpha \cup \tau)$
(e^1, t^1)	$P(\bar{\alpha} \cap \bar{\varepsilon} \cap \bar{\tau})$	$P(\alpha \cup \varepsilon \cup \tau)$

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	0.99	0.01
(e^1, t^0)	≈ 0.01	$P(\alpha \cup \varepsilon)$
(e^0, t^1)	$P(\bar{\alpha} \cap \bar{\tau})$	$P(\alpha \cup \tau)$
(e^1, t^1)	$P(\bar{\alpha} \cap \bar{\varepsilon} \cap \bar{\tau})$	$P(\alpha \cup \varepsilon \cup \tau)$

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	0.99	0.01
(e^1, t^0)	≈ 0.01	≈ 0.99
(e^0, t^1)	$P(\bar{\alpha} \cap \bar{\tau})$	$P(\alpha \cup \tau)$
(e^1, t^1)	$P(\bar{\alpha} \cap \bar{\varepsilon} \cap \bar{\tau})$	$P(\alpha \cup \varepsilon \cup \tau)$

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	0.99	0.01
(e^1, t^0)	≈ 0.01	≈ 0.99
(e^0, t^1)	≈ 0.01	≈ 0.99
(e^1, t^1)	$P(\bar{\alpha} \cap \bar{\varepsilon} \cap \bar{\tau})$	$P(\alpha \cup \varepsilon \cup \tau)$

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):

α Se activa sola: $P(\alpha) = 0.01$

$\bar{\varepsilon}$ No se activa a pesar de entrada: $P(\bar{\varepsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Intuición sobre los mecanismos causales probabilísticos

$$P(A|E, T)$$

	a^0	a^1
(e^0, t^0)	0.99	0.01
(e^1, t^0)	≈ 0.01	≈ 0.99
(e^0, t^1)	≈ 0.01	≈ 0.99
(e^1, t^1)	≈ 0.0001	≈ 0.9999

- Siempre que entra alguien a la casa o que hay un terremoto se activa la alarma (si no pasa nada raro):


α Se activa sola: $P(\alpha) = 0.01$

$\bar{\epsilon}$ No se activa a pesar de entrada: $P(\bar{\epsilon}) = 0.01$

$\bar{\tau}$ No se activa a pesar de terremoto: $P(\bar{\tau}) = 0.01$

Redes Bayesianas Causales

Inferencia sobre sus hipótesis internas




Redes Bayesianas Causales

Inferencia sobre sus hipótesis internas


Entradera:

e^0	e^1
0.999	0.001




Redes Bayesianas Causales

Inferencia sobre sus hipótesis internas




Redes Bayesianas Causales

Inferencia sobre sus hipótesis internas




Redes Bayesianas Causales

Inferencia sobre sus hipótesis internas




Redes Bayesianas Causales

Inferencia sobre sus hipótesis internas



Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(e^0, t^0, a^0, r^0, l^0) = P(e^0)P(t^0)P(a^0|t^0, e^0)P(r^0|t^0)P(l^0|a^0)$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(e^0, t^0, a^0, r^0, l^0) = 0.999 \cdot P(t^0)P(a^0|t^0, e^0)P(r^0|t^0)P(l^0|a^0)$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(e^0, t^0, a^0, r^0, l^0) = 0.999 \cdot 0.992 \cdot 0.99 \cdot 0.99 \cdot 0.99$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(e^0, t^0, a^0, r^0, l^0) = 0.999 \cdot 0.992 \cdot 0.99 \cdot 0.99 \cdot 0.99 \approx 0.96$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(a^1) =$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(a^1) = \sum_e \sum_t \sum_r \sum_l P(e, t, a^1, r, l)$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(a^1) = \sum_e \sum_t \sum_r \sum_l P(e)P(t)P(a^1|t, e)P(r|t)P(l|a^1)$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(a^1) = \sum_e \sum_t \sum_r \sum_l P(e)P(t)P(a^1|t, e)P(r|t)P(l|a^1) \approx 0.019$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(A|r^1)$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(A|r^1) = \frac{P(A, r^1)}{P(r^1)}$$

Redes Bayesianas Causales


Inferencia sobre sus hipótesis internas



$$P(A|r^1) = \frac{P(A, r^1)}{P(r^1)} = \frac{\sum_e \sum_t \sum_l P(e)P(t)P(A|t, e)P(r^1|t)P(l|A)}{\sum_e \sum_t \sum_a \sum_l P(e)P(t)P(a|t, e)P(r^1|t)P(l|a)}$$

Argumentos causales


Proceso generativo



Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.

Argumentos causales

Independencias




Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.

$$L \perp\!\!\!\perp E, T, R \mid A$$

$$P(L|A, \cancel{E}, \cancel{T}, \cancel{R}) = P(L|A)$$

Argumentos causales

Independencias



Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.


$$L \perp\!\!\!\perp E, T, R \mid A$$

$$P(L|A, \cancel{E}, \cancel{T}, \cancel{R}) = P(L|A)$$

Cuando conocemos el valor de su causa directa A , el resto de variables no agregan más información para predecir L

Argumentos causales

Independencias




Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.

$$R \perp\!\!\!\perp E, A, L \mid T$$

$$P(R|T, \cancel{E}, \cancel{A}, \cancel{L}) = P(R|T)$$

Argumentos causales

Independencias



Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.


$$R \perp\!\!\!\perp E, A, L \mid T$$

$$P(R|T, \cancel{E}, \cancel{A}, \cancel{L}) = P(R|T)$$

R es independiente del resto del grafo dado T

Argumentos causales

Independencias




Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.

No todas las las variables son independiente del resto dado sus causas!

Argumentos causales

Independencias




Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.

No todas las las variables son independiente del resto dado sus causas!

$$P(a^1|E, T)$$

Argumentos causales

Independencias




Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.

No todas las las variables son independiente del resto dado sus causas!

$$P(a^1|E, T) < P(a^1|E, T, l^1)$$

Argumentos causales

Independencias



Las variables se generan a través de mecanismos que se rigen únicamente por sus causas directas.


No todas las variables son independientes del resto dado sus causas!

$$P(a^1|E, T) < P(a^1|E, T, l^1)$$

$$A \perp\!\!\!\perp R \mid E, T$$

Argumentos causales

Independencias



Las variables es generan a través de mecanismos que se rigen únicamente por sus causas directas.

En una Red Bayesiana Causal

$$X \perp\!\!\!\perp \text{NoDecendientes}(X) \mid \text{Causas}(X)$$

Redes Bayesianas

$$P(L, E, T, R, A) = P(E)P(T|E)P(A|E, T)P(L|T, E, A)P(R|T, E, A, L)$$

Redes Bayesianas

$$P(L, E, T, R, A) = P(E)P(T|E)P(A|E, T)P(L|T, E, A)P(R|T, E, A, L)$$

- $E \perp\!\!\!\perp T \implies P(T|E) = P(T)$

Redes Bayesianas

$$P(L, E, T, R, A) = P(E)P(T|E)P(A|E, T)P(L|T, E, A)P(R|T, E, A, L)$$

- $E \perp\!\!\!\perp T \implies P(T|E) = P(T)$
- $A \perp\!\!\!\perp R|E, T \implies P(A|E, T, R) = P(A|E, T)$

Redes Bayesianas

$$P(L, E, T, R, A) = P(E)P(T|E)P(A|E, T)P(L|T, E, A)P(R|T, E, A, L)$$

- $E \perp\!\!\!\perp T \implies P(T|E) = P(T)$
- $A \perp\!\!\!\perp R|E, T \implies P(A|E, T, R) = P(A|E, T)$
- $L \perp\!\!\!\perp E, T|A \implies P(L|A, T, E) = P(L|A)$

Redes Bayesianas

$$P(L, E, T, R, A) = P(E)P(T|E)P(A|E, T)P(L|T, E, A)P(R|T, E, A, L)$$

- $E \perp\!\!\!\perp T \implies P(T|E) = P(T)$
- $A \perp\!\!\!\perp R|E, T \implies P(A|E, T, R) = P(A|E, T)$
- $L \perp\!\!\!\perp E, T|A \implies P(L|A, T, E) = P(L|A)$
- $R \perp\!\!\!\perp E, A, L|T \implies P(R|A, T, E, L) = P(R|T)$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T|E)P(A|E, T)P(L|T, E, A)P(R|T, E, A, L)$$

- $E \perp\!\!\!\perp T \implies P(T|E) = P(T)$
- $A \perp\!\!\!\perp R|E, T \implies P(A|E, T, R) = P(A|E, T)$
- $L \perp\!\!\!\perp E, T|A \implies P(L|A, T, E) = P(L|A)$
- $R \perp\!\!\!\perp E, A, L|T \implies P(R|A, T, E, L) = P(R|T)$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T|\cancel{E})P(A|E, T)P(L|T, \cancel{E}, A)P(R|T, \cancel{E}, \cancel{A}, \cancel{L})$$

- $E \perp\!\!\!\perp T \implies P(T|E) = P(T)$
- $A \perp\!\!\!\perp R|E, T \implies P(A|E, T, R) = P(A|E, T)$
- $L \perp\!\!\!\perp E, T|A \implies P(L|A, T, E) = P(L|A)$
- $R \perp\!\!\!\perp E, A, L|T \implies P(R|A, T, E, L) = P(R|T)$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

- $E \perp\!\!\!\perp T \implies P(T|E) = P(T)$
- $A \perp\!\!\!\perp R|E, T \implies P(A|E, T, R) = P(A|E, T)$
- $L \perp\!\!\!\perp E, T|A \implies P(L|A, T, E) = P(L|A)$
- $R \perp\!\!\!\perp E, A, L|T \implies P(R|A, T, E, L) = P(R|T)$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

$$P(R|T, E, A, L) = \frac{P(L, E, T, R, A)}{P(L, E, T, A)}$$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

$$P(R|T, E, A, L) = \frac{P(L, E, T, R, A)}{P(L, E, T, A)} = \frac{P(T)P(E)P(A|E, T)P(L|A)P(R|T)}{\sum_r P(T)P(E)P(A|E, T)P(L|A)P(r|T)}$$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

$$P(R|T, E, A, L) = \frac{P(L, E, T, R, A)}{P(L, E, T, A)} = \frac{P(T)P(E)P(A|E, T)P(L|A)P(R|T)}{P(T)P(E)P(A|E, T)P(L|A) \sum_r P(r|T)}$$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

$$P(R|T, E, A, L) = \frac{P(L, E, T, R, A)}{P(L, E, T, A)} = \frac{P(T)P(E)P(A|E, T)P(L|A)P(R|T)}{P(T)P(E)P(A|E, T)P(L|A)}$$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

$$P(R|T, E, A, L) = \frac{P(L, E, T, R, A)}{P(L, E, T, A)} = \frac{\cancel{P(T)} \cancel{P(E)} \cancel{P(A|E, T)} \cancel{P(L|A)} P(R|T)}{\cancel{P(T)} \cancel{P(E)} \cancel{P(A|E, T)} \cancel{P(L|A)}}$$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

$$P(R|T, E, A, L) = \frac{P(L, E, T, R, A)}{P(L, E, T, A)} = P(R|T)$$

Redes Bayesianas

Independencias $\Rightarrow$ Factorización

$$P(L, E, T, R, A) = P(E)P(T)P(A|E, T)P(L|A)P(R|T)$$

Independencias $\Leftarrow$ Factorización

$$P(R|T, E, A, L) = \frac{P(L, E, T, R, A)}{P(L, E, T, A)} = P(R|T)$$

Independencias $\Longleftrightarrow$ Factorización

Práctica 1: $P(\text{Hipótesis}|\text{Dato})$

Estimar hipótesis internas a los modelos (optativa)

Estimar y comparar los siguientes casos.

1. Consecuencia común observada y no observada.

a. $P(T|E = 1, A = 1)$

b. $P(T|E = 1)$

2. Causa común observada y no observada.

a. $P(A|T = 1, R = 1)$

b. $P(A|R = 1)$

3. Variable intermedia observada y no observada.

a. $P(T|A = 1, L = 1)$

b. $P(T|L = 1)$

Regla del producto

$$P(H_1 \mid H_2) = \frac{P(H_1, H_2)}{P(H_2)}$$

Regla del producto

$$P(H_1 \mid H_2) = \frac{P(H_1, H_2)}{P(H_2)}$$

Regla del producto

$$P(H_1 | H_2) = \frac{P(H_1, H_2)}{P(H_2)}$$

$$P(H_2 | H_1) = \frac{P(H_1, H_2)}{P(H_1)}$$

Regla del producto

$$P(H_1 | H_2) = \frac{P(H_1, H_2)}{P(H_2)}$$

$$P(H_1)P(H_2 | H_1) = P(H_1, H_2)$$

Regla del producto

$$P(H_1 | H_2) = \frac{P(H_1, H_2)}{P(H_2)}$$

$$P(H_1)P(H_2 | H_1) = \mathbf{P(H_1, H_2)}$$

Regla del producto

Teorema de Bayes

$$P(H_1 | H_2) = \frac{P(H_1)P(H_2 | H_1)}{P(H_2)}$$

$$P(H_1)P(H_2 | H_1) = \mathbf{P(H_1, H_2)}$$

Regla del producto

Teorema de Bayes

$$P(H_1 | D) = \frac{P(H_1)P(D | H_1)}{P(D)}$$

Regla del producto

Teorema de Bayes

$$P(H_1 | D) = \frac{P(H_1)P(D | H_1)}{P(D)}$$

$$\overbrace{P(\text{Hipótesis}_i, \text{Datos})}^{\text{Creencia que sobrevive}} = \overbrace{P(\text{Datos} | \text{Hipótesis}_i)}^{\text{Predicción (verosimilitud)}} \overbrace{P(\text{Hipótesis}_i)}^{\text{Creencia previa}}$$

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Hipótesis}_i, \text{Datos})}^{\text{Creencia que sobrevive}}}{\underbrace{P(\text{Datos})}_{\text{Evidencia}}}$$

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Dato} | \text{Hipótesis}_i)}^{\text{Verosimilitud}} \overbrace{P(\text{Hipótesis}_i)}^{\text{Prior}}}{\underbrace{P(\text{Dato})}_{\text{Evidencia}}}$$

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos}, \text{Modelo})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Hipótesis}_i | \text{Modelo})}^{\text{Prior}}}{\underbrace{P(\text{Datos} | \text{Modelo})}_{\text{Evidencia}}}$$

Y el **modelo**!
que relaciona el **dato** con la **hipótesis**!

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos}, \text{Modelo})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Hipótesis}_i | \text{Modelo})}^{\text{Prior}}}{\underbrace{P(\text{Datos} | \text{Modelo})}_{\text{Evidencia}}}$$

$$\overbrace{P(\text{Datos} | \text{Modelo})}^{\text{Evidencia}} = ?$$

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos}, \text{Modelo})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Hipótesis}_i | \text{Modelo})}^{\text{Prior}}}{\underbrace{P(\text{Datos} | \text{Modelo})}_{\text{Evidencia}}}$$

$$\overbrace{P(\text{Datos} | \text{Modelo})}^{\text{Evidencia}} = \text{Regla de la suma}$$

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos}, \text{Modelo})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Hipótesis}_i | \text{Modelo})}^{\text{Prior}}}{\underbrace{P(\text{Datos} | \text{Modelo})}_{\text{Evidencia}}}$$

$$\overbrace{P(\text{Datos} | \text{Modelo})}^{\text{Evidencia}} = \sum_{\text{Hipótesis}_i} \underbrace{P(\text{Hipótesis}_i, \text{Dato} | \text{Modelo})}_{\text{Creencia conjunta}}$$

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos}, \text{Modelo})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Hipótesis}_i | \text{Modelo})}^{\text{Prior}}}{\underbrace{P(\text{Datos} | \text{Modelo})}_{\text{Evidencia}}}$$

$$P(\text{Modelo}_j | \text{Datos}) =$$

Regla del producto

Teorema de Bayes

$$\underbrace{P(\text{Hipótesis}_i | \text{Datos}, \text{Modelo})}_{\text{Posterior}} = \frac{\overbrace{P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})}^{\text{Verosimilitud}} \overbrace{P(\text{Hipótesis}_i | \text{Modelo})}^{\text{Prior}}}{\underbrace{P(\text{Datos} | \text{Modelo})}_{\text{Evidencia}}}$$

$$P(\text{Modelo}_j | \text{Datos}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo}_j)}^{\text{Evidencia}} P(\text{Modelo}_j)}{P(\text{Datos})}$$

Modelo causal alternativo

Modelo gráfico:



$1/3$



$1/3$



$1/3$



Modelo causal alternativo

Modelo gráfico:



$1/3$



$1/3$

$1/3$



Modelo causal alternativo


Modelo gráfico:



Modelo causal alternativo

Monty Hall



Modelo gráfico:



Modelo causal alternativo

Monty Hall



Modelo gráfico:



Modelo causal alternativo

Monty Hall

Modelo gráfico:




Modelo causal alternativo

Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3	
s_2				
s_3				




Modelo causal alternativo

Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3	
s_2	$1/6$			
s_3				




Modelo causal alternativo

Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3		
s_2	$1/6$				
s_3	$1/6$				




Modelo causal alternativo

Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3		
s_2	$1/6$	0			
s_3	$1/6$				




Modelo causal alternativo

Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3		
s_2	$1/6$	0			
s_3	$1/6$	$1/3$			




Modelo causal alternativo

Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3		
s_2	$1/6$	0	$1/3$		
s_3	$1/6$	$1/3$			




Modelo causal alternativo

Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3	
s_2	$1/6$	0	$1/3$	
s_3	$1/6$	$1/3$	0	



Modelo causal alternativo


Monty Hall

$P(R, S | \text{Modelo}_{\text{Monty Hall}})$

	r_1	r_2	r_3	
s_2	$1/6$	0	$1/3$	
s_3	$1/6$	$1/3$	0	

Regla de la suma

$$P(S) = \sum_j P(r_j, S)$$



Modelo causal alternativo


Monty Hall

$$P(R, S | \text{Modelo}_{\text{Monty Hall}})$$

	r_1	r_2	r_3	
s_2	$1/6$	0	$1/3$	$1/2$
s_3	$1/6$	$1/3$	0	$1/2$
	$1/3$	$1/3$	$1/3$	1

Regla de la suma

$$P(S) = \sum_j P(r_j, S)$$



Modelo causal alternativo


Monty Hall

$$P(R, s_2)$$

	r_1	r_2	r_3	
s_2	$1/6$	0	$1/3$	$1/2$

Regla del producto

$$P(R|s_2) = \frac{P(R, s_2)}{P(s_2)}$$



Modelo causal alternativo


Monty Hall

$$P(R|s_2)$$

	r_1	r_2	r_3	
s_2	$1/3$	0	$2/3$	1

Regla del producto

$$P(R|s_2) = \frac{P(R, s_2)}{P(s_2)}$$





Modelo causal alternativo





Monty Hall

$$P(R|s_2)$$



	r_1	r_2	r_3	
s_2	$1/3$	0	$2/3$	1



Modelos causales alternativos





Modelos causales alternativos



¿Y el acuerdo intersubjetivo respecto de los modelos?

$$P(\text{Modelo}_i | \text{Datos} = \underbrace{\{(c_0, s_0, r_0)\}}_{\text{Episodio 0}}, \underbrace{\{(c_1, s_1, r_1), \dots\}}_{\text{Episodio 1}})$$

Modelos causales alternativos



¿Y el acuerdo intersubjetivo respecto de los modelos?

$$P(\text{Modelo}_i | \text{Datos} = \underbrace{\{(c_0, s_0, r_0)\}}_{\text{Episodio 0}}, \underbrace{\{(c_1, s_1, r_1), \dots\}}_{\text{Episodio 1}})$$

Evaluación de modelos causales

$$P(\text{Modelo}_i|\text{Datos}) = \frac{\overbrace{P(\text{Datos}|\text{Modelo}_i)}^{\text{Evidencia}} P(\text{Modelo}_i)}{P(\text{Datos})}$$

Evaluación de modelos causales

$$P(\text{Modelo}_i | \text{Datos}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo}_i)}^{\text{Evidencia}} P(\text{Modelo}_i)}{P(\text{Datos})}$$

$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) =$$

Evaluación de modelos causales

$$P(\text{Modelo}_i | \text{Datos}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo}_i)}^{\text{Evidencia}} P(\text{Modelo}_i)}{P(\text{Datos})}$$

$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = \text{Regla de la suma}$

Evaluación de modelos causales

$$P(\text{Modelo}_i | \text{Datos}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo}_i)}^{\text{Evidencia}} P(\text{Modelo}_i)}{P(\text{Datos})}$$

$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = \text{Regla del producto}$$

Evaluación de modelos causales

$$P(\text{Modelo}_i | \text{Datos}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo}_i)}^{\text{Evidencia}} P(\text{Modelo}_i)}{P(\text{Datos})}$$

$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	1/3
s_2	1/6	0	1/6	1/3
s_3	1/6	1/6	0	1/3

$$P(D|M)$$

	r_1	r_2	r_3	
s_1	0	0	0	0
s_2	1/6	0	1/3	1/2
s_3	1/6	1/3	0	1/2

$$P(D|M)$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	1/3
s_2	1/6	0	1/6	1/3
s_3	1/6	1/6	0	1/3

$$P(D|M) = \frac{1}{3}$$

	r_1	r_2	r_3	
s_1	0	0	0	0
s_2	1/6	0	1/3	1/2
s_3	1/6	1/3	0	1/2

$$P(D|M) = \frac{1}{2}$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

	r_1	r_2	r_3	
s_2	$1/2$	0	$1/2$	1

$$P(D|M) = \frac{1}{3}$$

	r_1	r_2	r_3	
s_2	$1/3$	0	$2/3$	1

$$P(D|M) = \frac{1}{2}$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

	r_1	r_2	r_3	
s_2	1/2	0	1/2	1

$$P(D|M) = \frac{1}{3} \frac{1}{2}$$

	r_1	r_2	r_3	
s_2	1/3	0	2/3	1

$$P(D|M) = \frac{1}{2} \frac{1}{3}$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

	r_1	r_2	r_3	
s_1	0	1/6	1/6	1/3
s_2	1/6	0	1/6	1/3
s_3	1/6	1/6	0	1/3

$$P(D|M) = \frac{1}{3} \frac{1}{2}$$

	r_1	r_2	r_3	
s_1	0	0	0	0
s_2	1/6	0	1/3	1/2
s_3	1/6	1/3	0	1/2

$$P(D|M) = \frac{1}{2} \frac{1}{3}$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

	r_1	r_2	r_3	
s_1	0	$1/6$	$1/6$	$1/3$
s_2	$1/6$	0	$1/6$	$1/3$
s_3	$1/6$	$1/6$	0	$1/3$

$$P(D|M) = \frac{1}{3} \frac{1}{2} \frac{1}{3}$$

	r_1	r_2	r_3	
s_1	0	0	0	0
s_2	$1/6$	0	$1/3$	$1/2$
s_3	$1/6$	$1/3$	0	$1/2$

$$P(D|M) = \frac{1}{2} \frac{1}{3} \frac{1}{2}$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$

	r_1	r_2	r_3	
s_3	$1/2$	$1/2$	0	1

$$P(D|M) = \frac{1}{3} \frac{1}{2} \frac{1}{3}$$

	r_1	r_2	r_3	
s_3	$1/3$	$2/3$	0	1

$$P(D|M) = \frac{1}{2} \frac{1}{3} \frac{1}{2}$$

Evaluación de modelos causales



$$P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo}) = P(d_1 | \text{Modelo}) P(d_2 | d_1, \text{Modelo}) \dots$$


	r_1	r_2	r_3	
s_3	1/2	1/2	0	1

$$P(D|M) = \frac{1}{3} \frac{1}{2} \frac{1}{3} \frac{1}{2}$$

	r_1	r_2	r_3	
s_3	1/3	2/3	0	1



$$P(D|M) = \frac{1}{2} \frac{1}{3} \frac{1}{2} \frac{2}{3}$$

Evaluación de modelos causales



Evaluación de modelos causales

$$P(\text{Modelo}|\text{Datos}) = \frac{\overbrace{P(\text{Datos}|\text{Modelo})}^{\text{Predicción a priori}} P(\text{Modelo})}{P(\text{Datos})}$$



Evaluación de modelos causales

Predicción típica

$$P(\text{Datos}|\text{Modelo}) = P(d_1|\text{Modelo})P(d_2|d_1\text{Modelo}) \dots$$

Evaluación de modelos causales

Predicción típica

$$P(\text{Datos}|\text{Modelo}) = P(d_1|\text{Modelo})P(d_2|d_1\text{Modelo}) \dots$$

$$P(\text{Datos}|\text{Modelo}) = \prod_{i=1}^n \underbrace{P(\text{Datos}|\text{Modelo})^{1/n}}_{\substack{\text{Predicción típica} \\ \text{(Media geométrica)}}}$$

Evaluación de modelos causales

Comparación de modelos

$$P(\text{Datos}|\text{Modelo}) = P(d_1|\text{Modelo})P(d_2|d_1\text{Modelo}) \dots$$

$$P(\text{Datos}|\text{Modelo}) = \prod_{i=1}^n \underbrace{P(\text{Datos}|\text{Modelo})^{1/n}}_{\substack{\text{Predicción típica} \\ \text{(Media geométrica)}}}$$

$$\frac{P(\text{Modelo}_A|\text{Datos})}{P(\text{Modelo}_B|\text{Datos})} = \overbrace{\frac{P(\text{Datos}|\text{Modelo}_A)}{P(\text{Datos}|\text{Modelo}_B)}}^{\text{Bayes Factor}}$$

Evaluación de modelos causales

Comparación de modelos

$$P(\text{Datos}|\text{Modelo}) = P(d_1|\text{Modelo})P(d_2|d_1\text{Modelo}) \dots$$

$$P(\text{Datos}|\text{Modelo}) = \prod_{i=1}^n \underbrace{P(\text{Datos}|\text{Modelo})^{1/n}}_{\substack{\text{Predicción típica} \\ \text{(Media geométrica)}}}$$

$$\frac{P(\text{Modelo}_A|\text{Datos})}{P(\text{Modelo}_B|\text{Datos})} = \overbrace{\frac{P(\text{Datos}|\text{Modelo}_A)}{P(\text{Datos}|\text{Modelo}_B)}}^{\text{Bayes Factor}}$$

$$\log \frac{P(\text{Datos}|\text{Modelo}_A)}{P(\text{Datos}|\text{Modelo}_B)} = \underbrace{\log P(\text{Datos}|\text{Modelo}_A) - \log P(\text{Datos}|\text{Modelo}_B)}_{\text{Diferencia de predicción en orden de magnitud}}$$

Práctica 2: $P(\text{Modelo}|\text{Datos})$

Evaluación de modelos causales alternativos (**Entrega 1.1**)

Estimar siguientes casos.

1. Generar datos con el modelo causal generativo Monty Hall
 - a. $\text{Datos} = \{(C_0, S_0, R_0), (C_1, S_1, R_1), \dots\}$ con t episodios
2. Posterior de los modelos
 - a. $P(\text{Modelo}|\text{Datos})$
3. Predicción típica para cada modelo
 - a. $P(\text{Datos}|\text{Modelo})^{1/(t*3)}$
4. Diferencia de predicción en órdenes de magnitud.
 - a. $\log P(\text{Datos}|\text{Modelo}_A) - \log P(\text{Datos}|\text{Modelo}_B)$

Bibliografía sugerida

Unidad 1.1. Argumentos causales alternativos e incertidumbre.

1. Daphne Koller: Probabilística Graphical Models.
Capítulo 2 (todo): Probabilidad.
Capítulo 3 (hasta 3.2 incluido): Modelos gráficos.

Prácticas

Unidad 1.1. Argumentos causales alternativos e incertidumbre.

1. Evaluación de hipótesis internas a los argumentos causales dada la evidencia, $P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$, en el modelo de la alarma y el terremoto.
2. **Entrega 1.1.** Evaluación de argumentos causales alternativos dada la evidencia, $P(\text{Modelo}|\text{Datos})$, replicando el caso Monty Hall vs Base.

$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos