


# Inferencia aproximada y PPLs

## Unidad 2.2.




# Inferencia aproximada y PPLs

## Unidad 2.2.

Métodos analíticos de aproximación. Divergencia KL e inferencia aproximada por expectation propagation. El caso de la estimación de habilidad en la industria del video juego. Divergencia KL invertida e inferencia aproximada por variational inference. El caso del sistema de recomendación bayesiano de Netflix. El lenguaje de programación probabilística pyro. Métodos insaculares de aproximación. Inferencia aproximada por Monte Carlo: metropolis-hasting, Hamiltonian Monte Carlo y Sequential Monte Carlo. Lenguajes de programación probabilística pymc, stan, turinglang. El caso de la evaluación de instrumentos alternativos de medición, y el p-valor bayesiano. Métodos generativos de aproximación. Computación Bayesiana Aproximada (ABC): inferencia libre de verosimilitud mediante estadísticos de resumen y métricas de distancia. Métodos actuales de estimación de la distribución conjunta mediante redes neuronales a partir de datos simulados (SBI) e inferencia eficiente.


La vida es muy compleja

Incluso reglas simples pueden generar comportamientos complejos



## THE **GAME OF LIFE**

Conway desarrolla el juego de la vida con el interés de que su evolución sea “impredecible”




## THE **GAME OF LIFE**

Conway desarrolla el juego de la vida con el interés de que su evolución sea “impredecible”


Reglas:

- Sobreviven las celdas rodeadas por 2 o 3 celdas vivas
- Mueren las celdas por sobrepoblación, rodeadas por 4 o más celdas vivas
- Nacen las celdas cuando están rodeadas por exactamente 3


Fijo:



Fijo:



Periódico:



Fijo:




Periódico:




Periódico caminante:




Fijo:




Periódico:




Periódico caminante:




Periódico creciente:




Fijo:




Periódico:



Periódico caminante:




Periódico creciente:




“Caótico” finito: [playgameoflife.com](http://playgameoflife.com)


Fijo:




Periódico:



Periódico caminante:



Periódico creciente:



“Caótico” finito: [playgameoflife.com](http://playgameoflife.com)

“Caótico” infinito: Desconocido

# Inferencia aproximada

## 1. Aproximaciones por sampleo

- Gibbs Sampler
- Metropolis Hasting
- Hamiltonian Montecarlo
- Sequential Monte Carlo


## 2. Aproximaciones analítica

- Expectation propgation:  $\arg \min_{\theta} \text{KL}(p||q(\theta))$
- Variational Bayes:  $\arg \min_{\theta} \text{KL}(q(\theta)||p)$


## 3. Aproximaciones por simulación

- Approximate Bayesian Computation (ABC)
- Simulation-Based Inference (SBI)


# Mecanismos causales dinámicos




# Mecanismos causales dinámicos



# Mecanismos causales dinámicos




# Mecanismos causales dinámicos



$$P(s_t|r_t, c_t, a_t) = P(s_t|r_t)^{\mathbb{I}(a_t=0)} P(s_t|r_t, c_t)^{\mathbb{I}(a_t=1)}$$

# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.




$$P(s_t|r_t, c_t, a_t) = P(s_t|r_t)^{\mathbb{I}(a_t=0)} P(s_t|r_t, c_t)^{\mathbb{I}(a_t=1)}$$

# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.

¿Y la persona que esconde,  
cómo esconde?




$$P(s_t|r_t, c_t, a_t) = P(s_t|r_t)^{\mathbb{I}(a_t=0)} P(s_t|r_t, c_t)^{\mathbb{I}(a_t=1)}$$

# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.


¿Y la persona que esconde,  
cómo esconde?



# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.


¿Y la persona que esconde,  
cómo esconde?



# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.


¿Y la persona que esconde,  
cómo esconde?



# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.


¿Y la persona que esconde,  
cómo esconde?



# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.


¿Y la persona que esconde,  
cómo esconde?



# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.


¿Y la persona que esconde,  
cómo esconde?



# Mecanismos causales dinámicos



Generamos datos, sus universos paralelos.

¿Y la persona que esconde,  
cómo esconde?




# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.




# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.




¿Cuál de todos los puntos?




# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.




¿Cuál de todos los puntos?




# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.




¿Cuál de todos los puntos?




# Mecanismos causales dinámicos

Generamos datos, sus universos paralelos.




No mentir  
(MaxEnt)



# Mecanismos causales dinámicos


Generamos datos, sus universos paralelos.



No mentir  
(MaxEnt)


Ajá, y ahora?

$P(r|\text{Datos} = \{(c_0, s_0), \dots\})$



# Mecanismos causales dinámicos


Generamos datos, sus universos paralelos.



No mentir  
(MaxEnt)  
Prior


Ajá, y ahora?

$P(r|\text{Datos} = \{(c_0, s_0), \dots\})$



# Mecanismos causales dinámicos


Generamos datos, sus universos paralelos.



¿Y el posterior?


Ajá, y ahora?

$P(r|\text{Datos} = \{(c_0, s_0), \dots\})$



# Mecanismos causales dinámicos


Generamos datos, sus universos paralelos.



¿Y el posterior?


¿Cómo esconde?

$P(r|\text{Datos} = \{(c_0, s_0), \dots\})$





Paseos (no tan) aleatorios

# Meta-juego de la vida





# Meta-juego de la vida





# Meta-juego de la vida




## Turing completo



Turing completo  
Not




Turing completo  
And



# Turing completo

## Memoria



¿Es posible crear un máquina  
que genere números aleatorios?

Ante mismas condiciones iniciales  
devuelva diferentes resultados

# El principio de razón suficiente

Una cosa no puede ocurrir sin una causa que la produzca

# Modelo poblacional simple


## Determinista

$$p_{n+1} = p_n \cdot (1 - p_n) \cdot r \quad \text{con } r \in (0, 4)$$


# Modelo poblacional simple

## Determinista


$$p_{n+1} = p_n \cdot (1 - p_n) \cdot r \quad \text{con } r \in (0, 4)$$




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales



# Modelos causales deterministas no lineales




# Modelos causales deterministas no lineales




# Modelos causales deterministas

## Atractores




# Modelos causales deterministas

## Atractores




# Modelos causales deterministas

## Atractores




# Modelos causales deterministas


## Atractores




# Modelos causales deterministas




# Modelos causales deterministas



# Modelos causales deterministas




# Modelos causales deterministas




# Modelos causales deterministas

## caos determinista



# Efecto mariposa

El aleteo de una mariposa cambia totalmente tu futuro



# Efecto mariposa

El aleteo de una mariposa cambia totalmente tu futuro

Estos paseos (no) aleatorios del caos determinista sirven para emular un generador de números (pseudo) aleatorios de la distribución Uniforme.


# Efecto mariposa

El aleteo de una mariposa cambia totalmente tu futuro


Estos paseos (no) aleatorios del caos determinista sirven para emular un generador de números (pseudo) aleatorios de la distribución Uniforme.

**¿Cómo podemos hacer para generar números (pseudo) aleatorios de cualquier distribución de probabilidad?**


# Generador de números (pseudo) aleatorios de cualquier distribución de probabilidad



# Generador de números (pseudo) aleatorios de cualquier distribución de probabilidad




# Generador de números (pseudo) aleatorios de cualquier distribución de probabilidad




# Generador de números (pseudo) aleatorios de cualquier distribución de probabilidad

N = 10000




# Ancestral Sampling



# Ancestral Sampling


Producto de condicionales  
distribución conjunta



# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a, r, c, s)$$



# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a, r, c, s)$$

=

$$P(p)$$

$$P(\mathbf{b})$$


$$\prod_t$$

$$P(c_t)$$

$$P(r_t|\mathbf{b})$$

$$P(a_t|p)$$

$$P(s_t|r_t, a_t, c_t)$$



# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a, r, c, s)$$

=

$$P(p)$$

$$P(\mathbf{b})$$

$$\prod_t$$


$$P(c_t)$$

$$P(r_t|\mathbf{b})$$

$$P(a_t|p)$$

$$P(s_t|r_t, a_t, c_t)$$

Aleatorio de condicionales  
son datos sintéticos



# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a, r, c, s)$$

=

$$P(p)$$

$$P(\mathbf{b})$$

$$\prod_t$$

$$P(c_t)$$


$$P(r_t|\mathbf{b})$$

$$P(a_t|p)$$

$$P(s_t|r_t, a_t, c_t)$$

Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta



# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a, r, c, s)$$

=

$$P(p)$$

$$P(\mathbf{b})$$


$$\prod_t$$

$$P(c_t)$$

$$P(r_t|\mathbf{b})$$

$$P(a_t|p)$$

$$P(s_t|r_t, a_t, c_t)$$



Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta

=

$$p^* \sim P(p)$$

$$\mathbf{b}^* \sim P(\mathbf{b})$$

for  $t$  in 1:T

$$c_t^* \sim P(c_t)$$

$$r_t^* \sim P(r_t|\mathbf{b}^*)$$


$$a_t^* \sim P(a_t|p^*)$$

$$s_t^* \sim P(s_t|r_t^*, a_t^*, c_t^*)$$

# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(\underbrace{p, \mathbf{b}, a}_{\text{Ocultas}} \mid \underbrace{r, c, s}_{\text{Datos}})$$



Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta

=

$$p^* \sim P(p)$$

$$\mathbf{b}^* \sim P(\mathbf{b})$$

for  $t$  in  $1:T$

$$c_t^* \sim P(c_t)$$

$$r_t^* \sim P(r_t | \mathbf{b}^*)$$

$$a_t^* \sim P(a_t | p^*)$$

$$s_t^* \sim P(s_t | r_t^*, a_t^*, c_t^*)$$


# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a \mid r, c, s)$$

$\propto$

$$P(p, \mathbf{b}, a, r, c, s)$$



Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta

$=$

$$p^* \sim P(p)$$

$$\mathbf{b}^* \sim P(\mathbf{b})$$

for  $t$  in 1:T

$$c_t^* \sim P(c_t)$$

$$r_t^* \sim P(r_t | \mathbf{b}^*)$$

$$a_t^* \sim P(a_t | p^*)$$

$$s_t^* \sim P(s_t | r_t^*, a_t^*, c_t^*)$$


# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a \mid r, c, s)$$

$\propto$

$$P(p, \mathbf{b}, a, \underbrace{r, c, s}_{\text{Datos}})$$



Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta

$=$

$$p^* \sim P(p)$$

$$\mathbf{b}^* \sim P(\mathbf{b})$$

for  $t$  in 1:T

$$c_t^* \sim P(c_t)$$

$$r_t^* \sim P(r_t | \mathbf{b}^*)$$

$$a_t^* \sim P(a_t | p^*)$$

$$s_t^* \sim P(s_t | r_t^*, a_t^*, c_t^*)$$

# Ancestral Sampling


Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a \mid r, c, s)$$

$\propto$

$$P(p, \mathbf{b}, a, \underbrace{r, c, s}_{\text{Datos}})$$

¿Se puede aproximar con  
Ancestral Sampling?



Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta

=

$$p^* \sim P(p)$$

$$\mathbf{b}^* \sim P(\mathbf{b})$$

for  $t$  in  $1:T$

$$c_t^* \sim P(c_t)$$

$$r_t^* \sim P(r_t | \mathbf{b}^*)$$

$$a_t^* \sim P(a_t | p^*)$$

$$s_t^* \sim P(s_t | r_t^*, a_t^*, c_t^*)$$

# Ancestral Sampling


Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a \mid r, c, s)$$

$\propto$

$$P(p, \mathbf{b}, a, \underbrace{r, c, s}_{\text{Datos}})$$

¿Se puede aproximar con  
Ancestral Sampling?  
¿Cómo?



Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta

=

$$p^* \sim P(p)$$

$$\mathbf{b}^* \sim P(\mathbf{b})$$

for  $t$  in 1:T

$$c_t^* \sim P(c_t)$$

$$r_t^* \sim P(r_t|\mathbf{b}^*)$$

$$a_t^* \sim P(a_t|p^*)$$

$$s_t^* \sim P(s_t|r_t^*, a_t^*, c_t^*)$$

# Ancestral Sampling

Producto de condicionales  
distribución conjunta

$$P(p, \mathbf{b}, a \mid r, c, s)$$


$\propto$

$$P(p, \mathbf{b}, a, \underbrace{r, c, s}_{\text{Datos}})$$

¿Se puede aproximar con  
Ancestral Sampling?

¿Cómo?

¿Problema?



Aleatorio de condicionales  
son datos sintéticos

Datos de la conjunta

=

$$p^* \sim P(p)$$

$$\mathbf{b}^* \sim P(\mathbf{b})$$

for  $t$  in 1:T

$$c_t^* \sim P(c_t)$$

$$r_t^* \sim P(r_t | \mathbf{b}^*)$$

$$a_t^* \sim P(a_t | p^*)$$

$$s_t^* \sim P(s_t | r_t^*, a_t^*, c_t^*)$$

# Saltar entre universos compatibles

## Ancestral Sampling

$$P(p, \mathbf{b}, a, \underbrace{r, c, s}_{\text{Datos}}) = [\text{Cualquier descomposición}]$$

# Saltar entre universos compatibles

## Ancestral Sampling

$$P(p, \mathbf{b}, a, \underbrace{r, c, s}_{\text{Datos}}) = \underbrace{[\text{Cualquier descomposición}]}_{\text{Cada una induce un Ancestral Sampling distinto}}$$

# Saltar entre universos compatibles

## Ancestral Sampling

$$P(p, \mathbf{b}, a, \underbrace{r, c, s}_{\text{Datos}}) = [\text{Cualquier descomposición}] \underbrace{P(p|\mathbf{b}, a, r, c, s)}_{\substack{\text{Último paso del} \\ \text{Ancestral Sampling}}}$$

# Saltar entre universos compatibles

## Ancestral Sampling

$$P(p, \underbrace{\mathbf{b}, a, r, c, s}_{\text{Datos}}) = [\text{Cualquier descomposición}] \underbrace{P(p|\mathbf{b}, a, r, c, s)}_{\substack{\text{Último paso del} \\ \text{Ancestral Sampling}}}$$

Si ya tenemos valores específicos para  $\mathbf{b}^*, a^*, \underbrace{r^*, c^*, s^*}_{\text{Datos}}$   
podemos saltar en  $p$  entre universos compatibles  $(p, \mathbf{b}^*, a^*, r^*, c^*, s^*)$   
eligiendo

$$p^* \sim P(p|\mathbf{b}^*, a^*, r^*, c^*, s^*)$$

# Saltar entre universos compatibles

## Ancestral Sampling

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

# Saltar entre universos compatibles

## Ancestral Sampling

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

# Saltar entre universos compatibles

## Ancestral Sampling

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

Perfecto! Sabemos generar números (pseudo) aleatorio de cualquier distribución

$P(p|\mathbf{b}, a, r, c, s)$ , no?

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p, \mathbf{b}, a, r, c, s)}{P(\mathbf{b}, a, r, c, s)}$$

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(\mathbf{b})P(a|p)P(r|\mathbf{b})P(c)P(s|a, r, c)}{P(\mathbf{b})P(r|\mathbf{b})P(c)P(s|a, r, c) \sum_p P(p)P(a|p)}$$

# Saltar entre universos compatibles

## Gibbs Sampler!

$$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s) \quad \text{Salto en } p \text{ dado el resto}$$

$$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s) \quad \text{Salto en } \mathbf{b} \text{ dado el resto}$$

$$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s) \quad \text{Salto en } a \text{ dado el resto}$$

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p) \cancel{P(\mathbf{b})} P(a|p) \cancel{P(r|\mathbf{b})} \cancel{P(c)} \cancel{P(s|a, r, c)}}{\cancel{P(\mathbf{b})} \cancel{P(r|\mathbf{b})} \cancel{P(c)} \cancel{P(s|a, r, c)} \sum_p P(p) P(a|p)}$$

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(a|p)}{\sum_p P(p)P(a|p)}$$

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(a|p)}{\sum_p P(p)P(a|p)} \propto P(p)P(a|p)$$

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(a|p)}{\sum_p P(p)P(a|p)} \propto P(p)P(a|p) = f(p)$$

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(a|p)}{\sum_p P(p)P(a|p)} \propto P(p)P(a|p) = f(p)$$

Está difícil calcular la acumulada.

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(a|p)}{\sum_p P(p)P(a|p)} \propto P(p)P(a|p) = f(p)$$

Está difícil calcular la acumulada. Algunas opciones fáciles:

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(a|p)}{\sum_p P(p)P(a|p)} \propto P(p)P(a|p) = f(p)$$

Está difícil calcular la acumulada. Algunas opciones fáciles:

- Aproximamos la acumulada de  $\frac{f(p)}{\sum_p f(p)}$  con una **grilla fina** y con la uniforme elegimos  $p$

# Saltar entre universos compatibles

## Gibbs Sampler!

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(p|\mathbf{b}, a, r, c, s)$  Salto en  $p$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(\mathbf{b}|p, a, r, c, s)$  Salto en  $\mathbf{b}$  dado el resto

$P(p, \mathbf{b}, a, r, c, s) = [\text{Cualquier descomposición}] P(a|p, \mathbf{b}, r, c, s)$  Salto en  $a$  dado el resto

$$P(p|\mathbf{b}, a, r, c, s) = \frac{P(p)P(a|p)}{\sum_p P(p)P(a|p)} \propto P(p)P(a|p) = f(p)$$

Está difícil calcular la acumulada. Algunas opciones fáciles:

- Aproximamos la acumulada de  $\frac{f(p)}{\sum_p f(p)}$  con una **grilla fina** y con la uniforme elegimos  $p$
- **Saltamos a otro**  $p'$ , miramos la “acumulada” de  $\mathcal{B}(\frac{f(p')}{f(p') + f(p)})$ , y con la uniforme elegimos

# Saltar entre universos compatibles

Barker Sampler

# Saltar entre universos compatibles

## Barker Sampler

```
def barker_sampler(fn, gn, x_actual):
```

# Saltar entre universos compatibles

## Barker Sampler

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn() # Genera numero aleatorio en el rango de x
```

# Saltar entre universos compatibles

## Barker Sampler

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn() # Genera numero aleatorio en el rango de x  
    proba_propuesto = fn(x_propuesto) / (fn(x_propuesto)+ fn(x_actual))
```

# Saltar entre universos compatibles

## Barker Sampler

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn() # Genera numero aleatorio en el rango de x  
    proba_propuesto = fn(x_propuesto) / (fn(x_propuesto)+ fn(x_actual))  
    if unif() < proba_propuesto:  
        return x_propuesto  
    else:  
        return x_actual
```

# Saltar entre universos compatibles

## Barker Sampler

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn() # Genera numero aleatorio en el rango de x  
    proba_propuesto = fn(x_propuesto) / (fn(x_propuesto)+ fn(x_actual))  
    if unif() < proba_propuesto:  
        return x_propuesto  
    else:  
        return x_actual
```

# Saltar entre universos compatibles

## Metropolis Hasting

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn() # Genera numero aleatorio en el rango de x  
    proba_propuesto = fn(x_propuesto) / (fn(x_propuesto)+ fn(x_actual))  
    if unif() < proba_propuesto:  
        return x_propuesto  
    else:  
        return x_actual
```

Rechaza la propuesta muchas veces, en proporción a proba\_propuesto.

# Saltar entre universos compatibles

## Metropolis Hasting

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn() # Genera numero aleatorio en el rango de x  
    bayes_factor = fn(x_propuesto) / fn(x_actual)  
    if unif() < min(1,bayes_factor):  
        return x_propuesto  
    else:  
        return x_actual
```

# Saltar entre universos compatibles

## Metropolis Hasting

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn() # Genera numero aleatorio en el rango de x  
    bayes_factor = fn(x_propuesto) / fn(x_actual)  
    if unif() < min(1,bayes_factor):  
        return x_propuesto  
    else:  
        return x_actual
```

Acepta siempre la propuesta a partir de  $\text{proba\_propuesto} \geq 0.5$ .

# Saltar entre universos compatibles

## Hamiltonian Monte Carlo

```
def barker_sampler(fn, gn, x_actual):  
    x_propuesto = gn(posicion, momento) # Elige inteligentemente el siguiente x  
    bayes_factor = fn(x_propuesto) / fn(x_actual)  
    if unif() < min(1, bayes_factor):  
        return x_propuesto  
    else:  
        return x_actual
```

# Divergencia Kullback-Leibler

$$-\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T}$$

Tasa de predicción (temporal) en órdenes de magnitud (log) en signo opuesto

# Divergencia Kullback-Leibler

$$\begin{aligned} & -\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ & = \\ & \sum_{c,s,r} P(c, s, r | \text{Realidad Causal}) \cdot (-\log P(c, s, r | \text{Modelo Causal})) \end{aligned}$$

Información esperada del sistema de comunicación

# Divergencia Kullback-Leibler

$$\begin{aligned} & -\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ & = \\ & \sum_{c,s,r} P(c, s, r | \text{Realidad Causal}) \cdot (-\log P(c, s, r | \text{Modelo Causal})) \\ & = \\ & \mathcal{H}(R) + \underbrace{\sum_{c,s,r} P(c, s, r | R) \cdot \left( -\log \frac{P(c, s, r | M)}{P(c, s, r | R)} \right)}_{\text{Divergencia KL } \mathcal{D}_{KL}(R||M)} \end{aligned}$$

Tasa de información del sistema de comunicación perfecto (entropía)  
+ Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot \left( -\log \frac{P(c, s, r|M)}{P(c, s, r|R)} \right)$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot (\log P(c, s, r|R) - \log P(c, s, r|M))$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot \underbrace{\left( \log P(c, s, r|R) - \log P(c, s, r|M) \right)}_{\substack{\text{La diferencia de predicción} \\ \text{en órdenes de magnitud}}}$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot \underbrace{(\log P(c, s, r|R) - \log P(c, s, r|M))}_{\substack{\text{La diferencia de predicción} \\ \text{en órdenes de magnitud}}}$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot \underbrace{(\log P(c, s, r|R) - \log P(c, s, r|M))}_{\substack{\text{La diferencia de predicción} \\ \text{en órdenes de magnitud}}}$$

¿Para qué sirve si no conozco la realidad?

Tasa de información debida a la imperfección del sistema (divergencia KL)

## Divergencia KL

$$\text{KL}(p(x)||q(x)) = \sum_x p(x) \left( -\log \frac{q(x)}{p(x)} \right)$$


## Divergencia KL

$$\text{KL}(p(x)||q(x)) = \sum_x p(x) \left( -\log \frac{q(x)}{p(x)} \right)$$

$$\text{Mixture}(x|\mu_1, \sigma_1, \mu_2, \sigma_2, w) = w\mathcal{N}(x|\mu_1, \sigma_1^2) + (1 - w)\mathcal{N}(x|\mu_2, \sigma_2^2)$$


# Divergencia KL

$$\text{KL}(p(x)||q(x)) = \sum_x p(x) \left( -\log \frac{q(x)}{p(x)} \right)$$




# Divergencia KL

$$\text{KL}(p(x)||q(x)) = \sum_x p(x) \left( -\log \frac{q(x)}{p(x)} \right)$$



# Divergencia KL

$$\text{KL}(p(x)||q(x)) = \sum_x p(x) \left( -\log \frac{q(x)}{p(x)} \right)$$



## Estimación de habilidad por pasaje de mensajes




# Evidencia vs Verosimilitud

$$p(r) = 1 - \Phi\left(0 \mid \underbrace{(\mu_1 + \mu_2) - (\mu_3 + \mu_4)}_{\text{Diferencia esperada}}, \underbrace{4\beta^2 + \sigma_1^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2}_{\text{Incertidumbre total}}\right)$$


$$p(r|s_1) = 1 - \Phi\left(0 \mid \underbrace{(s_1 + \mu_2) - (\mu_3 + \mu_4)}_{\text{Diferencia esperada si la habilidad fuera } s_1}, \underbrace{4\beta^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2}_{\text{Incertidumbre total salvo la de la habilidad } s_1}\right)$$

Predicciones del resultado  
usando todas las hipótesis  
pesadas por la creencia a prior




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$


$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_3 \mid r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_3 \mid \mu_3, \sigma_2^2)}^{\text{Priori}} \overbrace{\Phi(0 \mid \delta - \mu_3 - s_3, \vartheta^2 - \sigma_3^2)}^{\text{Verosimilitud}} \quad \text{Caso perdedor}$$







$$m_{f_d \rightarrow d}(d) =$$




$$m_{f_d \rightarrow d}(d) = \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(d + t_b | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \int \underbrace{\mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)}_{\text{const.}} \underbrace{\mathcal{N}(t_b | \mu_*, \sigma_*^2)}_1 dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(d | \underbrace{\mu_a - \mu_b}_{\text{Diferencia esperada } \delta}, \underbrace{\sigma_a^2 + \sigma_b^2}_{\text{Varianza total } \vartheta})
 \end{aligned}$$



$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(d | \underbrace{\mu_a - \mu_b}_{\text{Diferencia esperada } \delta}, \underbrace{\sigma_a^2 + \sigma_b^2}_{\text{Varianza total } \vartheta^2}) = \mathcal{N}(d | \delta, \vartheta^2)
 \end{aligned}$$




$$m_{f_d \rightarrow d}(d) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)$$



$$m_{f_d \rightarrow d}(d) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)$$


$$m_{f_r \rightarrow d}(d) = \mathbb{I}(r = (d > 0))$$



$$m_{f_d \rightarrow d}(d) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)$$

$$m_{f_r \rightarrow d}(d) = \mathbb{I}(r = (d > 0))$$

$$p(d|r) \propto p(d, r) = m_{f_r \rightarrow d}(d) m_{f_d \rightarrow d}(d)$$



$$m_{f_d \rightarrow d}(d) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)$$


$$m_{f_r \rightarrow d}(d) = \mathbb{I}(r = (d > 0))$$

$$p(d|r) \propto p(d, r) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2) \mathbb{I}(r = (d > 0))$$

# Mínima Divergencia

Aproximación del posterior ( $\propto$ ) de la diferencia


$$p(d, \underbrace{\text{Gana}}_{r=1}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(r = (d > 0))$$



# Mínima Divergencia

Aproximación del posterior ( $\propto$ ) de la diferencia


$$p(d, \underbrace{\text{Gana}}_{r=1}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(r = (d > 0))$$



# Mínima Divergencia

Aproximación del posterior ( $\infty$ ) de la diferencia

$$p(d, \underbrace{\text{Gana}}_{r=1}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(r = (d > 0))$$



# Mínima Divergencia

Aproximación del posterior ( $\propto$ ) de la diferencia

$$p(d, \underbrace{\text{Gana}}_{r=1}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(r = (d > 0))$$

$$\hat{p}(d, \text{Gana}) \propto \mathcal{N}\left(d \mid \underbrace{E(d, \text{Gana} | d > 0)}_{\text{Misma media}}, \underbrace{V(d, \text{Gana} | d > 0)}_{\text{Misma varianza}}\right)$$

# Mínima Divergencia

Aproximación del posterior ( $\propto$ ) de la diferencia

$$p(d, \underbrace{\text{Gana}}_{r=1}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(r = (d > 0))$$

$$\hat{p}(d, \text{Gana}) \propto \mathcal{N}\left(d \mid \underbrace{E(d, \text{Gana} | d > 0)}_{\text{Misma media}}, \underbrace{V(d, \text{Gana} | d > 0)}_{\text{Misma varianza}}\right)$$

Siempre la divergencia dentro de una familia exponencial (gaussiana) es mínima cuando tienen mismos momentos (Expectation Propagation)

# Mínima Divergencia

Aproximación del mensaje de la diferencia

$$p(d, \text{Gana}) = m_{f_d \rightarrow d}(d) m_{f_r \rightarrow d}(d)$$

# Mínima Divergencia

Aproximación del mensaje de la diferencia

$$p(d, \text{Gana}) = m_{f_d \rightarrow d}(d) m_{f_r \rightarrow d}(d)$$

$$m_{f_r \rightarrow d}(d) = m_{d \rightarrow f_d}(d)$$

# Mínima Divergencia

Aproximación del mensaje de la diferencia

$$p(d, \text{Gana}) = m_{f_d \rightarrow d}(d) m_{d \rightarrow f_d}(d)$$

# Mínima Divergencia

Aproximación del mensaje de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

# Mínima Divergencia

Aproximación del mensaje de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$m_{d \rightarrow f_d}(d) = \frac{p(d, \text{Gana})}{p(d)}$$

# Mínima Divergencia

Aproximación del mensaje de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$m_{d \rightarrow f_d}(d) = \frac{p(d, \text{Gana})}{p(d)} \approx \frac{\hat{p}(d, \text{Gana})}{p(d)}$$

# Mínima Divergencia

Aproximación del mensaje de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$\begin{aligned} m_{d \rightarrow f_d}(d) &= \frac{p(d, \text{Gana})}{p(d)} \approx \frac{\hat{p}(d, \text{Gana})}{p(d)} \\ &= \frac{\mathcal{N}(d | \hat{\delta}, \hat{\vartheta}^2)}{\mathcal{N}(d | \delta, \vartheta^2)} \end{aligned}$$


# Mínima Divergencia

Aproximación del mensaje de la diferencia


$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$\begin{aligned} m_{d \rightarrow f_d}(d) &= \frac{p(d, \text{Gana})}{p(d)} \approx \frac{\hat{p}(d, \text{Gana})}{p(d)} \\ &= \frac{\mathcal{N}(d | \hat{\delta}, \hat{\vartheta}^2)}{\mathcal{N}(d | \delta, \vartheta^2)} \propto \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \end{aligned}$$


$$\text{con } \delta_{\div} = \frac{\hat{\delta}}{\hat{\vartheta}^2} - \frac{\delta}{\vartheta^2} \text{ y } \vartheta_{\div}^2 = \left( \frac{1}{\hat{\vartheta}^2} - \frac{1}{\vartheta^2} \right)^{-1}$$




$$\hat{m}_{f_d \rightarrow t_a}(t_a) \approx \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dd dt_b$$




$$\begin{aligned}
 \hat{m}_{f_d \rightarrow t_a}(t_a) &\approx \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dd dt_b \\
 &= \int \mathcal{N}(t_a - t_b | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 \hat{m}_{f_d \rightarrow t_a}(t_a) &\approx \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dd dt_b \\
 &= \int \mathcal{N}(t_a - t_b | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(t_a | \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2)
 \end{aligned}$$




$$\hat{m}_{f_{t_a} \rightarrow p_1}(p_1) = \iint \mathbb{I}(t_a = p_1 + p_2) \mathcal{N}(t_a | \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) dt_a dp_2$$




$$\begin{aligned}
 \hat{m}_{f_{t_a} \rightarrow p_1}(p_1) &= \iint \mathbb{I}(t_a = p_1 + p_2) \mathcal{N}(t_a \mid \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 \mid \mu_2, \sigma_2^2 + \beta^2) dt_a dp_2 \\
 &= \int \mathcal{N}(p_1 + p_2 \mid \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 \mid \mu_2, \sigma_2^2 + \beta^2) dp_2
 \end{aligned}$$




$$\begin{aligned}
 \hat{m}_{f_{t_a} \rightarrow p_1}(p_1) &= \iint \mathbb{I}(t_a = p_1 + p_2) \mathcal{N}(t_a \mid \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 \mid \mu_2, \sigma_2^2 + \beta^2) dt_a dp_2 \\
 &= \int \mathcal{N}(p_1 + p_2 \mid \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 \mid \mu_2, \sigma_2^2 + \beta^2) dp_2 \\
 &= \mathcal{N}(p_1 \mid \underbrace{\mu_b - \mu_2 + \delta_{\div}}_{\mu_1 - \delta}, \underbrace{\vartheta_{\div}^2 + \sigma_b^2 + \sigma_2^2 + \beta^2}_{\vartheta^2 - (\sigma_1^2 + \beta^2)})
 \end{aligned}$$



$$\hat{m}_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \mathcal{N}(p_1 | \mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2 - \beta^2) dp_1$$



$$\begin{aligned}
 \hat{m}_{f_{p_1} \rightarrow s_1}(s_1) &= \int \mathcal{N}(p_1 | s_1, \beta^2) \mathcal{N}(p_1 | \mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2 - \beta^2) dp_1 \\
 &= \mathcal{N}(s_1 | \mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2)
 \end{aligned}$$



$$\begin{aligned}\hat{m}_{f_{p_1} \rightarrow s_1}(s_1) &= \int \mathcal{N}(p_1|s_1, \beta^2) \mathcal{N}(p_1|\mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2 - \beta^2) dp_1 \\ &= \mathcal{N}(s_1|\mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2)\end{aligned}$$

$$\hat{p}(s_1, r) = \mathcal{N}(s_1|\mu_1, \sigma_1^2) \mathcal{N}(s_1|\mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2)$$

## Posterior aproximado

$$\hat{p}(s_1|r) = \arg \min_{\mu, \sigma} \text{KL}(p(s_1|r) || \mathcal{N}(s_1|\mu, \sigma^2) )$$

## Posterior aproximado

$$\hat{p}(s_1|r) = \mathcal{N}(s_1 \mid \hat{\mu}, \hat{\sigma}^2)$$

## Posterior aproximado

$$\underbrace{\hat{p}(s_1|r)}_{\text{Posterior}_1} = \mathcal{N}(s_1 \mid \hat{\mu}, \hat{\sigma}^2)$$

## Posterior aproximado

$$\underbrace{\widehat{p}(s_1|r)}_{\text{Posterior}_1} = \mathcal{N}(s_1 \mid \widehat{\mu}, \widehat{\sigma}^2)$$

$$\widehat{\text{Posterior}}_t \rightarrow \text{Prior}_{t+1}$$


# Posterior aproximado

$$\underbrace{\widehat{p}(s_1|r)}_{\text{Posterior}_1} = \mathcal{N}(s_1 | \widehat{\mu}, \widehat{\sigma}^2)$$


$$\widehat{\text{Posterior}}_t \rightarrow \text{Prior}_{t+1}$$

$$\underbrace{p(s_1)}_{\text{Prior}_2} = \mathcal{N}(s_b | \widehat{\mu}, \widehat{\sigma}^2 + \gamma^2)$$

# Enfoque Posterior $\rightarrow$ Prior



# Enfoque Posterior $\rightarrow$ Prior



# Enfoque Posterior $\rightarrow$ Prior

Problemas de un procedimiento ad-hoc

## Problemas.

- Ofrece resultados que van en contra de nuestra intuición

# Enfoque Posterior $\rightarrow$ Prior

Problemas de un procedimiento ad-hoc

## Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales

# Enfoque Posterior $\rightarrow$ Prior

## Problemas de un procedimiento ad-hoc

### Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales
- No aprovecha la información disponible (entre ramas paralelas)

# Enfoque Posterior $\rightarrow$ Prior

## Problemas de un procedimiento ad-hoc

### Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales
- No aprovecha la información disponible (entre ramas paralelas)
- No garantiza comparabilidad entre estimaciones lejanas en el tiempo y el espacio.

# Enfoque Posterior $\rightarrow$ Prior

Problemas de un procedimiento ad-hoc


Propaga la información en una sola dirección, del pasado al futuro.

## Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales
- No aprovecha la información disponible (entre ramas paralelas)
- No garantiza comparabilidad entre estimaciones lejanas en el tiempo y el espacio.


# Modelos de historia completa

Estado del arte en la industria del videojuego.




# Modelos de historia completa

Estado del arte en la industria del videojuego.




# Modelos de historia completa

Estado del arte en la industria del videojuego.




# Modelos de historia completa

Estado del arte en la industria del videojuego.




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing




# Modelos de historia completa

## Smoothing



# Modelos de historia completa

## Smoothing



# TrueSkill Through Time

Estado del arte en la industria del videojuego.



python™



# TrueSkill Through Time

Estado del arte en la industria del videojuego.


```
using CSV; using Dates
using TrueSkillThroughTime
global const ttt = TrueSkillThroughTime

data = CSV.read("atp.csv")
dates = Dates.value.(data[:, "time_start"] .- Date("1900-1-1"))

matches = [ r.double == "t" ? [[r.w1_id, r.w2_id], [r.l1_id, r.l2_id]] :
            [[r.w1_id], [r.l1_id]] for r in eachrow(data) ]
h = History(composition = matches, times = dates, sigma = 1.6, gamma = 0.036)
convergence(h, epsilon = 0.01, iterations = 10)
```

# TrueSkill Through Time

Estado del arte en la industria del videojuego.





A large, stylized red 'N' with the word 'NETFLIX' in white capital letters is centered over a collage of various Asian movie posters. The posters are tilted and overlap each other, creating a dense background. Some visible titles include '水行俠' (Aquaman), '格雷的五十道陰影' (Fifty Shades of Grey), '我親愛的爸爸' (My Beloved Father), '刻在你心底的名字' (Your Name Engraved Herein), '消失的種人' (The Disappearance of the Human Race), '歌喉讚2' (Pitch Perfect 2), '飯道主夫' (The Chef's Men), '#ALIVE', 'LAW SCHOOL', '轉學來的女生' (Girl from Nowhere), '黑道律師文森佐' (The Black Attorney Vincenzo), and '愛的迫降' (Love to Death).

NETFLIX

# Sistema de recomendación de Netflix

Modelo original (versión bayesiana)

Datos:

$\mathbf{x} \in \mathbb{R}^n$ : vector de atributos (descripción) de una persona.

$\mathbf{y} \in \mathbb{R}^m$ : vector de atributos (descripción) de un ítem.

$\Phi \in \mathbb{R}^f$ : vector de atributos del contexto.

$r \in \mathbb{R}$ : puntaje que la persona da al ítem (rating).

# Sistema de recomendación de Netflix

Modelo original (versión bayesiana)

Datos:

$\mathbf{x} \in \mathbb{R}^n$ : vector de atributos (descripción) de una persona.

$\mathbf{y} \in \mathbb{R}^m$ : vector de atributos (descripción) de un ítem.

$\Phi \in \mathbb{R}^f$ : vector de atributos del contexto.

$r \in \mathbb{R}$ : puntaje que la persona da al ítem (rating).

Variables ocultas

$\mathbf{s} = \mathbf{U}\mathbf{x} \in \mathbb{R}^k$ : gustos de las personas, con  $\mathbf{U} \in \mathbb{R}^{k \times n}$  sus características latentes.

$\mathbf{t} = \mathbf{V}\mathbf{y} \in \mathbb{R}^k$ : géneros de los ítems, con  $\mathbf{V} \in \mathbb{R}^{k \times m}$  sus características latentes.

$b = \Phi^T \mathbf{w} = \sum_f \Phi_f w_f \in \mathbb{R}$ : sesgo de contexto, con  $\mathbf{w} \in \mathbb{R}^f$  los pesos latentes.

# Sistema de recomendación de Netflix

Modelo original (versión bayesiana)

Datos:

$\mathbf{x} \in \mathbb{R}^n$ : vector de atributos (descripción) de una persona.

$\mathbf{y} \in \mathbb{R}^m$ : vector de atributos (descripción) de un ítem.

$\Phi \in \mathbb{R}^f$ : vector de atributos del contexto.

$r \in \mathbb{R}$ : puntaje que la persona da al ítem (rating).

Variables ocultas

$\mathbf{s} = \mathbf{U}\mathbf{x} \in \mathbb{R}^k$ : gustos de las personas, con  $\mathbf{U} \in \mathbb{R}^{k \times n}$  sus características latentes.

$\mathbf{t} = \mathbf{V}\mathbf{y} \in \mathbb{R}^k$ : géneros de los ítems, con  $\mathbf{V} \in \mathbb{R}^{k \times m}$  sus características latentes.

$b = \Phi^T \mathbf{w} = \sum_f \Phi_f w_f \in \mathbb{R}$ : sesgo de contexto, con  $\mathbf{w} \in \mathbb{R}^f$  los pesos latentes.

Predicción:

$$p(r|\mathbf{s}, \mathbf{t}, b) = \mathcal{N}(r|\mathbf{s}^T \mathbf{t} + b, \beta^2)$$

# Ratings como Gustos $\times$ Características

| Usuarios | Películas |   |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|---|
|          | 5         | 1 | 4 | 4 | 2 | 2 | 5 | 1 | 5 |
|          | 3         | 2 | 3 | 1 | 1 | 2 | 2 | 4 | 4 |
|          | 1         | 3 | 3 | 5 | 1 | 5 | 2 | 2 | 1 |
|          | 4         | 2 | 3 | 4 | 3 | 5 | 1 | 1 | 4 |
|          | 5         | 3 | 2 | 2 | 4 | 1 | 4 | 5 | 2 |
|          | 1         | 3 | 5 | 4 | 2 | 1 | 2 | 1 | 4 |
|          | 3         | 1 | 4 | 2 | 4 | 5 | 2 | 1 | 2 |

Matriz de puntuaciones, 1-5 estrellas

$$\mathbf{A} \in \mathbb{R}^{7 \times 9}, \mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^t$$

# Ratings como Gustos $\times$ Características

| Usuarios | Películas |   |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|---|
|          | 5         | 1 | 4 | 4 | 2 | 2 | 5 | 1 | 5 |
|          | 3         | 2 | 3 | 1 | 1 | 2 | 2 | 4 | 4 |
|          | 1         | 3 | 3 | 5 | 1 | 5 | 2 | 2 | 1 |
|          | 4         | 2 | 3 | 4 | 3 | 5 | 1 | 1 | 4 |
|          | 5         | 3 | 2 | 2 | 4 | 1 | 4 | 5 | 2 |
|          | 1         | 3 | 5 | 4 | 2 | 1 | 2 | 1 | 4 |
|          | 3         | 1 | 4 | 2 | 4 | 5 | 2 | 1 | 2 |

Matriz de puntuaciones, 1-5 estrellas

$$\mathbf{A} \in \mathbb{R}^{7 \times 9}, \mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^t$$

| Usuarios | Características |          |         |                   |
|----------|-----------------|----------|---------|-------------------|
|          | $u_{11}$        | $u_{12}$ | $\dots$ | $u_{1\mathbf{k}}$ |
|          | $u_{21}$        | $u_{22}$ |         | $u_{2\mathbf{k}}$ |
|          | $\vdots$        |          |         | $\vdots$          |
|          | $u_{71}$        | $u_{72}$ | $\dots$ | $u_{7\mathbf{k}}$ |


Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times \mathbf{k}}$

# Ratings como Gustos $\times$ Características

| Usuarios | Películas |   |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|---|
|          | 5         | 1 | 4 | 4 | 2 | 2 | 5 | 1 | 5 |
|          | 3         | 2 | 3 | 1 | 1 | 2 | 2 | 4 | 4 |
|          | 1         | 3 | 3 | 5 | 1 | 5 | 2 | 2 | 1 |
|          | 4         | 2 | 3 | 4 | 3 | 5 | 1 | 1 | 4 |
|          | 5         | 3 | 2 | 2 | 4 | 1 | 4 | 5 | 2 |
|          | 1         | 3 | 5 | 4 | 2 | 1 | 2 | 1 | 4 |
|          | 3         | 1 | 4 | 2 | 4 | 5 | 2 | 1 | 2 |

Matriz de puntuaciones, 1-5 estrellas

$$\mathbf{A} \in \mathbb{R}^{7 \times 9}, \mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^t$$



Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$

# Ratings como Gustos $\times$ Características

|          | Películas |   |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|---|
| Usuarios | 5         | 1 | 4 | 4 | 2 | 2 | 5 | 1 | 5 |
|          | 3         | 2 | 3 | 1 | 1 | 2 | 2 | 4 | 4 |
|          | 1         | 3 | 3 | 5 | 1 | 5 | 2 | 2 | 1 |
|          | 4         | 2 | 3 | 4 | 3 | 5 | 1 | 1 | 4 |
|          | 5         | 3 | 2 | 2 | 4 | 1 | 4 | 5 | 2 |
|          | 1         | 3 | 5 | 4 | 2 | 1 | 2 | 1 | 4 |
|          | 3         | 1 | 4 | 2 | 4 | 5 | 2 | 1 | 2 |

Matriz de puntuaciones, 1-5 estrellas

$$\mathbf{A} \in \mathbb{R}^{7 \times 9}, \mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^t$$

|          | Características                                                                                   |                                                                                                   |     |                                                                                                                |
|----------|---------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|-----|----------------------------------------------------------------------------------------------------------------|
| Usuarios |  <sub>11</sub> |  <sub>12</sub> | ... |  <sub>1<math>k</math></sub> |
|          |  <sub>21</sub> |  <sub>22</sub> | ... |  <sub>2<math>k</math></sub> |
|          | ...                                                                                               | ...                                                                                               | ... | ...                                                                                                            |
|          |  <sub>71</sub> |  <sub>72</sub> | ... |  <sub>7<math>k</math></sub> |

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$

|                 | Películas                                                                                                     |                                                                                                                |     |                                                                                                                 |
|-----------------|---------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|-----|-----------------------------------------------------------------------------------------------------------------|
| Características |  <sub>11</sub>               |  <sub>12</sub>               | ... |  <sub>19</sub>               |
|                 |  <sub>21</sub>               |  <sub>22</sub>               | ... |  <sub>29</sub>               |
|                 | ...                                                                                                           | ...                                                                                                            | ... | ...                                                                                                             |
|                 |  <sub><math>k_1</math></sub> |  <sub><math>k_2</math></sub> | ... |  <sub><math>k_9</math></sub> |

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

# Ratings como Gustos $\times$ Características

|          | Películas |   |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|---|
| Usuarios | 5         | 1 | 4 | 4 | 2 | 2 | 5 | 1 | 5 |
|          | 3         | 2 | 3 | 1 | 1 | 2 | 2 | 4 | 4 |
|          | 1         | 3 | 3 | 5 | 1 | 5 | 2 | 2 | 1 |
|          | 4         | 2 | 3 | 4 | 3 | 5 | 1 | 1 | 4 |
|          | 5         | 3 | 2 | 2 | 4 | 1 | 4 | 5 | 2 |
|          | 1         | 3 | 5 | 4 | 2 | 1 | 2 | 1 | 4 |
|          | 3         | 1 | 4 | 2 | 4 | 5 | 2 | 1 | 2 |

Matriz de puntuaciones, 1-5 estrellas

$$\mathbf{A} \in \mathbb{R}^{7 \times 9}, \mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^t$$

|          | Características                                                                                   |                                                                                                   |     |                                                                                                                |
|----------|---------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|-----|----------------------------------------------------------------------------------------------------------------|
| Usuarios |  <sub>11</sub> |  <sub>12</sub> | ... |  <sub>1<math>k</math></sub> |
|          |  <sub>21</sub> |  <sub>22</sub> | ... |  <sub>2<math>k</math></sub> |
|          | ...                                                                                               | ...                                                                                               | ... | ...                                                                                                            |
|          |  <sub>71</sub> |  <sub>72</sub> | ... |  <sub>7<math>k</math></sub> |

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$

|                 | Películas                                                                                                     |                                                                                                                |     |                                                                                                                 |
|-----------------|---------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|-----|-----------------------------------------------------------------------------------------------------------------|
| Características |  <sub>11</sub>               |  <sub>12</sub>               | ... |  <sub>19</sub>               |
|                 |  <sub>21</sub>               |  <sub>22</sub>               | ... |  <sub>29</sub>               |
|                 | ...                                                                                                           | ...                                                                                                            | ... | ...                                                                                                             |
|                 |  <sub><math>k_1</math></sub> |  <sub><math>k_2</math></sub> | ... |  <sub><math>k_9</math></sub> |

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

$$\begin{pmatrix} \alpha_1 & 0 & 0 \\ 0 & \alpha_2 & 0 & \vdots \\ 0 & 0 & \alpha_3 \\ & \dots & \end{pmatrix}$$

Matriz de valores singulares,  $\mathbf{\Sigma} \in \mathbb{R}^{k \times k}$

# Ratings como Gustos $\times$ Características

| Usuarios | Películas |   |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|---|
|          | 5         | 1 | 4 | 4 | 2 | 2 | 5 | 1 | 5 |
|          | 3         | 2 | 3 | 1 | 1 | 2 | 2 | 4 | 4 |
|          | 1         | 3 | 3 | 5 | 1 | 5 | 2 | 2 | 1 |
|          | 4         | 2 | 3 | 4 | 3 | 5 | 1 | 1 | 4 |
|          | 5         | 3 | 2 | 2 | 4 | 1 | 4 | 5 | 2 |
|          | 1         | 3 | 5 | 4 | 2 | 1 | 2 | 1 | 4 |
|          | 3         | 1 | 4 | 2 | 4 | 5 | 2 | 1 | 2 |

Matriz de puntuaciones, 1-5 estrellas

$$\mathbf{A} \in \mathbb{R}^{7 \times 9}, \mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^t$$

| Usuarios | Características                                                                             |                                                                                             |     |                                                                                             |
|----------|---------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|-----|---------------------------------------------------------------------------------------------|
|          |  $_{11}$ |  $_{12}$ | ... |  $_{1k}$ |
|          |  $_{21}$ |  $_{22}$ | ... |  $_{2k}$ |
|          |  $_{71}$ |  $_{72}$ | ... |  $_{7k}$ |

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$

| Características | Películas                                                                                 |                                                                                            |     |                                                                                             |
|-----------------|-------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|-----|---------------------------------------------------------------------------------------------|
|                 |  $_{11}$ |  $_{12}$ | ... |  $_{19}$ |
|                 |  $_{21}$ |  $_{22}$ | ... |  $_{29}$ |
|                 |  $_{k1}$ |  $_{k2}$ | ... |  $_{k9}$ |

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

$$\begin{pmatrix} \alpha_1 & 0 & 0 \\ 0 & \alpha_2 & 0 & \vdots \\ 0 & 0 & \alpha_3 \\ & \dots & \end{pmatrix}$$

Matriz de valores singulares,  $\mathbf{\Sigma} \in \mathbb{R}^{k \times k}$

# Ratings como Gustos $\times$ Características

| Usuarios | Películas |   |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|---|
|          | 5         | 1 | 4 | 4 | 2 | 2 | 5 | 1 | 5 |
|          | 3         | 2 | 3 | 1 | 1 | 2 | 2 | 4 | 4 |
|          | 1         | 3 | 3 | 5 | 1 | 5 | 2 | 2 | 1 |
|          | 4         | 2 | 3 | 4 | 3 | 5 | 1 | 1 | 4 |
|          | 5         | 3 | 2 | 2 | 4 | 1 | 4 | 5 | 2 |
|          | 1         | 3 | 5 | 4 | 2 | 1 | 2 | 1 | 4 |
|          | 3         | 1 | 4 | 2 | 4 | 5 | 2 | 1 | 2 |

Matriz de puntuaciones, 1-5 estrellas

$$\mathbf{A} \in \mathbb{R}^{7 \times 9}, \mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^t$$

| Usuarios | Características                                                                             |                                                                                             |     |                                                                                             |
|----------|---------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|-----|---------------------------------------------------------------------------------------------|
|          |  $_{11}$ |  $_{12}$ | ... |  $_{1k}$ |
|          |  $_{21}$ |  $_{22}$ | ... |  $_{2k}$ |
|          | ...                                                                                         | ...                                                                                         | ... | ...                                                                                         |
|          |  $_{71}$ |  $_{72}$ | ... |  $_{7k}$ |

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$

| Características | Películas                                                                                 |                                                                                            |     |                                                                                             |
|-----------------|-------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|-----|---------------------------------------------------------------------------------------------|
|                 |  $_{11}$ |  $_{12}$ | ... |  $_{19}$ |
|                 |  $_{21}$ |  $_{22}$ | ... |  $_{29}$ |
|                 | ...                                                                                       | ...                                                                                        | ... | ...                                                                                         |
|                 |  $_{k1}$ |  $_{k2}$ | ... |  $_{k9}$ |

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

$$\begin{pmatrix} \alpha_1 & 0 & 0 \\ 0 & \alpha_2 & 0 & \vdots \\ 0 & 0 & \alpha_3 \\ & \dots & \end{pmatrix}$$

Matriz de valores singulares,  $\Sigma \in \mathbb{R}^{k \times k}$

# Factorización de matriz bayesiana

| Usuarios | Películas |   |   |   |   |   |   |   |
|----------|-----------|---|---|---|---|---|---|---|
|          | 5         | 1 |   | 4 |   | 2 | 5 | 1 |
|          |           | 2 | 3 | 1 |   |   | 2 |   |
|          |           |   | 3 | 5 | 1 |   |   | 2 |
|          | 4         |   | 3 |   |   | 5 |   | 1 |
|          | 5         | 3 | 2 | 2 |   | 1 | 4 | 5 |
|          | 1         |   |   | 4 |   |   | 2 | 1 |
| 3        | 1         | 4 | 2 |   | 5 |   |   |   |

Matriz de puntuaciones,  $\mathbf{A} \in \mathbb{R}^{7 \times 9}$

# Factorización de matriz bayesiana

|          |   | Películas |   |   |   |   |   |   |   |   | Usuarios |
|----------|---|-----------|---|---|---|---|---|---|---|---|----------|
|          |   | 1         |   |   | 2 |   |   | 3 |   |   |          |
| Usuarios | 1 | 5         | 1 |   | 4 |   | 2 | 5 | 1 |   |          |
|          | 2 |           | 2 | 3 | 1 |   |   | 2 |   | 4 |          |
|          | 3 |           |   | 3 | 5 | 1 |   |   | 2 | 1 |          |
|          | 4 |           |   | 3 |   |   | 5 |   | 1 | 4 |          |
|          | 5 | 3         | 2 | 2 |   | 1 | 4 | 5 | 5 | 2 |          |
|          | 1 |           |   |   | 4 |   | 2 | 1 |   | 4 |          |
|          | 3 | 1         | 4 | 2 |   | 5 |   |   |   | 2 |          |

Matriz de puntuaciones,  $\mathbf{A} \in \mathbb{R}^{7 \times 9}$

|  |   | Características          |                          |                          |                          | Usuarios |
|--|---|--------------------------|--------------------------|--------------------------|--------------------------|----------|
|  |   | 1                        | 2                        | 3                        | 4                        |          |
|  | 1 | $\mathcal{N}(-0.6, 0.7)$ | $\mathcal{N}(0.5, 0.3)$  | $\mathcal{N}(0.4, 0.5)$  | $\mathcal{N}(0.1, 0.2)$  |          |
|  | 2 | $\mathcal{N}(-0.3, 0.4)$ | $\mathcal{N}(-0.6, 0.8)$ | $\mathcal{N}(0.7, 0.2)$  | $\mathcal{N}(-0.3, 0.6)$ |          |
|  | 3 | $\mathcal{N}(-0.2, 0.5)$ | $\mathcal{N}(-0.6, 0.7)$ | $\mathcal{N}(-0.4, 0.3)$ | $\mathcal{N}(0.8, 0.1)$  |          |
|  | 4 |                          |                          |                          |                          |          |
|  | 5 |                          |                          |                          |                          |          |

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$   
con  $k = 4$  características

# Factorización de matriz bayesiana

|          |   | Películas |   |   |   |   |   |   |   |    |
|----------|---|-----------|---|---|---|---|---|---|---|----|
| Usuarios | 1 | 2         | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|          | 5 | 1         |   | 4 |   | 2 | 5 | 1 |   |    |
|          |   | 2         | 3 | 1 |   |   | 2 |   | 4 |    |
|          |   |           | 3 | 5 | 1 |   |   | 2 | 1 |    |
|          | 4 |           | 3 |   |   | 5 |   | 1 | 4 |    |
|          | 5 | 3         | 2 | 2 |   | 1 | 4 | 5 | 2 |    |
|          | 1 |           |   | 4 |   |   | 2 | 1 | 4 |    |
|          | 3 | 1         | 4 | 2 |   | 5 |   |   |   | 2  |

Matriz de puntuaciones,  $\mathbf{A} \in \mathbb{R}^{7 \times 9}$

|          |     | Características          |                          |                          |                          |
|----------|-----|--------------------------|--------------------------|--------------------------|--------------------------|
| Usuarios | 1   | $\mathcal{N}(-0.6, 0.7)$ | $\mathcal{N}(0.5, 0.3)$  | $\mathcal{N}(0.4, 0.5)$  | $\mathcal{N}(0.1, 0.2)$  |
|          | 2   | $\mathcal{N}(-0.3, 0.4)$ | $\mathcal{N}(-0.6, 0.8)$ | $\mathcal{N}(0.7, 0.2)$  | $\mathcal{N}(-0.3, 0.6)$ |
|          | 3   | $\mathcal{N}(-0.2, 0.5)$ | $\mathcal{N}(-0.6, 0.7)$ | $\mathcal{N}(-0.4, 0.3)$ | $\mathcal{N}(0.8, 0.1)$  |
|          | ... | ...                      | ...                      | ...                      | ...                      |

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$   
con  $k = 4$  características

|                 |     | Películas                |                          |                          |          |
|-----------------|-----|--------------------------|--------------------------|--------------------------|----------|
| Características | 1   | $\mathcal{N}(-0.8, 0.6)$ | $\mathcal{N}(-0.2, 0.3)$ | $\mathcal{N}(-0.5, 0.7)$ |          |
|                 | 2   | $\mathcal{N}(0.5, 0.4)$  | $\mathcal{N}(-0.2, 0.8)$ | $\mathcal{N}(-0.8, 0.5)$ | $\vdots$ |
|                 | 3   | $\mathcal{N}(-0.1, 0.9)$ | $\mathcal{N}(1.0, 0.2)$  | $\mathcal{N}(-0.2, 0.7)$ |          |
|                 | 4   | $\mathcal{N}(0.1, 0.9)$  | $\mathcal{N}(-0.4, 0.2)$ | $\mathcal{N}(0.6, 0.7)$  |          |
|                 | ... | ...                      | ...                      | ...                      | ...      |

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

# Factorización de matriz bayesiana

$$\begin{array}{c}
 \text{Usuarios} \begin{pmatrix} 5 & 1 & & 4 & & 2 & 5 & 1 \\ & 2 & 3 & 1 & & & 2 & & 4 \\ & & 3 & 5 & 1 & & & 2 & 1 \\ 4 & & 3 & & & 5 & & 1 & 4 \\ 5 & 3 & 2 & 2 & & 1 & 4 & 5 & 2 \\ 1 & & & 4 & & & 2 & 1 & 4 \\ 3 & 1 & 4 & 2 & & 5 & & & 2 \end{pmatrix} \begin{array}{c} \text{Películas} \\ \text{Usuarios} \end{array}
 \end{array}$$

Matriz de puntuaciones,  $\mathbf{A} \in \mathbb{R}^{7 \times 9}$

$$\begin{array}{c}
 \begin{array}{c} \text{Características} \\ \text{Usuarios} \end{array} \begin{pmatrix} \mathcal{N}(-0.6, 0.7) & \mathcal{N}(0.5, 0.3) & \mathcal{N}(0.4, 0.5) & \mathcal{N}(0.1, 0.2) \\ \mathcal{N}(-0.3, 0.4) & \mathcal{N}(-0.6, 0.8) & \mathcal{N}(0.7, 0.2) & \mathcal{N}(-0.3, 0.6) \\ \mathcal{N}(-0.2, 0.5) & \mathcal{N}(-0.6, 0.7) & \mathcal{N}(-0.4, 0.3) & \mathcal{N}(0.8, 0.1) \\ \dots & & & \end{pmatrix}
 \end{array}$$

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$   
con  $k = 4$  características

$$\begin{array}{c}
 \begin{array}{c} \text{Características} \\ \text{Películas} \end{array} \begin{pmatrix} \mathcal{N}(-0.8, 0.6) & \mathcal{N}(-0.2, 0.3) & \mathcal{N}(-0.5, 0.7) & \\ \mathcal{N}(0.5, 0.4) & \mathcal{N}(-0.2, 0.8) & \mathcal{N}(-0.8, 0.5) & \vdots \\ \mathcal{N}(-0.1, 0.9) & \mathcal{N}(1.0, 0.2) & \mathcal{N}(-0.2, 0.7) & \\ \mathcal{N}(0.1, 0.9) & \mathcal{N}(-0.4, 0.2) & \mathcal{N}(0.6, 0.7) & \end{pmatrix}
 \end{array}$$

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

$$\begin{pmatrix} \mathcal{N}(0.3, 0.9) & \mathcal{N}(-0.4, 0.5) & \mathcal{N}(-0.1, 0.5) & \mathcal{N}(0.1, 0.2) \end{pmatrix}$$

Afinidad,  $z \in \mathbb{R}^k = (\mathbf{U}\mathbf{e}_i)^t \mathbf{V}\mathbf{e}_j$

# Factorización de matriz bayesiana

$$\begin{array}{c} \text{Usuarios} \end{array} \begin{pmatrix} 5 & 1 & & 4 & & 2 & 5 & 1 \\ & 2 & 3 & 1 & & & 2 & & 4 \\ & & 3 & 5 & 1 & & & 2 & 1 \\ 4 & & 3 & & & 5 & & 1 & 4 \\ 5 & 3 & 2 & 2 & & 1 & 4 & 5 & 2 \\ 1 & & & 4 & & & 2 & 1 & 4 \\ 3 & 1 & 4 & 2 & & 5 & & & 2 \end{pmatrix} \begin{array}{c} \text{Películas} \end{array}$$

$$\begin{array}{c} \text{Usuarios} \end{array} \begin{pmatrix} \mathcal{N}(-0.6, 0.7) & \mathcal{N}(0.5, 0.3) & \mathcal{N}(0.4, 0.5) & \mathcal{N}(0.1, 0.2) \\ \mathcal{N}(-0.3, 0.4) & \mathcal{N}(-0.6, 0.8) & \mathcal{N}(0.7, 0.2) & \mathcal{N}(-0.3, 0.6) \\ \mathcal{N}(-0.2, 0.5) & \mathcal{N}(-0.6, 0.7) & \mathcal{N}(-0.4, 0.3) & \mathcal{N}(0.8, 0.1) \\ \dots & & & \end{pmatrix}$$

Matriz de puntuaciones,  $\mathbf{A} \in \mathbb{R}^{7 \times 9}$

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$   
con  $k = 4$  características

$$\begin{array}{c} \text{Características} \end{array} \begin{pmatrix} \mathcal{N}(-0.8, 0.6) & \mathcal{N}(-0.2, 0.3) & \mathcal{N}(-0.5, 0.7) \\ \mathcal{N}(0.5, 0.4) & \mathcal{N}(-0.2, 0.8) & \mathcal{N}(-0.8, 0.5) \\ \mathcal{N}(-0.1, 0.9) & \mathcal{N}(1.0, 0.2) & \mathcal{N}(-0.2, 0.7) \\ \mathcal{N}(0.1, 0.9) & \mathcal{N}(-0.4, 0.2) & \mathcal{N}(0.6, 0.7) \\ \vdots & & \end{pmatrix}$$

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

$$(\mathcal{N}(0.3, 0.9) \quad \mathcal{N}(-0.4, 0.5) \quad \mathcal{N}(-0.1, 0.5) \quad \mathcal{N}(0.1, 0.2))$$

$$\text{Afinidad, } z \in \mathbb{R}^k = (\mathbf{U}\mathbf{e}_i)^t \mathbf{V}\mathbf{e}_j$$

# Factorización de matriz bayesiana

$$\begin{array}{c} \text{Usuarios} \end{array} \begin{pmatrix} 5 & 1 & & 4 & & 2 & 5 & 1 \\ & 2 & 3 & 1 & & & 2 & & 4 \\ & & 3 & 5 & 1 & & & 2 & 1 \\ 4 & & 3 & & & 5 & & 1 & 4 \\ 5 & 3 & 2 & 2 & & 1 & 4 & 5 & 2 \\ 1 & & & 4 & & & 2 & 1 & 4 \\ 3 & 1 & 4 & 2 & & 5 & & & 2 \end{pmatrix} \begin{array}{c} \text{Películas} \end{array}$$

$$\begin{array}{c} \text{Usuarios} \end{array} \begin{pmatrix} \mathcal{N}(-0.6, 0.7) & \mathcal{N}(0.5, 0.3) & \mathcal{N}(0.4, 0.5) & \mathcal{N}(0.1, 0.2) \\ \mathcal{N}(-0.3, 0.4) & \mathcal{N}(-0.6, 0.8) & \mathcal{N}(0.7, 0.2) & \mathcal{N}(-0.3, 0.6) \\ \mathcal{N}(-0.2, 0.5) & \mathcal{N}(-0.6, 0.7) & \mathcal{N}(-0.4, 0.3) & \mathcal{N}(0.8, 0.1) \\ \dots & & & \end{pmatrix}$$

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$   
con  $k = 4$  características

Matriz de puntuaciones,  $\mathbf{A} \in \mathbb{R}^{7 \times 9}$

$$\begin{array}{c} \text{Características} \end{array} \begin{pmatrix} \mathcal{N}(-0.8, 0.6) & \mathcal{N}(-0.2, 0.3) & \mathcal{N}(-0.5, 0.7) & \\ \mathcal{N}(0.5, 0.4) & \mathcal{N}(-0.2, 0.8) & \mathcal{N}(-0.8, 0.5) & \vdots \\ \mathcal{N}(-0.1, 0.9) & \mathcal{N}(1.0, 0.2) & \mathcal{N}(-0.2, 0.7) & \\ \mathcal{N}(0.1, 0.9) & \mathcal{N}(-0.4, 0.2) & \mathcal{N}(0.6, 0.7) & \end{pmatrix}$$

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$

$$(\mathcal{N}(0.3, 0.9) \quad \mathcal{N}(-0.4, 0.5) \quad \mathcal{N}(-0.1, 0.5) \quad \mathcal{N}(0.1, 0.2))$$

$$\text{Afinidad, } z \in \mathbb{R}^k = (\mathbf{U}\mathbf{e}_i)^t \mathbf{V}\mathbf{e}_j$$

# Factorización de matriz bayesiana

$$\begin{array}{c}
 \text{Usuarios} \begin{pmatrix} 5 & 1 & \mathcal{N}(-0.6, 3.31) & 4 & 2 & 5 & 1 \\ & 2 & 3 & 1 & & 2 & \\ & & 3 & 5 & 1 & & 2 & 1 \\ 4 & & 3 & & & 5 & 1 & 4 \\ 5 & 3 & 2 & 2 & & 1 & 4 & 5 & 2 \\ 1 & & & 4 & & & 2 & 1 & 4 \\ 3 & 1 & 4 & 2 & & 5 & & & 2 \end{pmatrix} \begin{array}{c} \text{Películas} \\ \text{Usuarios} \end{array}
 \end{array}$$

Matriz de puntuaciones,  $\mathbf{A} \in \mathbb{R}^{7 \times 9}$

$$\begin{array}{c}
 \begin{pmatrix} \mathcal{N}(-0.6, 0.7) & \mathcal{N}(0.5, 0.3) & \mathcal{N}(0.4, 0.5) & \mathcal{N}(0.1, 0.2) \\ \mathcal{N}(-0.3, 0.4) & \mathcal{N}(-0.6, 0.8) & \mathcal{N}(0.7, 0.2) & \mathcal{N}(-0.3, 0.6) \\ \mathcal{N}(-0.2, 0.5) & \mathcal{N}(-0.6, 0.7) & \mathcal{N}(-0.4, 0.3) & \mathcal{N}(0.8, 0.1) \\ \dots & & & \end{pmatrix}
 \end{array}$$

Matriz de usuarios,  $\mathbf{U} \in \mathbb{R}^{7 \times k}$   
con  $k = 4$  características


$$\begin{array}{c}
 \begin{pmatrix} \mathcal{N}(-0.8, 0.6) & \mathcal{N}(-0.2, 0.3) & \mathcal{N}(-0.5, 0.7) & \\ \mathcal{N}(0.5, 0.4) & \mathcal{N}(-0.2, 0.8) & \mathcal{N}(-0.8, 0.5) & \vdots \\ \mathcal{N}(-0.1, 0.9) & \mathcal{N}(1.0, 0.2) & \mathcal{N}(-0.2, 0.7) & \\ \mathcal{N}(0.1, 0.9) & \mathcal{N}(-0.4, 0.2) & \mathcal{N}(0.6, 0.7) & \end{pmatrix}
 \end{array}$$

Matriz de películas,  $\mathbf{V} \in \mathbb{R}^{k \times 9}$


$$\begin{pmatrix} \mathcal{N}(0.3, 0.9) & \mathcal{N}(-0.4, 0.5) & \mathcal{N}(-0.1, 0.5) & \mathcal{N}(0.1, 0.2) \end{pmatrix}$$

Afinidad,  $z \in \mathbb{R}^k = (\mathbf{U}\mathbf{e}_i)^t \mathbf{V}\mathbf{e}_j$


# Modelo gráficos




# Modelo gráficos




# Modelo gráficos




# Modelo gráficos




# Modelo gráficos




# Modelo gráficos




# Modelo gráficos




# Modelo gráficos



# Modelo gráficos



# Modelo gráficos



# Mensaje 2

## Afinidad por característica

$$m_{f_* \rightarrow z_k}(z_k) = \iint_{s_k t_k} \underbrace{\mathbb{I}(z_k = s_k t_k)}_{\text{factor } *} \underbrace{\mathcal{N}(s_k | \mu_{U_{ki}}, \sigma_{U_{ki}}^2)}_{\text{Prior usuario}} \underbrace{\mathcal{N}(t_k | \mu_{V_{kj}}, \sigma_{V_{kj}}^2)}_{\text{Prior película}} ds_k dt_k$$

# Mensaje 2

## Afinidad por característica

$$\begin{aligned} m_{f_* \rightarrow z_k}(z_k) &= \iint_{s_k t_k} \mathbb{I}(z_k = s_k t_k) \mathcal{N}(s_k | \mu_{U_{ki}}, \sigma_{U_{ki}}^2) \mathcal{N}(t_k | \mu_{V_{kj}}, \sigma_{V_{kj}}^2) ds_k dt_k \\ &= \iint_{s_k t_k} \mathbb{I}\left(\frac{z_k}{t_k} = s_k\right) \mathcal{N}(s_k | \mu_{U_{ki}}, \sigma_{U_{ki}}^2) \mathcal{N}(t_k | \mu_{V_{kj}}, \sigma_{V_{kj}}^2) ds_k dt_k \end{aligned}$$

# Mensaje 2

## Afinidad por característica

$$\begin{aligned} m_{f_* \rightarrow z_k}(z_k) &= \iint_{s_k t_k} \mathbb{I}(z_k = s_k t_k) \mathcal{N}(s_k | \mu_{U_{ki}}, \sigma_{U_{ki}}^2) \mathcal{N}(t_k | \mu_{V_{kj}}, \sigma_{V_{kj}}^2) ds_k dt_k \\ &= \iint_{s_k t_k} \mathbb{I}\left(\frac{z_k}{t_k} = s_k\right) \mathcal{N}(s_k | \mu_{U_{ki}}, \sigma_{U_{ki}}^2) \mathcal{N}(t_k | \mu_{V_{kj}}, \sigma_{V_{kj}}^2) ds_k dt_k \\ &\stackrel{*}{=} \int_{t_k} \mathcal{N}\left(\frac{z_k}{t_k} | \mu_{U_{ki}}, \sigma_{U_{ki}}^2\right) \mathcal{N}(t_k | \mu_{V_{ki}}, \sigma_{V_{ki}}^2) dt_k \end{aligned}$$

# Mensaje 2

## Afinidad por característica

$$\begin{aligned} m_{f_* \rightarrow z_k}(z_k) &= \iint_{s_k t_k} \mathbb{I}(z_k = s_k t_k) \mathcal{N}(s_k | \mu_{U_{ki}}, \sigma_{U_{ki}}^2) \mathcal{N}(t_k | \mu_{V_{kj}}, \sigma_{V_{kj}}^2) ds_k dt_k \\ &= \iint_{s_k t_k} \mathbb{I}\left(\frac{z_k}{t_k} = s_k\right) \mathcal{N}(s_k | \mu_{U_{ki}}, \sigma_{U_{ki}}^2) \mathcal{N}(t_k | \mu_{V_{kj}}, \sigma_{V_{kj}}^2) ds_k dt_k \\ &\stackrel{*}{=} \int_{t_k} \mathcal{N}\left(\frac{z_k}{t_k} | \mu_{U_{ki}}, \sigma_{U_{ki}}^2\right) \mathcal{N}(t_k | \mu_{V_{ki}}, \sigma_{V_{ki}}^2) dt_k \end{aligned}$$

No tiene solución analítica

# Mensaje 2


Afinidad por característica

$$m_{f_* \rightarrow z_k}(z_k) = \int_{t_k} \mathcal{N}\left(\frac{z_k}{t_k} | \mu_{U_{ki}}, \sigma_{U_{ki}}^2\right) \mathcal{N}(t_k | \mu_{V_{ki}}, \sigma_{V_{ki}}^2) dt_k$$

# Mensaje 2

Afinidad por característica

$$m_{f_* \rightarrow z_k}(z_k) = \int_{t_k} \mathcal{N}\left(\frac{z_k}{t_k} | \mu_{U_{ki}}, \sigma_{U_{ki}}^2\right) \mathcal{N}(t_k | \mu_{V_{ki}}, \sigma_{V_{ki}}^2) dt_k$$




(a) Isolínea  $z_k = s_k t_k$ , con  $z_k = 2$


# Mensaje 2

Afinidad por característica

$$m_{f_* \rightarrow z_k}(z_k) = \int_{t_k} \mathcal{N}\left(\frac{z_k}{t_k} | \mu_{U_{ki}}, \sigma_{U_{ki}}^2\right) \mathcal{N}(t_k | \mu_{V_{ki}}, \sigma_{V_{ki}}^2) dt_k$$



(a) Isolínea  $z_k = s_k t_k$ , con  $z_k = 2$




(b) Densidad sobre la isolínea.

# Mensaje 2

Afinidad por característica


$$m_{f_* \rightarrow z_k}(z_k) = \int \mathcal{N}\left(\frac{z_k}{t_k} | \mu_{U_{ki}}, \sigma_{U_{ki}}^2\right) \mathcal{N}(t_k | \mu_{V_{ki}}, \sigma_{V_{ki}}^2) dt_k$$



# Mensaje 2

Afinidad por característica

$$m_{f_* \rightarrow z_k}(z_k) = \int \mathcal{N}\left(\frac{z_k}{t_k} | \mu_{U_{ki}}, \sigma_{U_{ki}}^2\right) \mathcal{N}(t_k | \mu_{V_{ki}}, \sigma_{V_{ki}}^2) dt_k$$



# Mensaje 7

## Verosimilitud de la afinidad

$$\begin{aligned} m_{f_* \rightarrow s_k}(s_k) &= \iint_{z_k t_k} \mathbb{I}(z_k = s_k t_k) \mathcal{N}(z_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dz_k dt_k \\ &= \int_{t_k} \mathcal{N}(s_k t_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dt_k \end{aligned}$$

# Mensaje 7

## Verosimilitud de la afinidad


$$\begin{aligned} m_{f_* \rightarrow s_k}(s_k) &= \iint_{z_k t_k} \mathbb{I}(z_k = s_k t_k) \mathcal{N}(z_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dz_k dt_k \\ &= \int_{t_k} \mathcal{N}(s_k t_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dt_k \end{aligned}$$

No tiene solución analítica

# Mensaje 7

## Verosimilitud de la afinidad



$$m_{f_* \rightarrow s_k}(s_k) = \int_{t_k} \mathcal{N}(s_k t_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dt_k$$



# Mensaje 7

## Verosimilitud de la afinidad


$$m_{f_* \rightarrow s_k}(s_k) = \int_{t_k} \mathcal{N}(s_k t_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dt_k$$



# Mensaje 7

## Verosimilitud de la afinidad


$$m_{f_* \rightarrow s_k}(s_k) = \int_{t_k} \mathcal{N}(s_k t_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dt_k$$



# Mensaje 7

## Verosimilitud de la afinidad

$$m_{f_* \rightarrow s_k}(s_k) = \int_{t_k} \mathcal{N}(s_k t_k | \mu_{6_k}, \sigma_{6_k}^2) \mathcal{N}(t_k | \mu_{t_k}, \sigma_{t_k}^2) dt_k$$







**PYRO**

# Stochastic Variational Inference (SVI)

Verosimilitud de la afinidad

$p = \mathbf{b}$

Laboratorios de  
Métodos Bayesianos