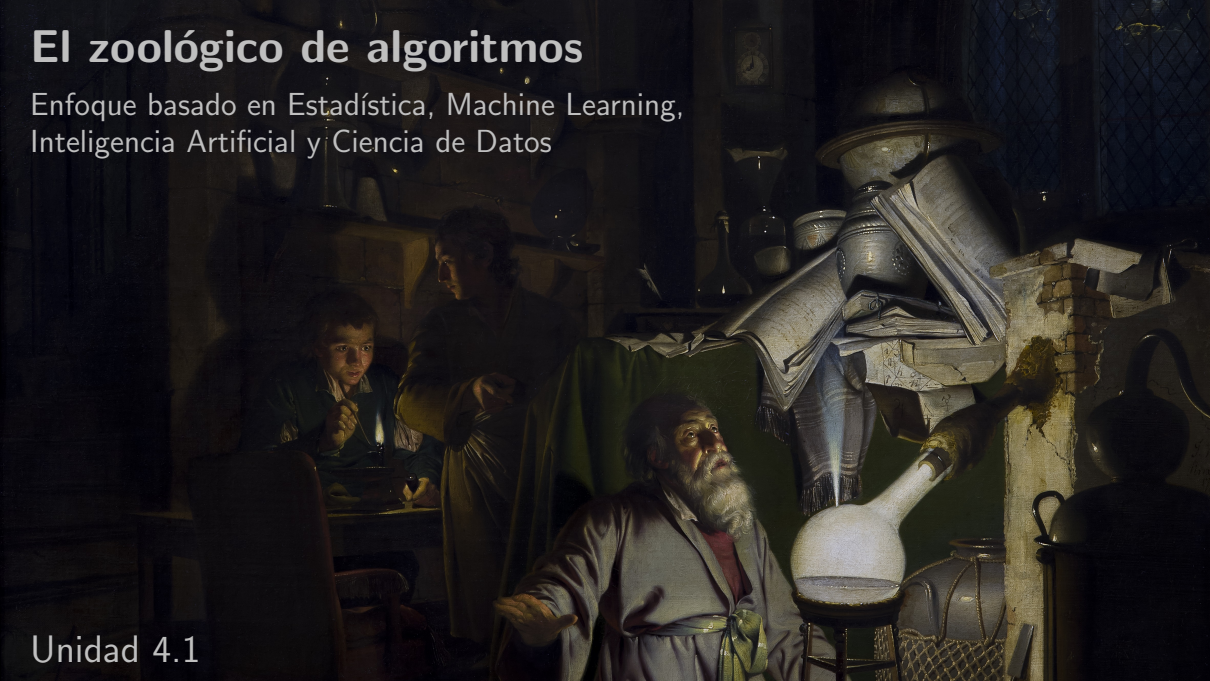
El zoológico de algoritmos

Enfoque basado en Estadística, Machine Learning, Inteligencia Artificial y Ciencia de Datos



Unidad 4.1

Bibliografía Unidad 4.1

- Molak 2023. *Causal Inference and Discovery in Python* (Libro) (Código).
- Facure 2023. *Causal Inference in Python* (Libro) y *Causal Inference for the Brave and True* (Web).
- Neal 2022. *Introduction to causal inference from a Machine Learning Perspective. (DRAFT)* (Libro)

El enfoque previo de Inferencia Causal

Cuando el problema no estaba resulto, se proponía una **analogía con los experimentos aleatorizados**

El enfoque previo de Inferencia Causal

Cuando el problema no estaba resulto, se proponía una **analogía con los experimentos aleatorizados**

El tratamiento se aplica ignorando (independiente de) sus resultados potenciales

El enfoque previo de Inferencia Causal

Resultados Potenciales

Cuando el problema no estaba resulto, se proponía una **analogía con los experimentos aleatorizados**

El tratamiento se aplica ignorando (independiente de) sus resultados potenciales

Resultados potenciales: Y_0 (sin tratamiento) y Y_1 (con tratamiento)

El enfoque previo de Inferencia Causal

Resultados Potenciales

Cuando el problema no estaba resulto, se proponía una **analogía con los experimentos aleatorizados**

El tratamiento se aplica ignorando (independiente de) sus resultados potenciales

Resultados potenciales: Y_0 (sin tratamiento) y Y_1 (con tratamiento)

$$Y_t \perp\!\!\!\perp T \quad \forall t$$ (Ignorabilidad)

El enfoque previo de Inferencia Causal

Resultados Potenciales

Cuando el problema no estaba resulto, se proponía una **analogía con los experimentos aleatorizados**

El tratamiento se aplica ignorando (independiente de) sus resultados potenciales

Resultados potenciales: Y_0 (sin tratamiento) y Y_1 (con tratamiento)

$$Y_t \perp\!\!\!\perp T \quad \forall t$$ (Ignorabilidad)

$$Y_t \perp\!\!\!\perp T \,|\, Q \quad \forall t$$ (Ignorabilidad condicional)

El enfoque previo de Inferencia Causal

Resultados Potenciales

Cuando el problema no estaba resulto, se proponía una **analogía con los experimentos aleatorizados**

El tratamiento se aplica ignorando (independiente de) sus resultados potenciales

Resultados potenciales: Y_0 (sin tratamiento) y Y_1 (con tratamiento)

$$Y_t \perp\!\!\!\perp T \quad \forall t$$ (Ignorabilidad)

$$Y_t \perp\!\!\!\perp T \,|\, Q \quad \forall t$$ (Ignorabilidad condicional)

Pero nadie muestra como verificar el criterio!

$$P(Y_t, T|Q) \stackrel{??}{=} P(Y_t|Q)\, P(T|Q)$$

Adjustment Formula

Versión Resultados Potenciales

$\mathbb{E}[Y_t]$

Adjustment Formula

Versión Resultados Potenciales

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big] \qquad \overset{a}{=} \text{ Definición}$$

Adjustment Formula

Versión Resultados Potenciales

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q, T=t]\big]$$

$\overset{b}{=}$ Ignorabilidad condicional

Adjustment Formula

Versión Resultados Potenciales

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q, T=t]\big]$$

$\overset{b}{=}$ Ignorabilidad condicional

Lo que se observa es exactamente uno de los resultados potenciales.

Adjustment Formula

Versión Resultados Potenciales

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q, T=t]\big]$$

$\overset{b}{=}$ Ignorabilidad condicional

Lo que se observa es exactamente uno de los resultados potenciales.

$$T = t \implies Y = (1-t)\,Y_0 + t\,Y_1 \quad \text{(Consistencia determinística)}$$

Adjustment Formula

Versión Resultados Potenciales

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q, T=t]\big]$$

$\overset{b}{=}$ Ignorabilidad condicional

Lo que se observa es exactamente uno de los resultados potenciales.

$$T = t \implies Y = (1-t)\,Y_0 + t\,Y_1 \quad \text{(Consistencia determinística)}$$

(No hay azar en lo que se observa)

Adjustment Formula

Versión Resultados Potenciales

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q,T=t]\big]$$

$$\overset{c}{=} \mathbb{E}_q\big[\mathbb{E}[Y|Q=q,T=t]\big]$$

$\overset{c}{=}$ Consistencia

Adjustment Formula

Versión Resultados Potenciales

$$
\begin{aligned}
\mathbb{E}[Y_t] &\overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big] \\
&\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q,T=t]\big] \\
&\overset{c}{=} \underbrace{\mathbb{E}_q\big[\mathbb{E}[Y|Q=q,T=t]\big]}_{\text{Libre de contrafactuales}}
\end{aligned}
$$

Adjustment Formula

Versión Resultados Potenciales

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q,T=t]\big]$$

$$\overset{c}{=} \underbrace{\mathbb{E}_q\big[\mathbb{E}[Y|Q=q,T=t]\big]}_{\text{Libre de contrafactuales}}$$

$$\mathbb{E}_q\big[\mathbb{E}[Y|q,t]\big] = \sum_q \underbrace{P(q)}_{\substack{\text{Peso del}\\ \text{control}}} \underbrace{\mathbb{E}[Y|t,q]}_{\substack{\text{Estimación}\\ \text{causal}}}$$

Adjustment Formula

Versión do-calculus

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q,T=t]\big]$$

$$\overset{c}{=} \underbrace{\mathbb{E}_q\big[\mathbb{E}[Y|Q=q,T=t]\big]}_{\text{Libre de contrafactuales}}$$

$$P(y|\mathsf{do}(t)) = \sum_q P(y,q|\mathsf{do}(t))$$

$$= \sum_q P(q|\mathsf{do}(t))P(y|q,\mathsf{do}(t))$$

$$\overset{*}{=} \sum_q P(q)P(y|q,t)$$

$$\mathbb{E}_q\big[\mathbb{E}[Y|q,t]\big] = \sum_q \underbrace{P(q)}_{\substack{\text{Peso del}\\ \text{control}}} \underbrace{\mathbb{E}[Y|t,q]}_{\substack{\text{Estimación}\\ \text{causal}}}$$

Adjustment Formula

Versión do-calculus

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q,T=t]\big]$$

$$\overset{c}{=} \underbrace{\mathbb{E}_q\big[\mathbb{E}[Y|Q=q,T=t]\big]}_{\text{Libre de contrafactuales}}$$

$$P(y|\mathsf{do}(t)) = \sum_q P(y,q|\mathsf{do}(t))$$

$$= \sum_q P(q|\mathsf{do}(t))P(y|q,\mathsf{do}(t))$$

$$\overset{*}{=} \sum_q \underbrace{P(q)P(y|q,t)}_{\text{Libre de intervenciones}}$$

$$\mathbb{E}_q\big[\mathbb{E}[Y|q,t]\big] = \sum_q \underbrace{P(q)}_{\substack{\text{Peso del}\\ \text{control}}} \underbrace{\mathbb{E}[Y|t,q]}_{\substack{\text{Estimación}\\ \text{causal}}}$$

Adjustment Formula

Versión do-calculus

$$\mathbb{E}[Y_t] \overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big]$$

$$\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q,T=t]\big]$$

$$\overset{c}{=} \underbrace{\mathbb{E}_q\big[\mathbb{E}[Y|Q=q,T=t]\big]}_{\text{Libre de contrafactuales}}$$

$$P(y|\mathsf{do}(t)) = \sum_q P(y,q|\mathsf{do}(t))$$

$$= \sum_q P(q|\mathsf{do}(t))P(y|q,\mathsf{do}(t))$$

$$\overset{*}{=} \sum_q \underbrace{P(q)P(y|q,t)}_{\text{Libre de intervenciones}}$$

$$\mathbb{E}_q\big[\mathbb{E}[Y|q,t]\big] = \sum_q \underbrace{P(q)}_{\substack{\text{Peso del}\\ \text{control}}} \underbrace{\mathbb{E}[Y|t,q]}_{\substack{\text{Estimación}\\ \text{causal}}}$$

$$P(y|\mathsf{do}(t)) = \sum_q \underbrace{P(q)}_{\substack{\text{Peso del}\\ \text{control}}} \underbrace{P(y|t,q)}_{\substack{\text{Predicción}\\ \text{causal}}}$$

Adjustment Formula

Versión do-calculus

$$\begin{aligned}\mathbb{E}[Y_t] &\overset{a}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q]\big] \\ &\overset{b}{=} \mathbb{E}_q\big[\mathbb{E}[Y_t|Q=q,T=t]\big] \\ &\overset{c}{=} \underbrace{\mathbb{E}_q\big[\mathbb{E}[Y|Q=q,T=t]\big]}_{\text{Libre de contrafactuales}}\end{aligned}$$

$$\begin{aligned}P(y|\mathsf{do}(t)) &= \sum_q P(y,q|\mathsf{do}(t)) \\ &= \sum_q P(q|\mathsf{do}(t))P(y|q,\mathsf{do}(t)) \\ &\overset{*}{=} \sum_q \underbrace{P(q)P(y|q,t)}_{\text{Libre de intervenciones}}\end{aligned}$$

$$\mathbb{E}_q\big[\mathbb{E}[Y|q,t]\big] = \sum_q \underbrace{P(q)}_{\substack{\text{Peso del}\\ \text{control}}} \underbrace{\mathbb{E}[Y|t,q]}_{\substack{\text{Estimación}\\ \text{causal}}}$$

$$P(y|\mathsf{do}(t)) = \sum_q \underbrace{P(q)}_{\substack{\text{Peso del}\\ \text{control}}} \underbrace{P(y|t,q)}_{\substack{\text{Predicción}\\ \text{causal}}}$$

Dos caminos, **la "misma" adjustment formula**

Las dos caras
de la adjustment formula

$$P(y|\mathsf{do}(t)) = \sum_{q} P(y|t,q)P(q)$$

Las dos caras
de la adjustment formula

$$P(y|\mathsf{do}(t)) = \left(\frac{P(t|q)}{P(t|q)}\right) \sum_{q} P(y|t,q)P(q)$$

Las dos caras
de la adjustment formula

$$P(y|\mathsf{do}(t)) = \sum_{q} \frac{P(y|t,q)P(t|q)P(q)}{P(t|q)}$$

Las dos caras
de la adjustment formula

$$P(y|\mathsf{do}(t)) = \sum_q \frac{P(y|t,q)P(t|q)P(q)}{P(t|q)} = \sum_q \frac{P(y,t,q)}{P(t|q)}$$

Las dos caras
de la adjustment formula

$$P(y|\mathsf{do}(t)) = \sum_q \frac{P(y|t,q)P(t|q)P(q)}{P(t|q)} = \sum_q \frac{P(y,t,q)}{\boldsymbol{P(t|q)}}$$

Propensity Score $\coloneqq P(t|q)$

Las dos caras
de la adjustment formula

$$P(y|\mathsf{do}(t)) = \sum_q \frac{P(y|t,q)P(t|q)P(q)}{P(t|q)} = \sum_q \frac{P(y,t,q)}{\boldsymbol{P(t|q)}}$$

Propensity Score $:= P(t|q)$

$$\mathbb{E}[Y_t] = \sum_q P(q)\,\mathbb{E}[Y|t,q]$$

Regresión: modelo del resultado

$$\mathbb{E}[Y_t] = \mathbb{E}\left[\frac{Y\,\mathbb{I}(T=t)}{P(t|q)}\right]$$

Ponderación: modelo del tratamiento

Las dos caras
de la adjustment formula

$$P(y|\mathsf{do}(t)) = \sum_q \frac{P(y|t,q)P(t|q)P(q)}{P(t|q)} = \sum_q \frac{P(y,t,q)}{\boldsymbol{P(t|q)}}$$

$$\text{Propensity Score} \coloneqq P(t|q)$$

$$\mathbb{E}[Y_t] = \sum_q P(q)\,\mathbb{E}[Y|t,q]$$ Regresión: modelo del resultado

$$\mathbb{E}[Y_t] = \mathbb{E}\left[\frac{Y\,\mathbb{I}(T=t)}{P(t|q)}\right]$$ Ponderación: modelo del tratamiento

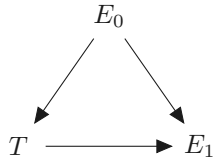
Promedio de los Y de recibieron t, ponderados por el inverso de la probabilidad de haber recibido ese t dado su q

Adjustment formula

Por ponderación

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050



$P(T|E_0)$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600

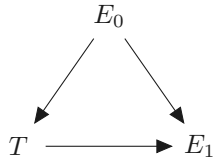
$P(E_1|T, E_0)$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	**0.15**
$T = 1$	0.90	**0.10**

$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	**0.30**
$T = 1$	0.80	**0.20**

Adjustment formula

Por ponderación



$P(T|E_0)$

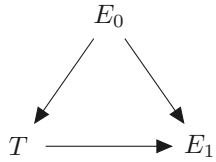
	$T=0$	$T=1$
$E_0=0$	1400/1450	50/1450
$E_0=1$	100/600	500/600

Adjustment formula

Por ponderación

$P(T|E_0)$

	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333

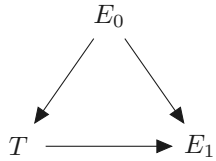


Adjustment formula

Por ponderación

$P(T|E_0)$

	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333

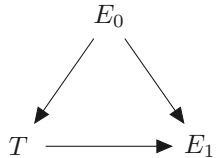


t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

Adjustment formula

Por ponderación

$P(T\|E_0)$	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



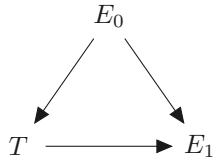
t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	$0.0488/P(t=1)$
1	1	0	$0.1951/P(t=1)$
1	0	1	$0.0024/P(t=1)$
1	0	0	$0.0220/P(t=1)$
			1.0000

Adjustment formula

Por ponderación

$P(T\|E_0)$	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



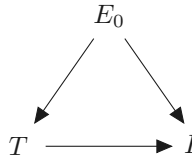
t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	$0.0488/P(t=1)$
1	1	0	$0.1951/P(t=1)$
1	0	1	$0.0024/P(t=1)$
1	0	0	$0.0220/P(t=1)$
			1.0000

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

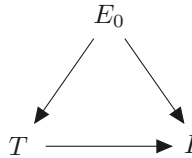
t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	$0.0488/P(t=1)$
1	1	0	$0.1951/P(t=1)$
1	0	1	$0.0024/P(t=1)$
1	0	0	$0.0220/P(t=1)$
			1.0000

t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	$0.0488/P(t\|e_0)$
1	1	0	$0.1951/P(t\|e_0)$
1	0	1	$0.0024/P(t\|e_0)$
1	0	0	$0.0220/P(t\|e_0)$
			1.0000

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	**0.0488**
1	1	0	**0.1951**
1	0	1	**0.0024**
1	0	0	**0.0220**
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	$0.0488/P(t=1)$
1	1	0	$0.1951/P(t=1)$
1	0	1	$0.0024/P(t=1)$
1	0	0	$0.0220/P(t=1)$
			1.0000

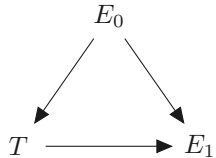
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	$0.0488/P(t\|e_0)$
1	1	0	$0.1951/P(t\|e_0)$
1	0	1	$0.0024/P(t\|e_0)$
1	0	0	$0.0220/P(t\|e_0)$
			1.0000

$P(t=1)=\sum_t P(t,e_0,e_1)=\mathbf{0.2683}$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

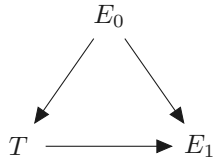
t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	$0.0488/P(t\|e_0)$
1	1	0	$0.1951/P(t\|e_0)$
1	0	1	$0.0024/P(t\|e_0)$
1	0	0	$0.0220/P(t\|e_0)$
			1.0000

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	**0.0345**
$E_0=1$	0.1666	**0.8333**



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

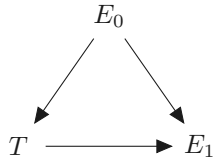
t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	$0.0488/P(t\|e_0)$
1	1	0	$0.1951/P(t\|e_0)$
1	0	1	$0.0024/P(t\|e_0)$
1	0	0	$0.0220/P(t\|e_0)$
			1.0000

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	**0.0345**
$E_0=1$	0.1666	**0.8333**



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

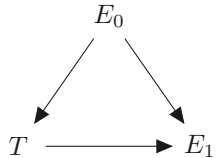
t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	0.0488/0.8333
1	1	0	0.1951/0.8333
1	0	1	0.0024/0.0345
1	0	0	0.0220/0.0345
			1.0000

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

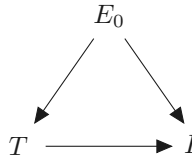
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	0.0585
1	1	0	0.2341
1	0	1	0.0707
1	0	0	0.6366
			1.0000

Adjustment formula

Por ponderación

$P(T|E_0)$

	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

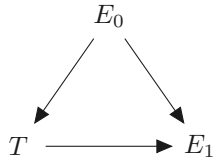
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	0.0585
1	1	0	0.2341
1	0	1	0.0707
1	0	0	0.6366
			1.0000

$P(E_1=1|\mathsf{do}(T=1))$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

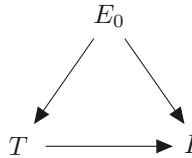
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	0.0585
1	1	0	0.2341
1	0	1	0.0707
1	0	0	0.6366
			1.0000

$$\sum_{e_0} P(E_0=e_0, E_1=1|\mathsf{do}(T=1))$$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=1))$
1	1	1	0.0585
1	1	0	0.2341
1	0	1	0.0707
1	0	0	0.6366
			1.0000

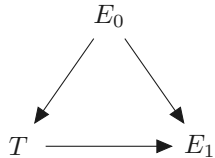
$$\underbrace{0.0585 + 0.0707}_{P(E_1=1|\mathsf{do}(T=1))}$$

Adjustment formula

Por ponderación

$P(T|E_0)$

	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=0)$
0	1	1	$0.0146/P(t=0)$
0	1	0	$0.0341/P(t=0)$
0	0	1	$0.1024/P(t=0)$
0	0	0	$0.5805/P(t=0)$
			1.0000

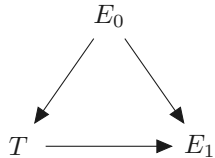
$$\underbrace{0.0585 + 0.0707}_{P(E_1=1|\mathsf{do}(T=1))}$$

Adjustment formula

Por ponderación

$P(T|E_0)$

	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

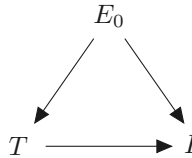
t	e_0	e_1	$P(e_0,e_1\|t=0)$
0	1	1	0.0200
0	1	0	0.0466
0	0	1	0.1400
0	0	0	0.7935
			1.0000

$$\underbrace{0.0585 + 0.0707}_{P(E_1=1|\mathsf{do}(T=1))}$$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=0)$
0	1	1	0.0200
0	1	0	0.0466
0	0	1	0.1400
0	0	0	0.7935
			1.0000

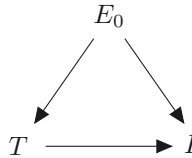
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=0))$
0	1	1	$0.0146/P(t\|e_0)$
0	1	0	$0.0341/P(t\|e_0)$
0	0	1	$0.1024/P(t\|e_0)$
0	0	0	$0.5805/P(t\|e_0)$
			1.0000

$$\underbrace{0.0585+0.0707}_{P(E_1=1|\mathsf{do}(T=1))}$$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=0)$
0	1	1	0.0200
0	1	0	0.0466
0	0	1	0.1400
0	0	0	0.7935
			1.0000

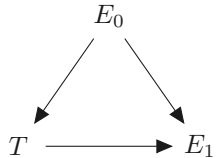
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=0))$
0	1	1	$0.0146/0.1666$
0	1	0	$0.0341/0.1666$
0	0	1	$0.1024/0.9655$
0	0	0	$0.5805/0.9655$
			1.0000

$$\underbrace{0.0585 + 0.0707}_{P(E_1=1|\mathsf{do}(T=1))}$$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=0)$
0	1	1	0.0200
0	1	0	0.0466
0	0	1	0.1400
0	0	0	0.7935
			1.0000

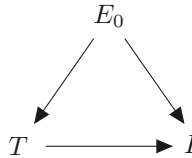
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=0))$
0	1	1	0.0876
0	1	0	0.2047
0	0	1	0.1061
0	0	0	0.6012
			1.0000

$$\underbrace{0.0585 + 0.0707}_{P(E_1=1|\mathsf{do}(T=1))}$$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=0)$
0	1	1	0.0200
0	1	0	0.0466
0	0	1	0.1400
0	0	0	0.7935
			1.0000

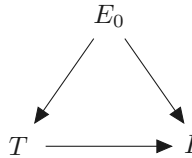
t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=0))$
0	1	1	0.0876
0	1	0	0.2047
0	0	1	0.1061
0	0	0	0.6012
			1.0000

$$\underbrace{0.0585+0.0707}_{P(E_1=1|\mathsf{do}(T=1))}-\underbrace{0.0876+0.1061}_{P(E_1=1|\mathsf{do}(T=0))}$$

Adjustment formula

Por ponderación

	$P(T\|E_0)$	
	$T=0$	$T=1$
$E_0=0$	0.9655	0.0345
$E_0=1$	0.1666	0.8333



t	e_0	e_1	$P(t,e_0,e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0,e_1\|t=0)$
0	1	1	0.0200
0	1	0	0.0466
0	0	1	0.1400
0	0	0	0.7935
			1.0000

t	e_0	e_1	$P(e_0,e_1\|\mathsf{do}(t=0))$
0	1	1	0.0876
0	1	0	0.2047
0	0	1	0.1061
0	0	0	0.6012
			1.0000

$$\underbrace{0.0585+0.0707}_{P(E_1=1|\mathsf{do}(T=1))}-\underbrace{0.0876+0.1061}_{P(E_1=1|\mathsf{do}(T=0))}=-0.0645$$

El zoológico de algoritmos

Sobre una simulación

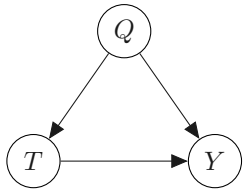
El zoológico de algoritmos

Sobre una simulación

$\overbrace{\mathbb{E}[Y_i\|Q]}$ **Regresión**	$\overbrace{1/P(T\|Q)}$ **Ponderación**	**Las dos**
Matching	IPW	Doubly robust
S-Learner		DML
T-Learner		Causal Forest
TARNet		Dragonnet
BART		BCF

El zoológico

Simulación de Hill (2011)



$P(q) = \frac{1}{2}\mathcal{N}(20, 10^2) + \frac{1}{2}\mathcal{N}(40, 10^2)$

$P(t|q) = \mathsf{Bern}(t \,|\, \sigma(q/5 - 6))$

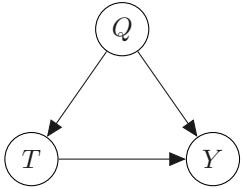
$P(y|q,t) = \mathcal{N}(y \,|\, \mu_t(q),\ 1)$

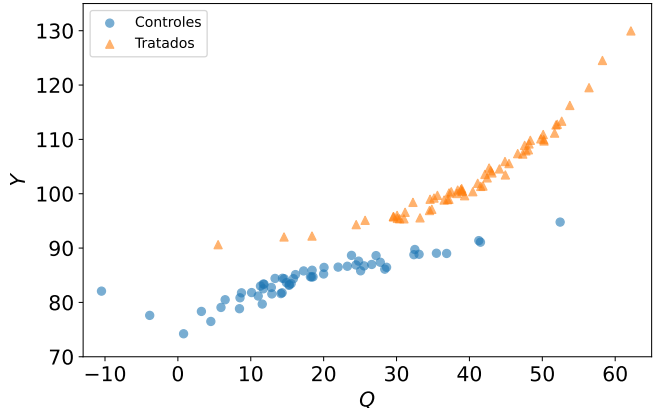
$\mu_0(q) = 72 + 3\sqrt{|q|}$

$\mu_1(q) = 90 + e^{0.06q}$

El zoológico

Simulación de Hill (2011)





$$P(q) = \tfrac{1}{2}\mathcal{N}(20, 10^2) + \tfrac{1}{2}\mathcal{N}(40, 10^2)$$

$$P(t|q) = \mathsf{Bern}(t \,|\, \sigma(q/5 - 6))$$

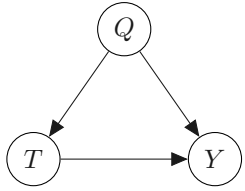
$$P(y|q,t) = \mathcal{N}(y \,|\, \mu_t(q),\ 1)$$

$$\mu_0(q) = 72 + 3\sqrt{|q|}$$

$$\mu_1(q) = 90 + e^{0.06q}$$

El zoológico

Simulación de Hill (2011)



$$\tau(q) = \mu_1(q) - \mu_0(q)$$

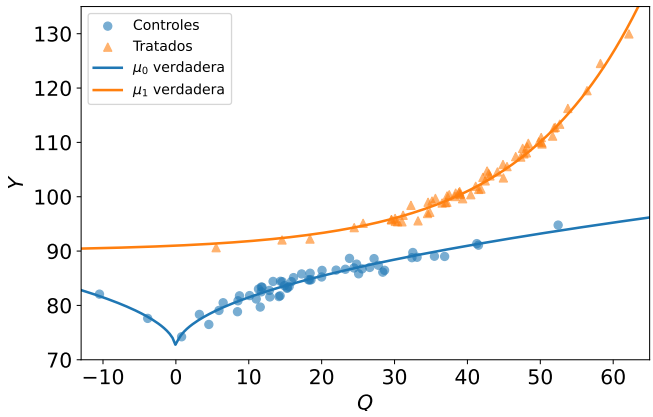
$$P(q) = \tfrac{1}{2}\mathcal{N}(20, 10^2) + \tfrac{1}{2}\mathcal{N}(40, 10^2)$$

$$P(t|q) = \mathsf{Bern}(t \,|\, \sigma(q/5 - 6))$$

$$P(y|q,t) = \mathcal{N}(y \,|\, \mu_t(q),\ 1)$$

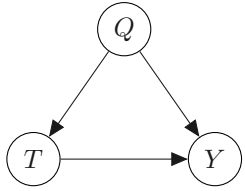
$$\mu_0(q) = 72 + 3\sqrt{|q|}$$

$$\mu_1(q) = 90 + e^{0.06q}$$



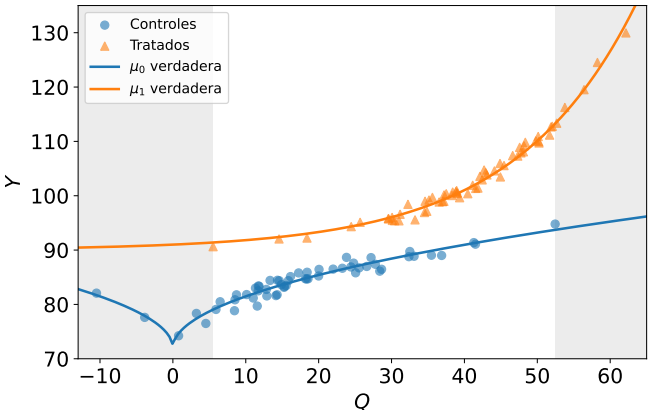
El zoológico

Simulación de Hill (2011)



$$\tau(q) = \mu_1(q) - \mu_0(q)$$

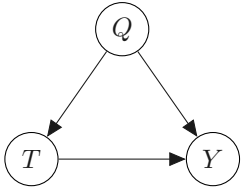
$$P(q) = \tfrac{1}{2}\mathcal{N}(20, 10^2) + \tfrac{1}{2}\mathcal{N}(40, 10^2)$$
$$P(t|q) = \mathsf{Bern}(t \,|\, \sigma(q/5 - 6))$$
$$P(y|q,t) = \mathcal{N}(y \,|\, \mu_t(q),\ 1)$$
$$\mu_0(q) = 72 + 3\sqrt{|q|}$$
$$\mu_1(q) = 90 + e^{0.06q}$$



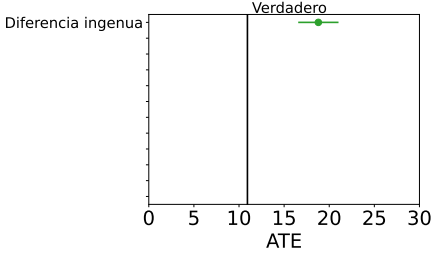
Gris: sin solapamiento, **falta uno de los grupos**

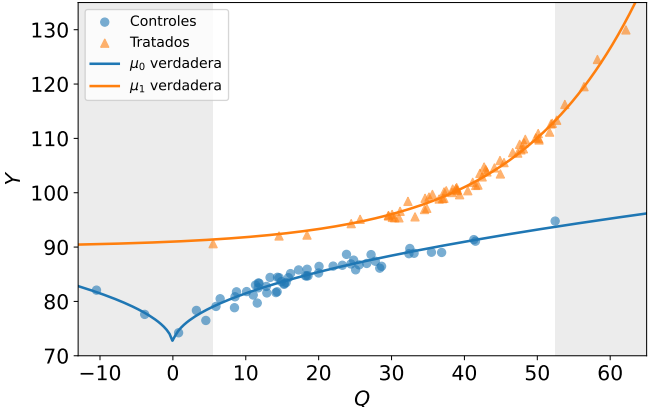
El zoológico

Simulación de Hill (2011)



$$\tau(q) = \mu_1(q) - \mu_0(q)$$





Gris: sin solapamiento, **falta uno de los grupos**

Matching

Cara de regresión

El contrafactual de cada individuo es el resultado de su vecino más cercano $j(i)$ del otro grupo

$\hat{\tau}_i = y_i - y_{j(i)}$ (tratados)

$\hat{\tau}_i = y_{j(i)} - y_i$ (controles)

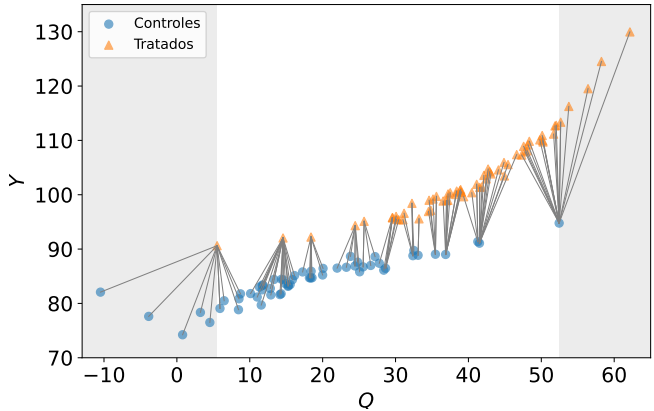
Matching

Cara de regresión

El contrafactual de cada individuo es el resultado de su vecino más cercano $j(i)$ del otro grupo

$\hat{\tau}_i = y_i - y_{j(i)}$ (tratados)

$\hat{\tau}_i = y_{j(i)} - y_i$ (controles)



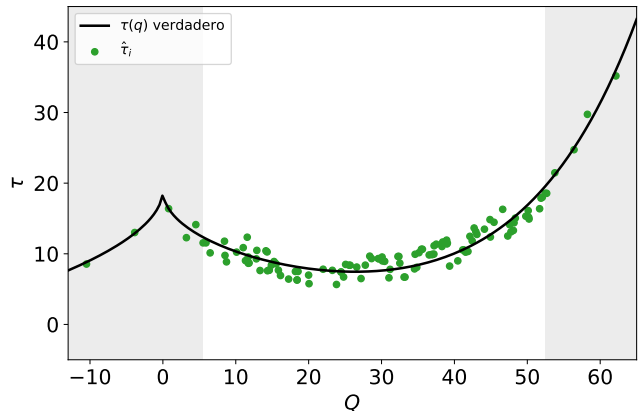
Matching

Cara de regresión

El contrafactual de cada individuo es el resultado de su vecino más cercano $j(i)$ del otro grupo

$\hat{\tau}_i = y_i - y_{j(i)}$ (tratados)

$\hat{\tau}_i = y_{j(i)} - y_i$ (controles)



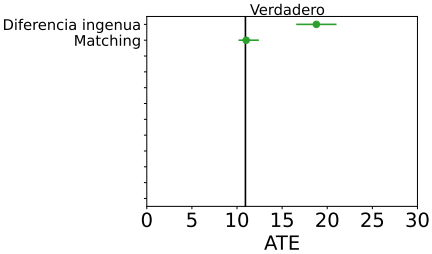
Matching

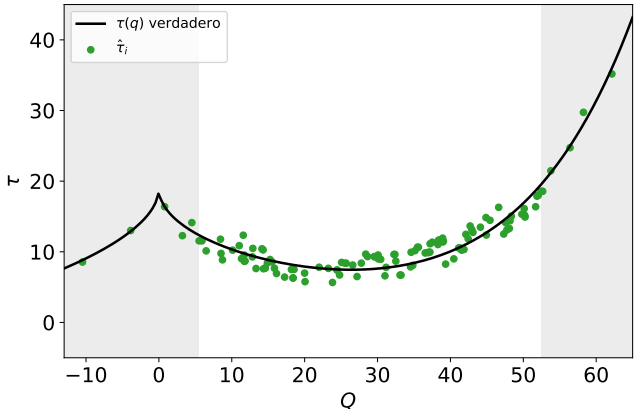
Cara de regresión

El contrafactual de cada individuo es el resultado de su vecino más cercano $j(i)$ del otro grupo

$\hat{\tau}_i = y_i - y_{j(i)}$ (tratados)

$\hat{\tau}_i = y_{j(i)} - y_i$ (controles)





Propensity score

El ingrediente de la ponderación

Probabilidad de recibir el tratamiento, estimada con una regresión logística

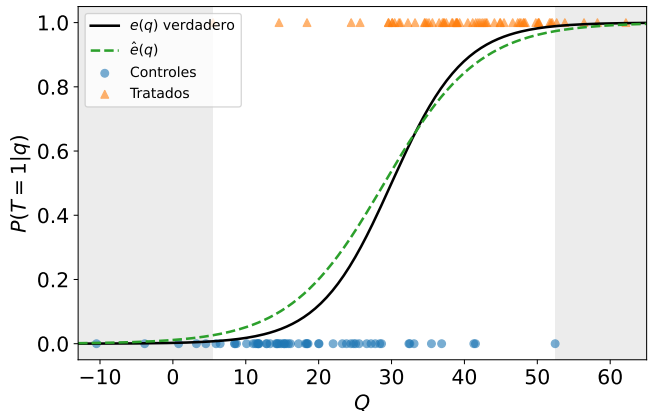
$$e(q) = P(T = 1|q)$$

Propensity score

El ingrediente de la ponderación

Probabilidad de recibir el tratamiento, estimada con una regresión logística

$$e(q) = P(T = 1|q)$$

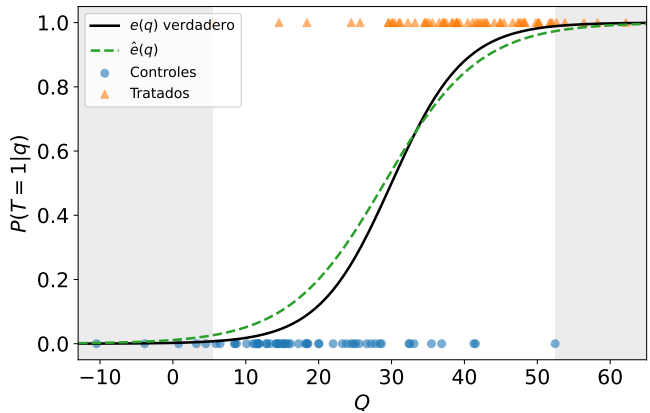


Propensity score

El ingrediente de la ponderación

Probabilidad de recibir el tratamiento, estimada con una regresión logística

$$e(q) = P(T = 1|q)$$



En los bordes, $e(q)$ **casi 0 o casi 1**

Propensity score matching

Cara de regresión

Si alcanza con ajustar por Q,
alcanza con ajustar por $e(Q)$

$$Y_t \perp T \mid Q \implies Y_t \perp T \mid e(Q)$$

El vecino se busca por $\hat{e}$: **un solo número**, con cualquier cantidad de covariables

Rosenbaum y Rubin 1983, *The Central Role of the Propensity Score in Observational Studies for Causal Effects*.

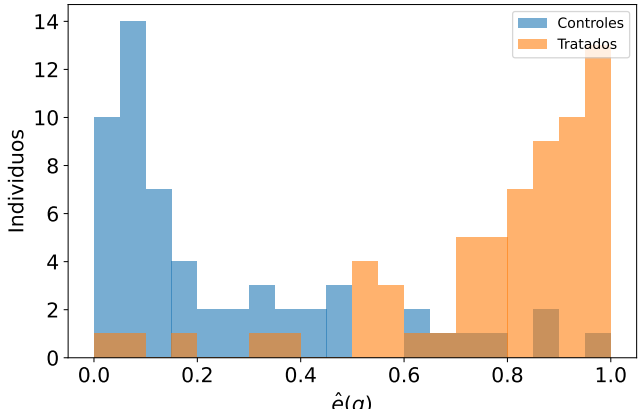
Propensity score matching

Cara de regresión

Si alcanza con ajustar por Q,
alcanza con ajustar por $e(Q)$

$$Y_t \perp T \mid Q \implies Y_t \perp T \mid e(Q)$$

El vecino se busca por $\hat{e}$: **un solo número**, con cualquier cantidad de covariables



Distancia en Propensity Score

Rosenbaum y Rubin 1983, *The Central Role of the Propensity Score in Observational Studies for Causal Effects.*

Propensity score matching

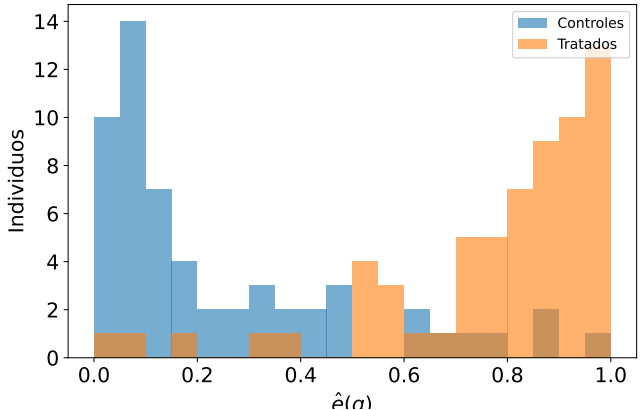
Cara de regresión

Si alcanza con ajustar por Q,
alcanza con ajustar por $e(Q)$

$$Y_t \perp T \mid Q \implies Y_t \perp T \mid e(Q)$$

El vecino se busca por $\hat{e}$: **un solo número**, con cualquier cantidad de covariables

Sirve cuando hay muchas covariables Q.



Distancia en Propensity Score

Rosenbaum y Rubin 1983, *The Central Role of the Propensity Score in Observational Studies for Causal Effects.*

IPW

Cara de ponderación

Cada individuo pesa $1/\hat{e}$ o $1/(1-\hat{e})$

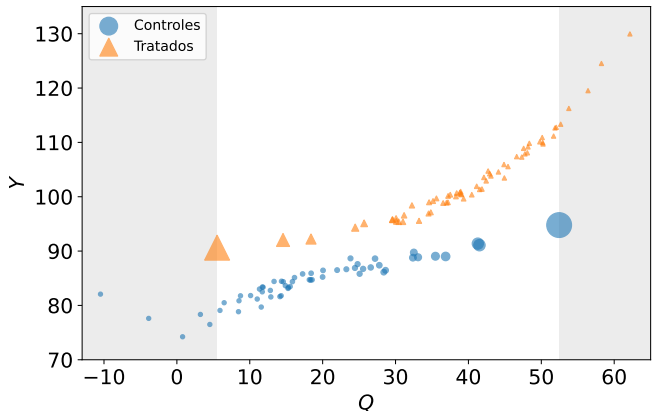
$$\widehat{\mathsf{ATE}} = \frac{1}{n}\sum_i \left[\frac{t_i y_i}{\hat{e}(q_i)} - \frac{(1-t_i)y_i}{1-\hat{e}(q_i)}\right]$$

IPW

Cara de ponderación

Cada individuo pesa $1/\hat{e}$ o $1/(1-\hat{e})$

$$\widehat{\text{ATE}} = \frac{1}{n}\sum_i \left[\frac{t_i y_i}{\hat{e}(q_i)} - \frac{(1-t_i)y_i}{1-\hat{e}(q_i)}\right]$$



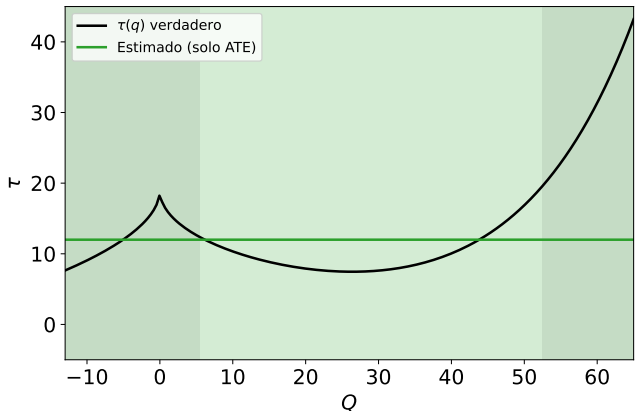
Pesos **enormes** en los bordes

IPW

Cara de ponderación

Cada individuo pesa $1/\hat{e}$ o $1/(1-\hat{e})$

$$\widehat{\text{ATE}} = \frac{1}{n}\sum_i \left[\frac{t_i y_i}{\hat{e}(q_i)} - \frac{(1-t_i)y_i}{1-\hat{e}(q_i)}\right]$$



Pesos **enormes** en los bordes

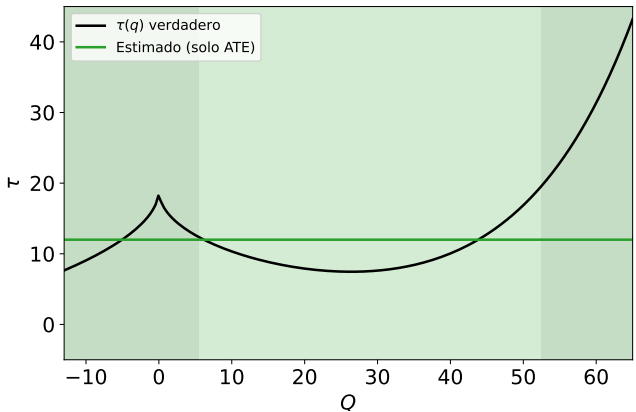
IPW

Cara de ponderación

Cada individuo pesa $1/\hat{e}$ o $1/(1-\hat{e})$

$$\widehat{\text{ATE}} = \frac{1}{n}\sum_i \left[\frac{t_i y_i}{\hat{e}(q_i)} - \frac{(1-t_i)y_i}{1-\hat{e}(q_i)}\right]$$

No calcula efectos heterogéneos



Pesos **enormes** en los bordes

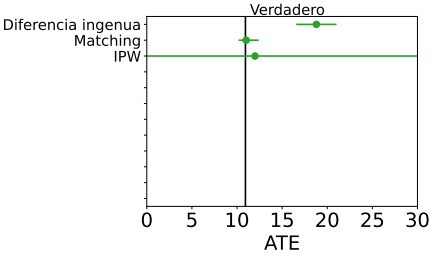
IPW

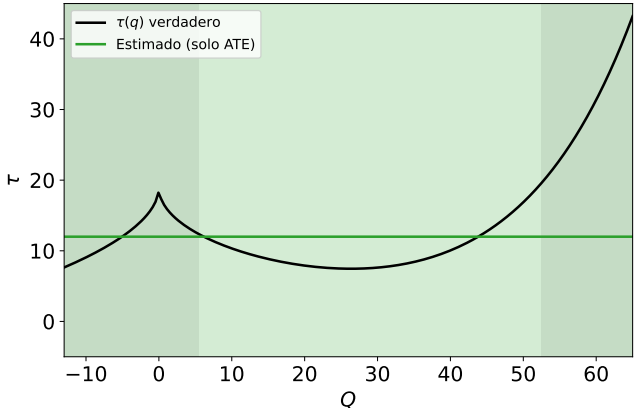
Cara de ponderación

Cada individuo pesa $1/\hat{e}$ o $1/(1-\hat{e})$

$$\widehat{\text{ATE}} = \frac{1}{n}\sum_i \left[\frac{t_i y_i}{\hat{e}(q_i)} - \frac{(1-t_i)y_i}{1-\hat{e}(q_i)}\right]$$

No calcula efectos heterogéneos





Pesos **enormes** en los bordes

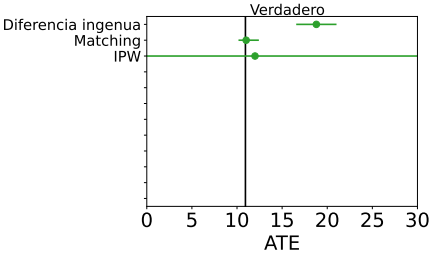
IPW

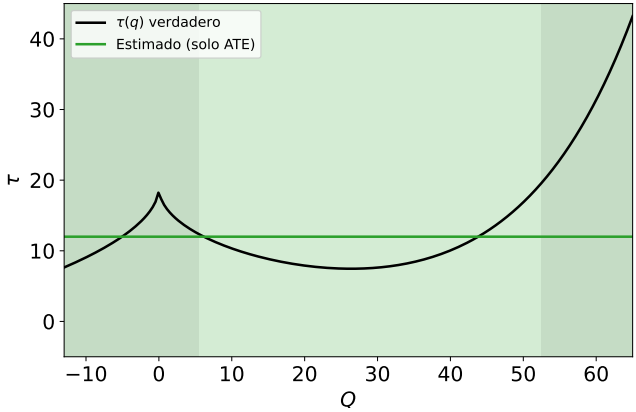
Cara de ponderación

Cada individuo pesa $1/\hat{e}$ o $1/(1-\hat{e})$

$$\widehat{\text{ATE}} = \frac{1}{n}\sum_i \left[\frac{t_i y_i}{\hat{e}(q_i)} - \frac{(1-t_i)y_i}{1-\hat{e}(q_i)}\right]$$

No calcula efectos heterogéneos





Intervalos por bootstrap: muestreo con reposición.

S-Learner

Cara de regresión

Un solo modelo para los dos grupos

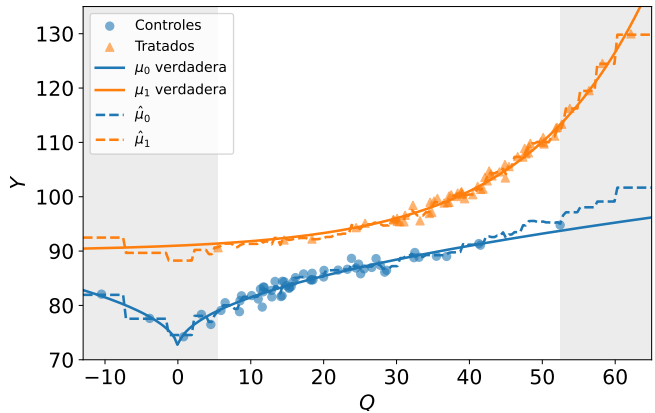
$f(q,t) \approx \mathbb{E}[Y|q,t]$
$\hat{\tau}(q) = f(q,1) - f(q,0)$

S-Learner

Cara de regresión

Un solo modelo para los dos grupos

$$f(q,t) \approx \mathbb{E}[Y|q,t]$$
$$\hat{\tau}(q) = f(q,1) - f(q,0)$$

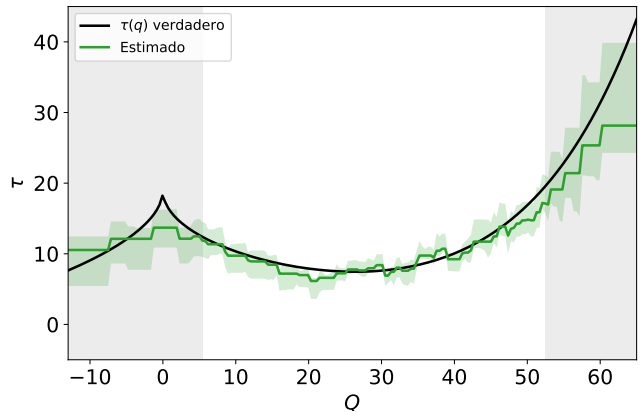


S-Learner

Cara de regresión

Un solo modelo para los dos grupos

$$f(q,t) \approx \mathbb{E}[Y|q,t]$$
$$\hat{\tau}(q) = f(q,1) - f(q,0)$$

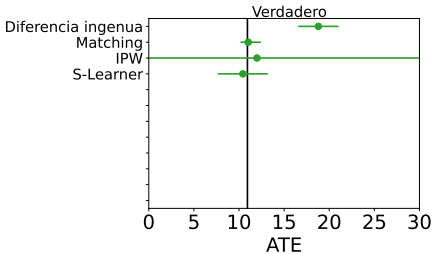


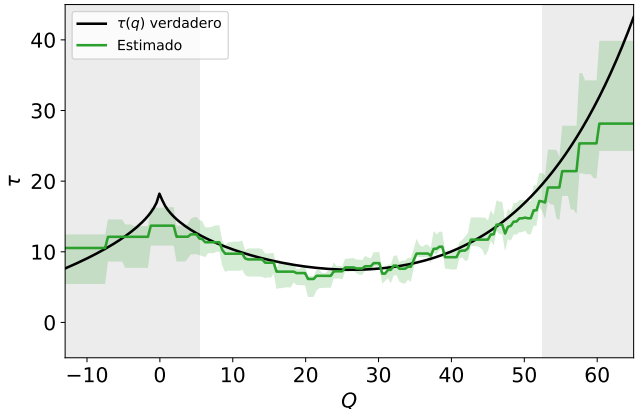
S-Learner

Cara de regresión

Un solo modelo para los dos grupos

$$f(q,t) \approx \mathbb{E}[Y|q,t]$$
$$\hat{\tau}(q) = f(q,1) - f(q,0)$$



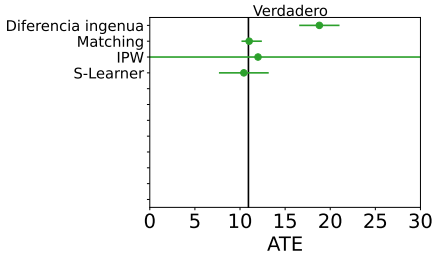


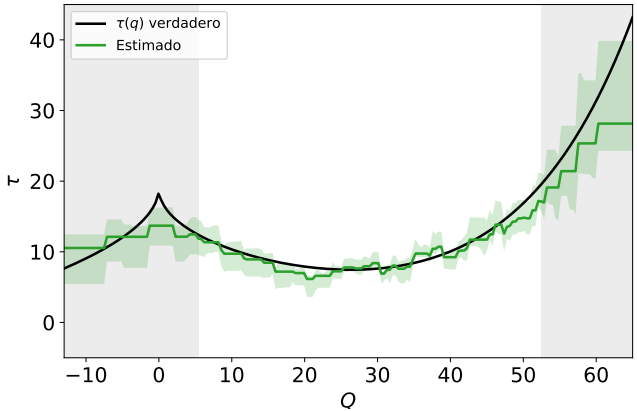
S-Learner

Cara de regresión

Un solo modelo para los dos grupos

$$f(q,t) \approx \mathbb{E}[Y|q,t]$$
$$\hat{\tau}(q) = f(q,1) - f(q,0)$$





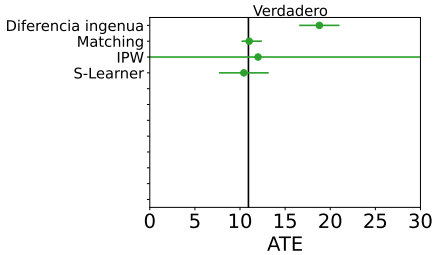
Intervalos por bootstrap: muestreo con reposición.

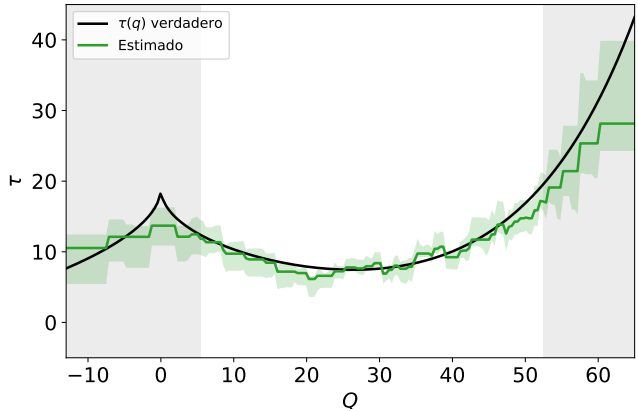
S-Learner

Cara de regresión

Un solo modelo para los dos grupos

$$f(q,t) \approx \mathbb{E}[Y|q,t]$$
$$\hat{\tau}(q) = f(q,1) - f(q,0)$$





En altas dimensiones, el modelo **puede ignorar** T

T-Learner

Cara de regresión

Un modelo por grupo

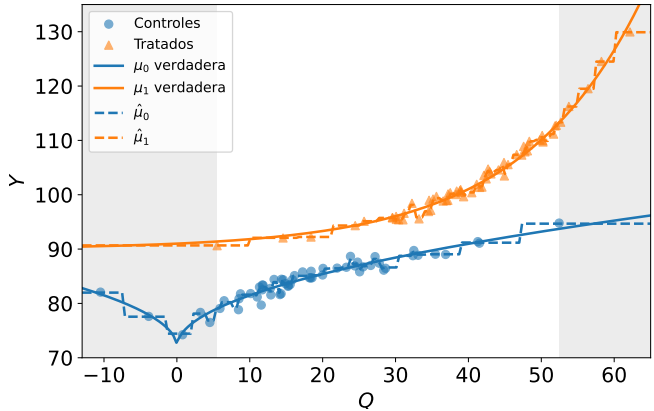
$f_0(q) \approx \mathbb{E}[Y|q, t = 0]$
$f_1(q) \approx \mathbb{E}[Y|q, t = 1]$
$\hat{\tau}(q) = f_1(q) - f_0(q)$

T-Learner

Cara de regresión

Un modelo por grupo

$$f_0(q) \approx \mathbb{E}[Y|q, t=0]$$
$$f_1(q) \approx \mathbb{E}[Y|q, t=1]$$
$$\hat{\tau}(q) = f_1(q) - f_0(q)$$

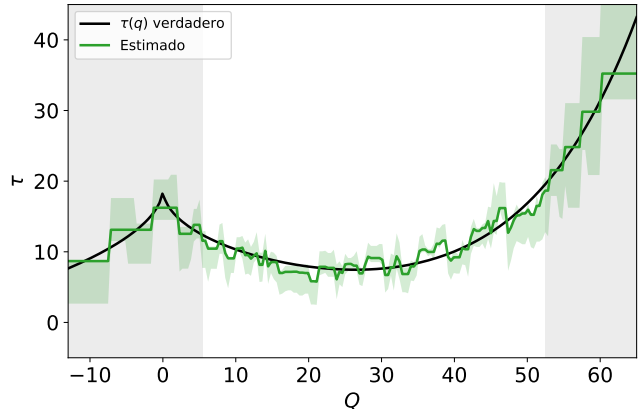


T-Learner

Cara de regresión

Un modelo por grupo

$$f_0(q) \approx \mathbb{E}[Y|q, t=0]$$
$$f_1(q) \approx \mathbb{E}[Y|q, t=1]$$
$$\hat{\tau}(q) = f_1(q) - f_0(q)$$

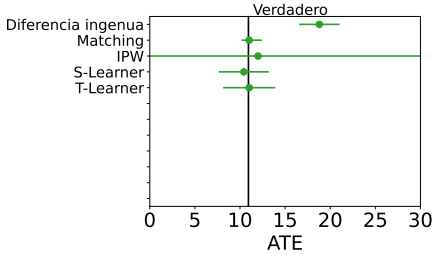


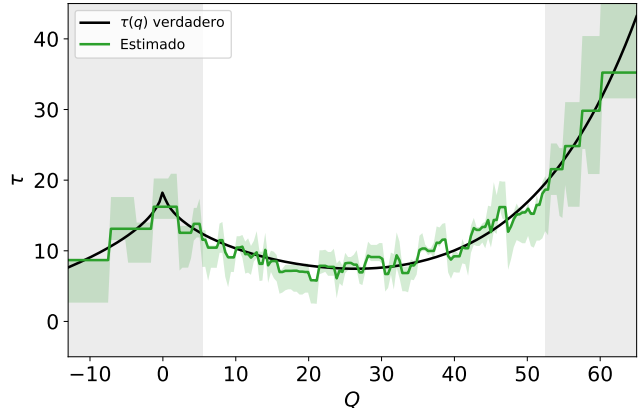
T-Learner

Cara de regresión

Un modelo por grupo

$$f_0(q) \approx \mathbb{E}[Y|q, t=0]$$
$$f_1(q) \approx \mathbb{E}[Y|q, t=1]$$
$$\hat{\tau}(q) = f_1(q) - f_0(q)$$





Cada curva **extrapola** donde su grupo no tiene datos

Doubly robust

Las dos caras

$$\hat{\tau}_i = \underbrace{\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i)}_{\text{Regresión}}$$

Doubly robust

Las dos caras

$$\hat{\tau}_i = \underbrace{\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i)}_{\text{Regresión}}$$

$$+ \frac{t_i \overbrace{(y_i - \hat{\mu}_1(q_i))}^{\text{Lo que el modelo erró}}}{\hat{e}(q_i)} - \frac{(1 - t_i) \overbrace{(y_i - \hat{\mu}_0(q_i))}^{\text{Lo que el modelo erró}}}{1 - \hat{e}(q_i)}$$

Doubly robust

Las dos caras

$$\hat{\tau}_i = \underbrace{\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i)}_{\text{Regresión}}$$

$$+\underbrace{\frac{t_i \overbrace{(y_i - \hat{\mu}_1(q_i))}^{\text{Lo que el modelo erró}}}{\hat{e}(q_i)} - \frac{(1-t_i) \overbrace{(y_i - \hat{\mu}_0(q_i))}^{\text{Lo que el modelo erró}}}{1-\hat{e}(q_i)}}_{\text{IPW de los residuos}}$$

Doubly robust

Las dos caras

$$\hat{\tau}_i = \underbrace{\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i)}_{\text{Regresión}}$$

$$\underbrace{+\frac{t_i \overbrace{(y_i - \hat{\mu}_1(q_i))}^{\text{Lo que el modelo erró}}}{\hat{e}(q_i)} - \frac{(1-t_i) \overbrace{(y_i - \hat{\mu}_0(q_i))}^{\text{Lo que el modelo erró}}}{1-\hat{e}(q_i)}}_{\text{IPW de los residuos}}$$

Si $\hat{\mu}$ es correcto, los residuos promedian 0: queda la **regresión**

Doubly robust

Las dos caras

$$\hat{\tau}_i = \underbrace{\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i)}_{\text{Regresión}}$$

$$\underbrace{+\frac{t_i \overbrace{(y_i - \hat{\mu}_1(q_i))}^{\text{Lo que el modelo erró}}}{\hat{e}(q_i)} - \frac{(1-t_i) \overbrace{(y_i - \hat{\mu}_0(q_i))}^{\text{Lo que el modelo erró}}}{1-\hat{e}(q_i)}}_{\text{IPW de los residuos}}$$

Si $\hat{\mu}$ es correcto, los residuos promedian 0: queda la **regresión**

Si $\hat{e}$ es correcto, queda **IPW**

Doubly robust

Las dos caras

$$\hat{\tau}_i = \underbrace{\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i)}_{\text{Regresión}}$$

$$\underbrace{+\frac{t_i \overbrace{(y_i - \hat{\mu}_1(q_i))}^{\text{Lo que el modelo erró}}}{\hat{e}(q_i)} - \frac{(1-t_i) \overbrace{(y_i - \hat{\mu}_0(q_i))}^{\text{Lo que el modelo erró}}}{1-\hat{e}(q_i)}}_{\text{IPW de los residuos}}$$

Si $\hat{\mu}$ es correcto, los residuos promedian 0: queda la **regresión**

Si $\hat{e}$ es correcto, queda **IPW**

Alcanza con que **uno de los dos** esté bien pero los dos dividen por $\hat{e}$

Doubly robust

Las dos caras

$$\hat{\tau}_i = \underbrace{\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i)}_{\text{Regresión}}$$

$$\underbrace{+\frac{t_i \overbrace{(y_i - \hat{\mu}_1(q_i))}^{\text{Lo que el modelo erró}}}{\hat{e}(q_i)} - \frac{(1-t_i) \overbrace{(y_i - \hat{\mu}_0(q_i))}^{\text{Lo que el modelo erró}}}{1-\hat{e}(q_i)}}_{\text{IPW de los residuos}}$$

$$\hat{\tau}_i = \underbrace{\frac{t_i\, y_i}{\hat{e}} - \frac{(1-t_i)\, y_i}{1-\hat{e}}}_{\text{IPW}} + \underbrace{\hat{\mu}_1\Big(1 - \frac{t_i}{\hat{e}}\Big) - \hat{\mu}_0\Big(1 - \frac{1-t_i}{1-\hat{e}}\Big)}_{\text{promedia 0}}$$

Doubly robust

Las dos caras

AIPW: regresión más la corrección por ponderación

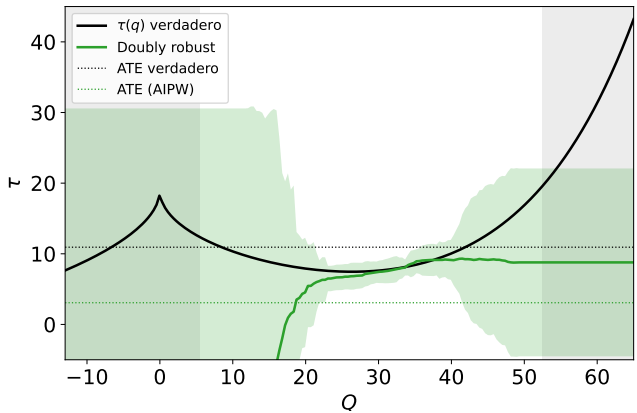
$$\begin{aligned}\hat{\tau}_i = &\hat{\mu}_1(q_i) - \hat{\mu}_0(q_i) \\ &+ \frac{t_i \left(y_i - \hat{\mu}_1(q_i)\right)}{\hat{e}(q_i)} \\ &- \frac{(1 - t_i)(y_i - \hat{\mu}_0(q_i))}{1 - \hat{e}(q_i)}\end{aligned}$$

Doubly robust

Las dos caras

AIPW: regresión más la corrección por ponderación

$$\hat{\tau}_i = \hat{\mu}_1(q_i) - \hat{\mu}_0(q_i) + \frac{t_i\,(y_i - \hat{\mu}_1(q_i))}{\hat{e}(q_i)} - \frac{(1-t_i)(y_i - \hat{\mu}_0(q_i))}{1-\hat{e}(q_i)}$$



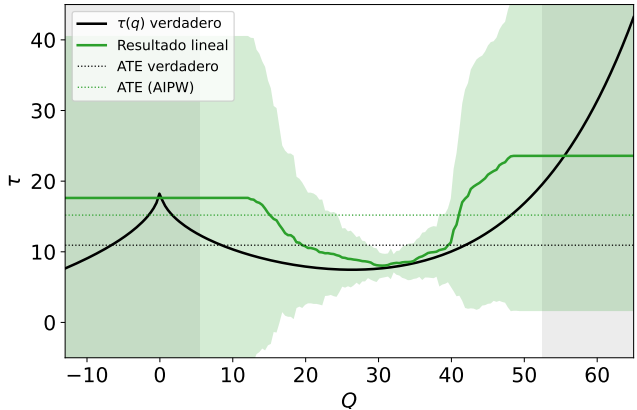
Los dos modelos flexibles

Doubly robust

Las dos caras

AIPW: regresión más la corrección por ponderación

$$\hat{\tau}_i = \hat{\mu}_1(q_i) - \hat{\mu}_0(q_i) + \frac{t_i\,(y_i - \hat{\mu}_1(q_i))}{\hat{e}(q_i)} - \frac{(1-t_i)(y_i - \hat{\mu}_0(q_i))}{1-\hat{e}(q_i)}$$



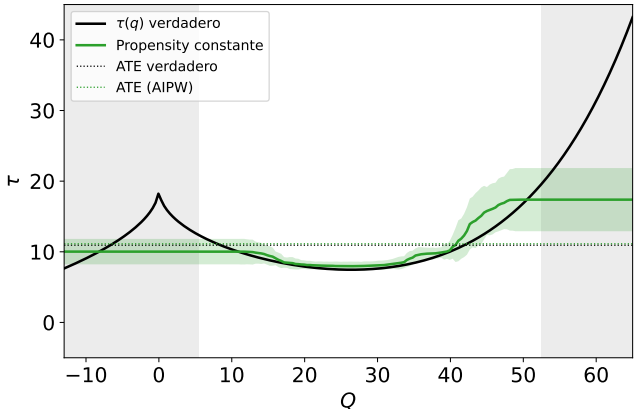
Modelo del resultado lineal

Doubly robust

Las dos caras

AIPW: regresión más la corrección por ponderación

$$\hat{\tau}_i = \hat{\mu}_1(q_i) - \hat{\mu}_0(q_i) + \frac{t_i\,(y_i - \hat{\mu}_1(q_i))}{\hat{e}(q_i)} - \frac{(1-t_i)(y_i - \hat{\mu}_0(q_i))}{1-\hat{e}(q_i)}$$



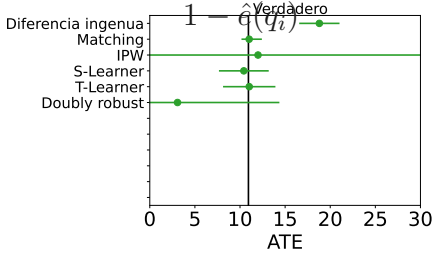
Propensity constante: regresión más una corrección suave

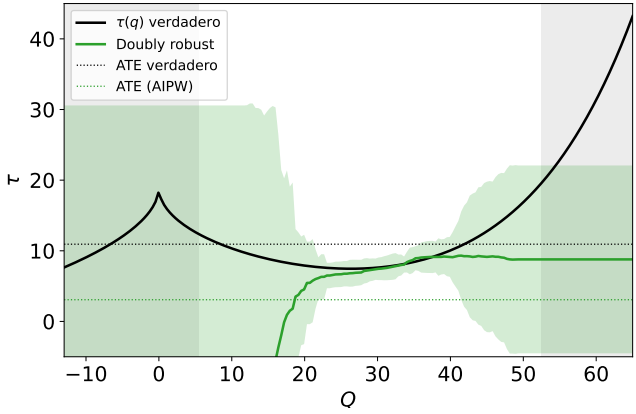
Doubly robust

Las dos caras

AIPW: regresión más la corrección por ponderación

$$\hat{\tau}_i = \hat{\mu}_1(q_i) - \hat{\mu}_0(q_i) + \frac{t_i\,(y_i - \hat{\mu}_1(q_i))}{\hat{e}(q_i)} - \frac{(1-t_i)(y_i - \hat{\mu}_0(q_i))}{1-\hat{e}(q_i)}$$





La doble robustez **no reemplaza** la positividad

DML

Las dos caras

Pendiente de los residuos, con cross-fitting

$$\hat{\theta} = \frac{\sum_i (t_i - \hat{e}(q_i))(y_i - \hat{m}(q_i))}{\sum_i (t_i - \hat{e}(q_i))^2}$$

con $\hat{m}(q) \approx \mathbb{E}[Y|q]$

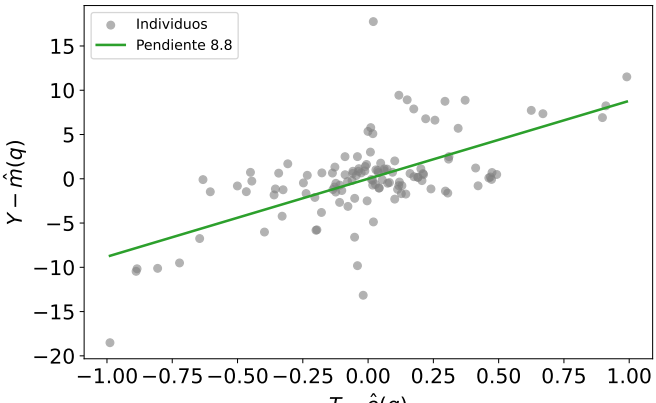
DML

Las dos caras

Pendiente de los residuos, con cross-fitting

$$\hat{\theta} = \frac{\sum_i (t_i - \hat{e}(q_i))(y_i - \hat{m}(q_i))}{\sum_i (t_i - \hat{e}(q_i))^2}$$

con $\hat{m}(q) \approx \mathbb{E}[Y|q]$



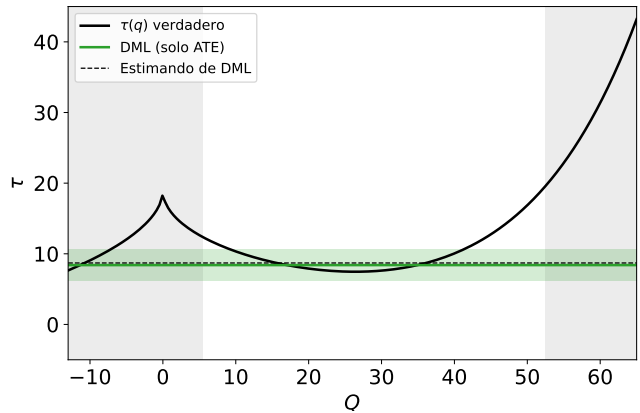
DML

Las dos caras

Pendiente de los residuos, con cross-fitting

$$\hat{\theta} = \frac{\sum_i (t_i - \hat{e}(q_i))(y_i - \hat{m}(q_i))}{\sum_i (t_i - \hat{e}(q_i))^2}$$

con $\hat{m}(q) \approx \mathbb{E}[Y|q]$



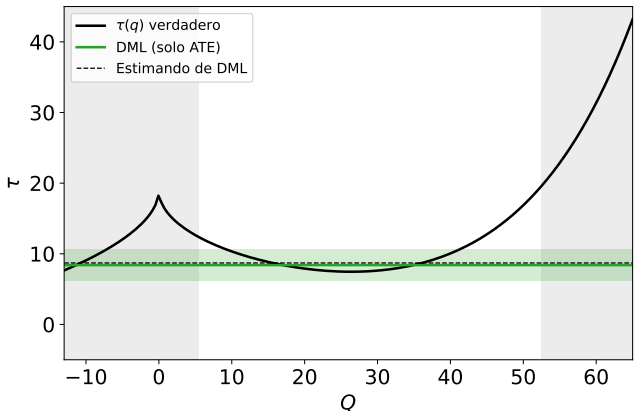
DML

Las dos caras

Pendiente de los residuos, con cross-fitting

$$\hat{\theta} = \frac{\sum_i (t_i - \hat{e}(q_i))(y_i - \hat{m}(q_i))}{\sum_i (t_i - \hat{e}(q_i))^2}$$

con $\hat{m}(q) \approx \mathbb{E}[Y|q]$



Con efecto heterogéneo estima $\frac{\sum_i e(q_i)(1-e(q_i))\,\tau(q_i)}{\sum_i e(q_i)(1-e(q_i))}$,

no el ATE

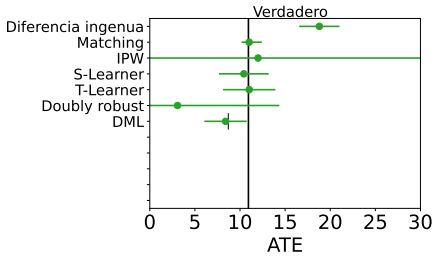
DML

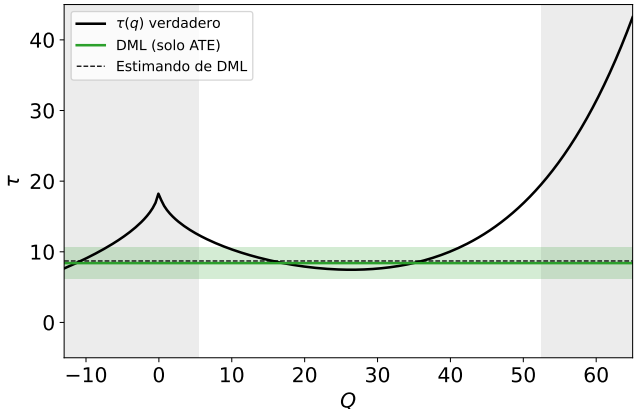
Las dos caras

Pendiente de los residuos, con cross-fitting

$$\hat{\theta} = \frac{\sum_i (t_i - \hat{e}(q_i))(y_i - \hat{m}(q_i))}{\sum_i (t_i - \hat{e}(q_i))^2}$$

con $\hat{m}(q) \approx \mathbb{E}[Y|q]$





Con efecto heterogéneo estima $\frac{\sum_i e(q_i)(1-e(q_i))\,\tau(q_i)}{\sum_i e(q_i)(1-e(q_i))}$,

no el ATE

Causal Forest

Las dos caras

Árboles que parten donde **cambia el efecto**

Honest splitting: una mitad de los datos arma el árbol y la otra estima el efecto en cada hoja

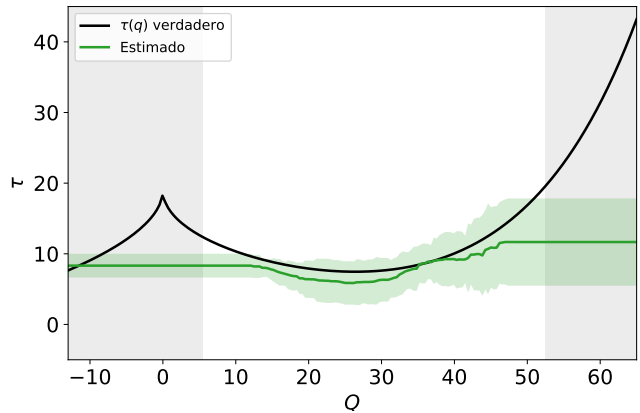
Wager y Athey 2018. Athey, Tibshirani y Wager 2019, *Generalized Random Forests*.

Causal Forest

Las dos caras

Árboles que parten donde **cambia el efecto**

Honest splitting: una mitad de los datos arma el árbol y la otra estima el efecto en cada hoja



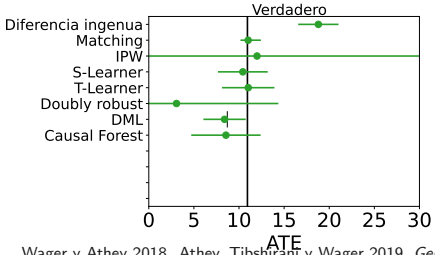
Wager y Athey 2018. Athey, Tibshirani y Wager 2019, *Generalized Random Forests*.

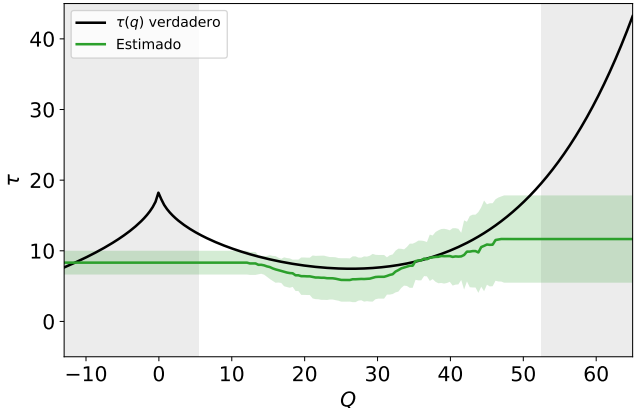
Causal Forest

Las dos caras

Árboles que parten donde **cambia el efecto**

Honest splitting: una mitad de los datos arma el árbol y la otra estima el efecto en cada hoja

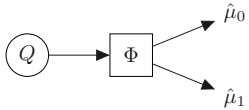




Wager y Athey 2018. Athey, Tibshirani y Wager 2019, *Generalized Random Forests*.

TARNet

Cara de regresión

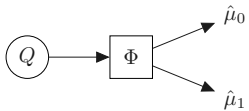


Un T-Learner que **comparte la representación**: el grupo chico aprende de los dos

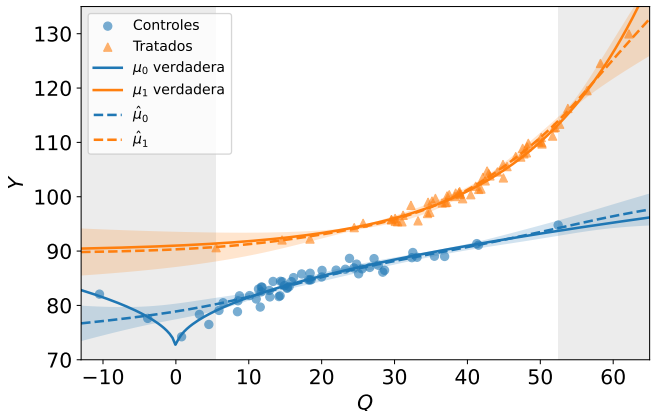
Shalit, Johansson y Sontag 2017, *Estimating Individual Treatment Effect: Generalization Bounds and Algorithms*.

TARNet

Cara de regresión



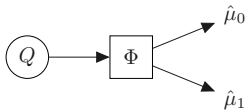
Un T-Learner que **comparte la representación**: el grupo chico aprende de los dos



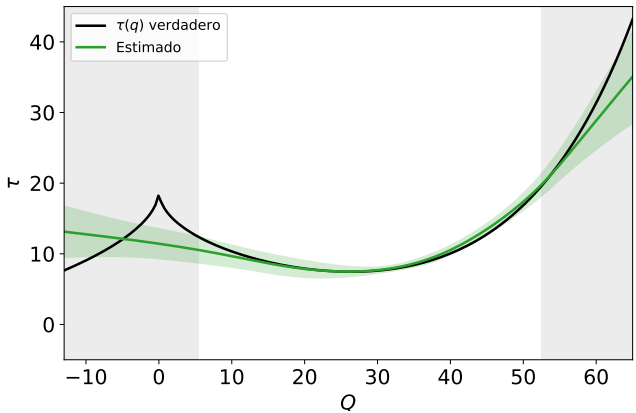
Shalit, Johansson y Sontag 2017, *Estimating Individual Treatment Effect: Generalization Bounds and Algorithms.*

TARNet

Cara de regresión



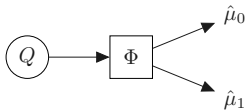
Un T-Learner que **comparte la representación**: el grupo chico aprende de los dos



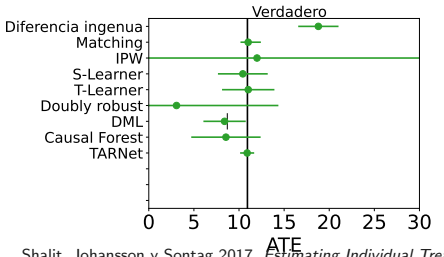
Shalit, Johansson y Sontag 2017, *Estimating Individual Treatment Effect: Generalization Bounds and Algorithms*.

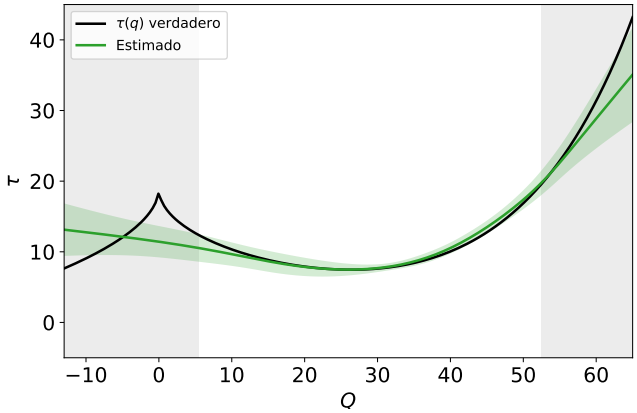
TARNet

Cara de regresión



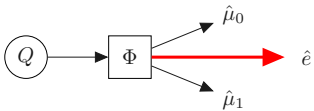
Un T-Learner que **comparte la representación**: el grupo chico aprende de los dos





Shalit, Johansson y Sontag 2017, *Estimating Individual Treatment Effect: Generalization Bounds and Algorithms.*

Dragonnet
Las dos caras

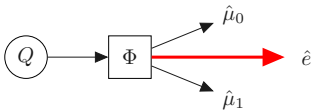


Si alcanza con $e(Q)$, **alcanza con** $\Phi(Q)$

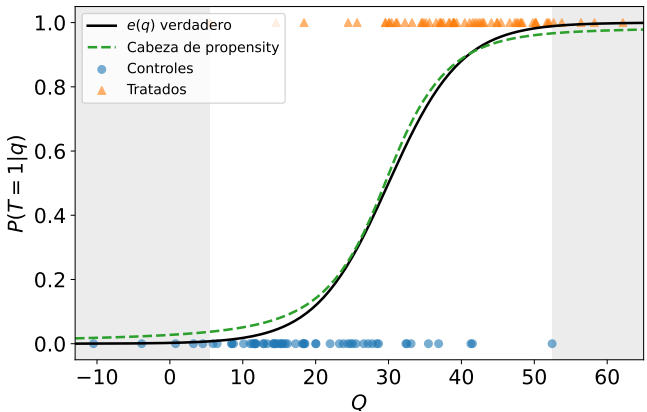
Shi, Blei y Veitch 2019, *Adapting Neural Networks for the Estimation of Treatment Effects*. CFR (Shalit y otros 2017) penaliza la distancia entre las

Dragonnet

Las dos caras



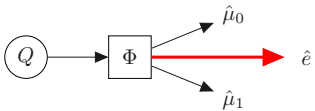
Si alcanza con $e(Q)$, **alcanza con** $\Phi(Q)$



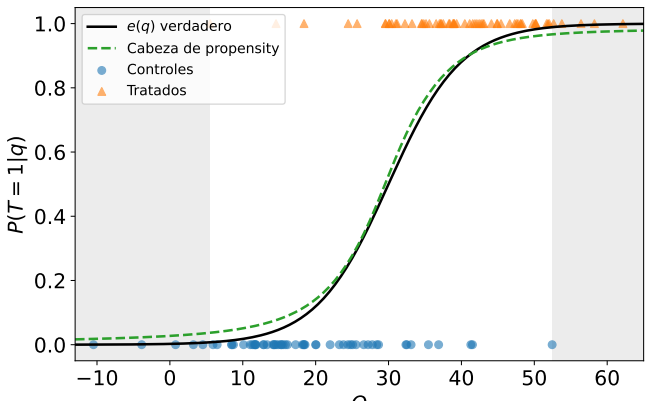
Shi, Blei y Veitch 2019, *Adapting Neural Networks for the Estimation of Treatment Effects.* CFR (Shalit y otros 2017) penaliza la distancia entre las

Dragonnet

Las dos caras



Si alcanza con $e(Q)$, **alcanza con** $\Phi(Q)$



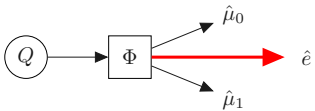
$$\tilde{\mu}_t = \hat{\mu}_t + \epsilon \left(\frac{t}{\hat{e}} - \frac{1-t}{1-\hat{e}} \right)$$

En el ϵ óptimo es la **corrección de AIPW**: da el ATE

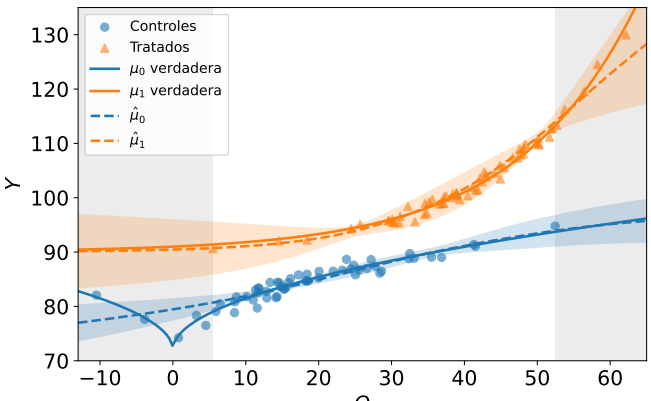
Shi, Blei y Veitch 2019, *Adapting Neural Networks for the Estimation of Treatment Effects*. CFR (Shalit y otros 2017) penaliza la distancia entre las

Dragonnet

Las dos caras



Si alcanza con $e(Q)$, **alcanza con** $\Phi(Q)$



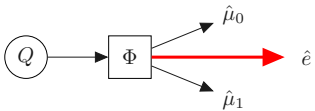
$$\tilde{\mu}_t = \hat{\mu}_t + \epsilon \left(\frac{t}{\hat{e}} - \frac{1-t}{1-\hat{e}} \right)$$

En el ϵ óptimo es la **corrección de AIPW**: da el ATE

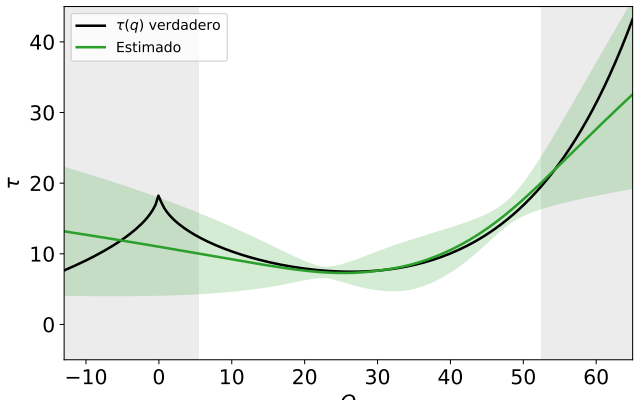
Shi, Blei y Veitch 2019, *Adapting Neural Networks for the Estimation of Treatment Effects*. CFR (Shalit y otros 2017) penaliza la distancia entre las

Dragonnet

Las dos caras



Si alcanza con $e(Q)$, **alcanza con** $\Phi(Q)$



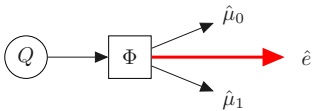
$$\tilde{\mu}_t = \hat{\mu}_t + \epsilon \left(\frac{t}{\hat{e}} - \frac{1-t}{1-\hat{e}} \right)$$

En el ϵ óptimo es la **corrección de AIPW**: da el ATE

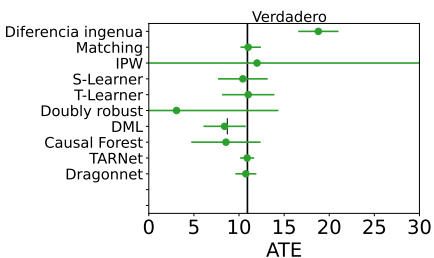
Shi, Blei y Veitch 2019, *Adapting Neural Networks for the Estimation of Treatment Effects.* CFR (Shalit y otros 2017) penaliza la distancia entre las

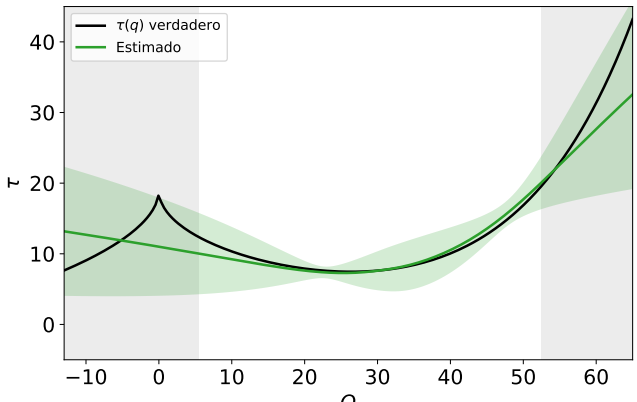
Dragonnet

Las dos caras



Si alcanza con $e(Q)$, **alcanza con** $\Phi(Q)$





$$\tilde{\mu}_t = \hat{\mu}_t + \epsilon \left(\frac{t}{\hat{e}} - \frac{1-t}{1-\hat{e}} \right)$$

En el ϵ óptimo es la **corrección de AIPW**: da el ATE

Shi, Blei y Veitch 2019, *Adapting Neural Networks for the Estimation of Treatment Effects.* CFR (Shalit y otros 2017) penaliza la distancia entre las

BART

Cara de regresión

Suma de árboles, con una prior que los mantiene chicos

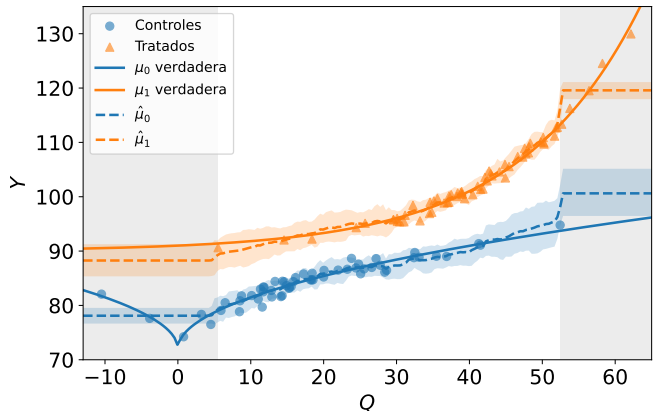
$$Y = \sum_{j=1}^{m} g(q, t; \mathcal{T}_j, M_j) + \varepsilon$$

BART

Cara de regresión

Suma de árboles, con una prior que los mantiene chicos

$$Y = \sum_{j=1}^{m} g(q, t; \mathcal{T}_j, M_j) + \varepsilon$$

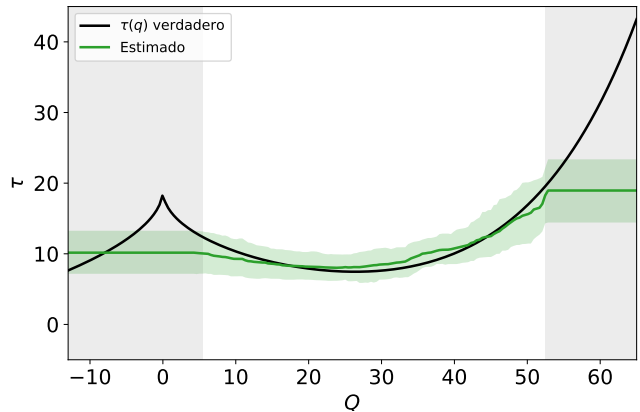


BART

Cara de regresión

Suma de árboles, con una prior que los mantiene chicos

$$Y = \sum_{j=1}^{m} g(q, t; \mathcal{T}_j, M_j) + \varepsilon$$

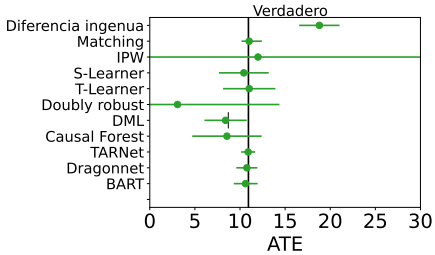


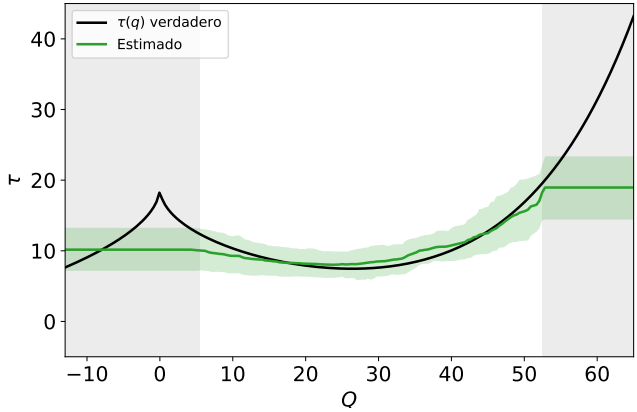
BART

Cara de regresión

Suma de árboles, con una prior que los mantiene chicos

$$Y = \sum_{j=1}^{m} g(q, t; \mathcal{T}_j, M_j) + \varepsilon$$





BCF

Las dos caras

$$Y = \mu(q, \hat{e}(q)) + \tau(q)\, t + \varepsilon$$

Prior propia sobre τ, que empuja hacia **efecto homogéneo**

BCF

Las dos caras

$$Y = \mu(q, \hat{e}(q)) + \tau(q)\, t + \varepsilon$$

Prior propia sobre τ, que empuja hacia **efecto homogéneo**

El propensity como covariable corrige el confounding inducido por regularización

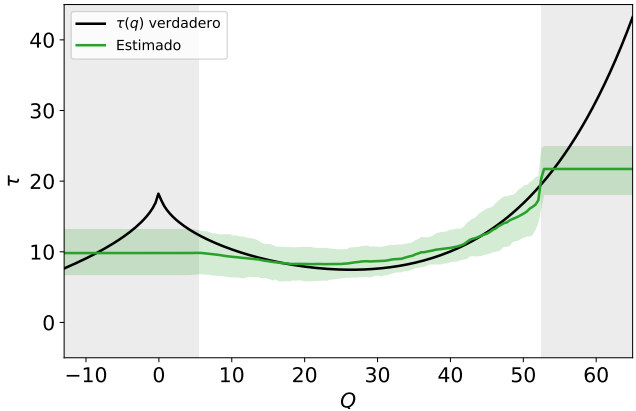
BCF

Las dos caras

$$Y = \mu(q, \hat{e}(q)) + \tau(q)\, t + \varepsilon$$

Prior propia sobre τ, que empuja hacia **efecto homogéneo**

El propensity como covariable corrige el confounding inducido por regularización



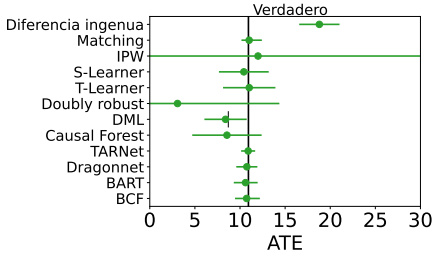
BCF

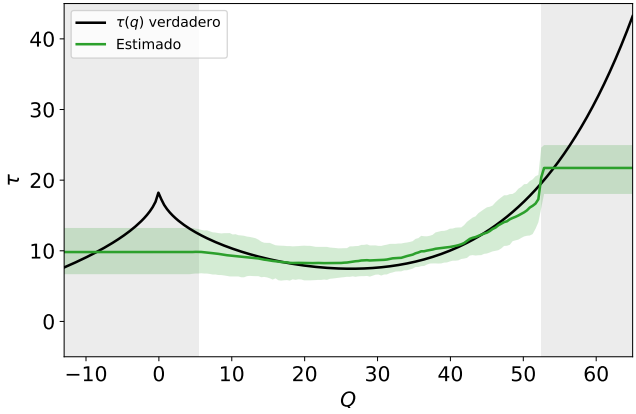
Las dos caras

$$Y = \mu(q, \hat{e}(q)) + \tau(q)\, t + \varepsilon$$

Prior propia sobre τ, que empuja hacia **efecto homogéneo**

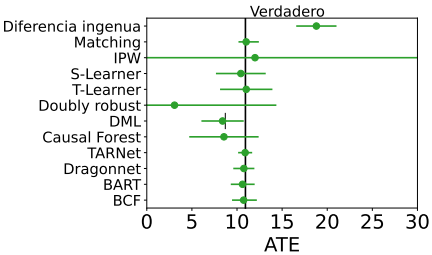
El propensity como covariable corrige el confounding inducido por regularización

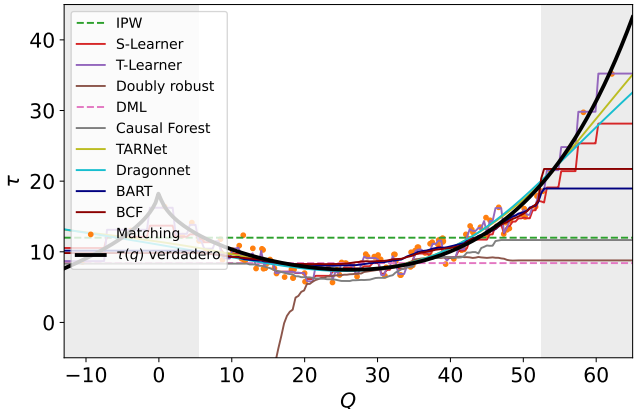




El zoológico

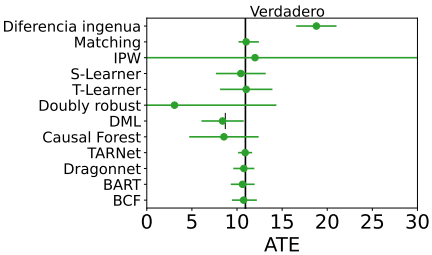
Todos juntos

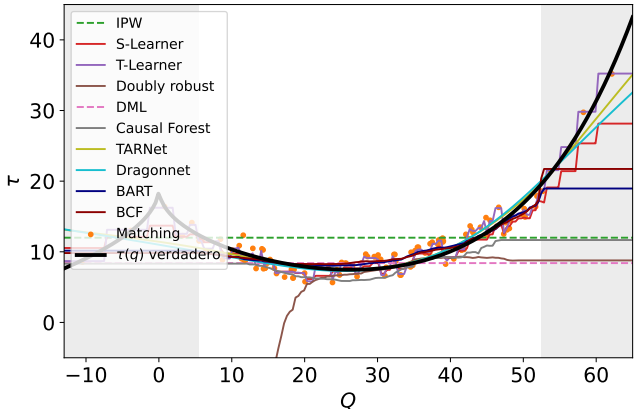




El zoológico

Todos juntos





Donde no hay datos, **todos extrapolan**

IHDP: ¿quién gana?

IHDP

Infant Health and Development Program

- Experimento aleatorizado con bebés prematuros de bajo peso

IHDP

Infant Health and Development Program

- Experimento aleatorizado con bebés prematuros de bajo peso
- Hill (2011) quita a los tratados con madre no blanca: **deja de ser un experimento**
  747 chicos, 139 tratados y 25 covariables

IHDP

Infant Health and Development Program

- Experimento aleatorizado con bebés prematuros de bajo peso
- Hill (2011) quita a los tratados con madre no blanca: **deja de ser un experimento**
  747 chicos, 139 tratados y 25 covariables

Superficie A: $Y_t = [1, X]\,\beta_A + 4\,t + \varepsilon$ (efecto homogéneo)

IHDP

Infant Health and Development Program

- Experimento aleatorizado con bebés prematuros de bajo peso
- Hill (2011) quita a los tratados con madre no blanca: **deja de ser un experimento**
  747 chicos, 139 tratados y 25 covariables

Superficie A: $Y_t = [1, X]\,\beta_A + 4\,t + \varepsilon$ (efecto homogéneo)

Superficie B: $Y_0 = \exp([1, X + 0.5]\,\beta_B) + \varepsilon$ (efecto heterogéneo)

$Y_1 = [1, X + 0.5]\,\beta_B - \omega_B + \varepsilon$

IHDP

Infant Health and Development Program

- Experimento aleatorizado con bebés prematuros de bajo peso
- Hill (2011) quita a los tratados con madre no blanca: **deja de ser un experimento**
  747 chicos, 139 tratados y 25 covariables

Superficie A: $Y_t = [1, X]\,\beta_A + 4\,t + \varepsilon$ (efecto homogéneo)

Superficie B: $Y_0 = \exp([1, X + 0.5]\,\beta_B) + \varepsilon$ (efecto heterogéneo)

$Y_1 = [1, X + 0.5]\,\beta_B - \omega_B + \varepsilon$

β_A: cada coeficiente en $\{0, 1, 2, 3, 4\}$ con probabilidades $(0.5, 0.2, 0.15, 0.1, 0.05)$
β_B: cada coeficiente en $\{0, 0.1, 0.2, 0.3, 0.4\}$ con probabilidades $(0.6, 0.1, 0.1, 0.1, 0.1)$

IHDP

Infant Health and Development Program

- Experimento aleatorizado con bebés prematuros de bajo peso
- Hill (2011) quita a los tratados con madre no blanca: **deja de ser un experimento**
  747 chicos, 139 tratados y 25 covariables

Superficie A: $Y_t = [1, X]\,\beta_A + 4\,t + \varepsilon$ (efecto homogéneo)

Superficie B: $Y_0 = \exp([1, X + 0.5]\,\beta_B) + \varepsilon$ (efecto heterogéneo)

$Y_1 = [1, X + 0.5]\,\beta_B - \omega_B + \varepsilon$

β_A: cada coeficiente en $\{0, 1, 2, 3, 4\}$ con probabilidades $(0.5, 0.2, 0.15, 0.1, 0.05)$
β_B: cada coeficiente en $\{0, 0.1, 0.2, 0.3, 0.4\}$ con probabilidades $(0.6, 0.1, 0.1, 0.1, 0.1)$

ω_B fija el ATE en 4 (Hill fijaba el efecto en los tratados).

IHDP

Cómo se juzga

Error en el ATE $|\widehat{\text{ATE}} - 4|$

Error y PEHE: **promedio sobre las 100 réplicas**

IHDP

Cómo se juzga

Error en el ATE $|\widehat{\text{ATE}} - 4|$

PEHE $\sqrt{\frac{1}{n}\sum_i (\hat{\tau}_i - \tau_i)^2}$

Error y PEHE: **promedio sobre las 100 réplicas**

IHDP

Cómo se juzga

Error en el ATE $|\widehat{\text{ATE}} - 4|$

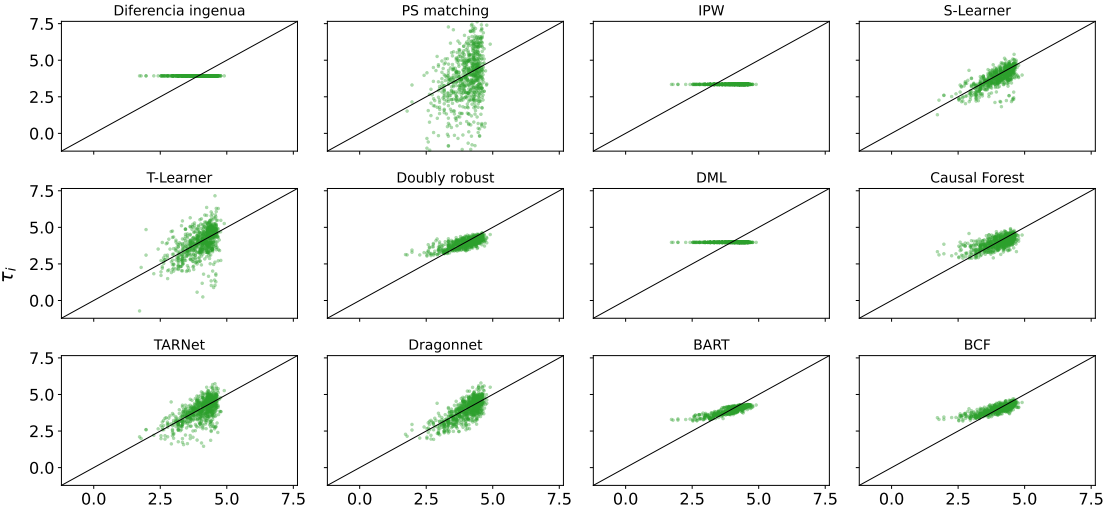
PEHE $\sqrt{\frac{1}{n}\sum_i (\hat{\tau}_i - \tau_i)^2}$

Cobertura proporción de réplicas en que el intervalo del 95% contiene a 4

Error y PEHE: **promedio sobre las 100 réplicas**

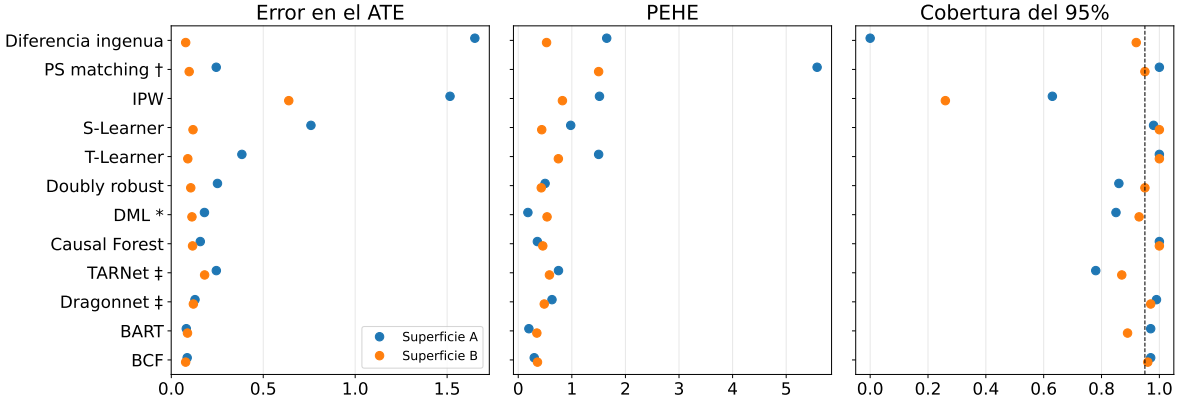
Estimado vs verdadero

IHDP, superficie B, réplica 1



Resumen

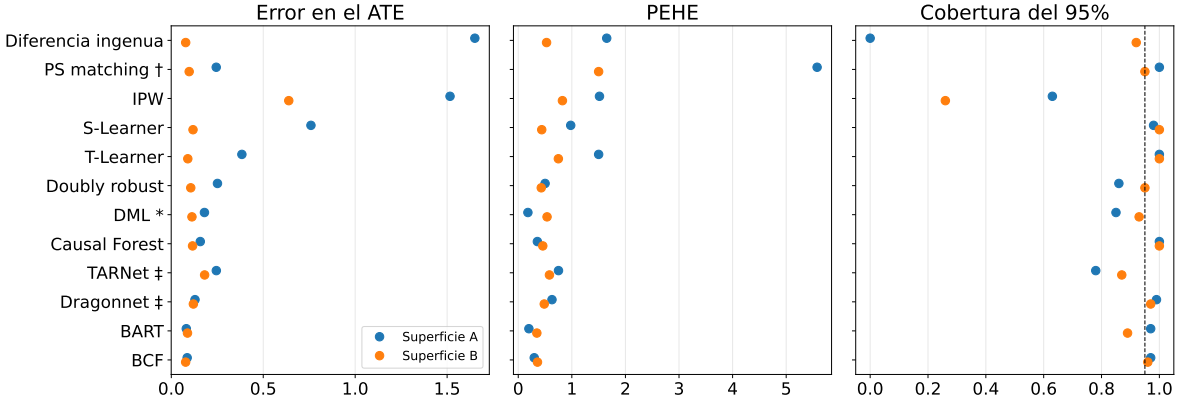
IHDP, 100 réplicas



† el bootstrap no es válido para matching. * en B, DML estima otro promedio de τ, no el ATE. ‡ cobertura aproximada: ensamble de 10 redes.

Resumen

IHDP, 100 réplicas



† el bootstrap no es válido para matching. * en B, DML estima otro promedio de τ, no el ATE. ‡ cobertura aproximada: ensamble de 10 redes.

Los que modelan con flexibilidad **ganan**

Las competencias

Atlantic / American Causal Inference Conference

• ACIC 2016: ganan los métodos que **modelan con flexibilidad** la superficie de respuesta

Dorie y otros 2019. Thal y Finucane 2023, *Causal Methods Madness*. Abadie e Imbens 2008, *On the Failure of the Bootstrap for Matching Estimators*.

Las competencias

Atlantic / American Causal Inference Conference

• ACIC 2016: ganan los métodos que **modelan con flexibilidad** la superficie de respuesta

• ACIC 2022 (datos de panel, estimando SATT, intervalos del 90%): los intervalos basados en el modelo funcionan mejor que los de bootstrap, y ningún estimador logra a la vez buen error y **cobertura nominal** en los efectos por práctica médica

Dorie y otros 2019. Thal y Finucane 2023, *Causal Methods Madness*. Abadie e Imbens 2008, *On the Failure of the Bootstrap for Matching Estimators*.

Las competencias

Atlantic / American Causal Inference Conference

• ACIC 2016: ganan los métodos que **modelan con flexibilidad** la superficie de respuesta

• ACIC 2022 (datos de panel, estimando SATT, intervalos del 90%): los intervalos basados en el modelo funcionan mejor que los de bootstrap, y ningún estimador logra a la vez buen error y **cobertura nominal** en los efectos por práctica médica

• Nuestros intervalos: la cobertura del resumen (el bootstrap no es válido para matching)

Dorie y otros 2019. Thal y Finucane 2023, *Causal Methods Madness*. Abadie e Imbens 2008, *On the Failure of the Bootstrap for Matching Estimators*.

El ecosistema de Python

¿En qué paso trabaja cada paquete?

	1. Especificación	2. Identificación	3. Estimación
DoWhy	•	•	•

DoWhy agrega un cuarto paso: refutar la estimación

El ecosistema de Python

¿En qué paso trabaja cada paquete?

	1. Especificación	2. Identificación	3. Estimación
DoWhy	•	•	•
EconML			•
CausalML			•
`stochtree`			•

DoWhy agrega un cuarto paso: refutar la estimación

El ecosistema de Python

¿En qué paso trabaja cada paquete?

	1. Especificación	2. Identificación	3. Estimación
DoWhy	•	•	•
EconML			•
CausalML			•
`stochtree`			•

DoWhy agrega un cuarto paso: refutar la estimación

Casi todo el ecosistema **vive en el paso 3**

Los límites

Un efecto bien estimado

Lotería de vivienda subsidiada en Argentina

JUE Insight: The Unintended Effect of Argentina's Subsidized Homeownership Lottery Program on Intimate Partner Violence

Bruno Cardinale Lagomarsino[a], Martin A. Rossi[b]

[a] *Department of Economics, Brown University, Providence, 02906, Rhode Island, US*
[b] *Department of Economics, Universidad de San Andrés, Victoria, 1644, Buenos Aires, Argentina*

Un efecto bien estimado

Lotería de vivienda subsidiada en Argentina

JUE Insight: The Unintended Effect of Argentina's Subsidized Homeownership Lottery Program on Intimate Partner Violence

Bruno Cardinale Lagomarsino[a], Martin A. Rossi[b]

[a] *Department of Economics, Brown University, Providence, 02906, Rhode Island, US*
[b] *Department of Economics, Universidad de San Andrés, Victoria, 1644, Buenos Aires, Argentina*

- Contrato de copropiedad con la pareja: el programa **aumenta** la violencia de pareja

Un efecto bien estimado

Lotería de vivienda subsidiada en Argentina

JUE Insight: The Unintended Effect of Argentina's Subsidized Homeownership Lottery Program on Intimate Partner Violence

Bruno Cardinale Lagomarsino[a], Martin A. Rossi[b]

[a] *Department of Economics, Brown University, Providence, 02906, Rhode Island, US*
[b] *Department of Economics, Universidad de San Andrés, Victoria, 1644, Buenos Aires, Argentina*

- Contrato de copropiedad con la pareja: el programa **aumenta** la violencia de pareja
- Contrato de propiedad individual: el programa la **disminuye**

¿Y qué hacemos?

- Leído como tratamiento y objetivo: **¿dejar de dar el subsidio?**

¿Y qué hacemos?

- Leído como tratamiento y objetivo: **¿dejar de dar el subsidio?**
- Queremos que sigan recibiendo el subsidio **y** que baje la violencia

¿Y qué hacemos?

- Leído como tratamiento y objetivo: **¿dejar de dar el subsidio?**
- Queremos que sigan recibiendo el subsidio **y** que baje la violencia
- El propio estudio: el **tipo de contrato** cambia el sentido del efecto, y los autores proponen cambiar el diseño del programa, no eliminarlo

Conclusiones

• El zoológico estima muy bien efectos entre pares de variables (paso 3), pero **supone resueltos** los pasos 1 y 2

Conclusiones

- El zoológico estima muy bien efectos entre pares de variables (paso 3), pero **supone resueltos** los pasos 1 y 2

- Los efectos causales por sí solos no dicen cómo intervenir en el mundo

Conclusiones

- El zoológico estima muy bien efectos entre pares de variables (paso 3), pero **supone resueltos** los pasos 1 y 2

- Los efectos causales por sí solos no dicen cómo intervenir en el mundo

- Para actuar hace falta una **teoría causal generativa** global del problema

Conclusiones

- El zoológico estima muy bien efectos entre pares de variables (paso 3), pero **supone resueltos** los pasos 1 y 2

- Los efectos causales por sí solos no dicen cómo intervenir en el mundo

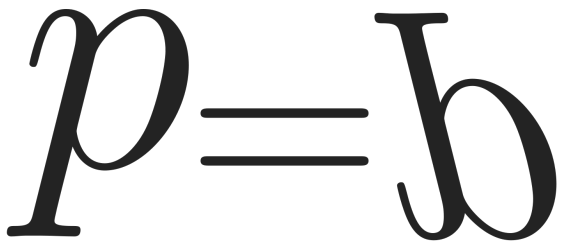
- Para actuar hace falta una **teoría causal generativa** global del problema

No hay atajo

Práctica 4.1: positividad y competencias

Predicciones causales bajo distintos grados de positividad (**Entrega 4.1**)

1. Positividad en la simulación de Hill.
   a. Variar el solapamiento con la asignación $P(t|q) = \sigma(k\,(q - 30))$.
   b. Correr todos los algoritmos del zoológico en cada k.
   c. Comparar el error en el ATE, el PEHE y la cobertura.
2. Competencia ACIC 2016.
   a. Dos escenarios que difieren solo en el solapamiento.
   b. Correr todos los algoritmos del zoológico y comparar las mismas métricas.



Laboratorios de Métodos Bayesianos