El ecosistema de las teorías causales

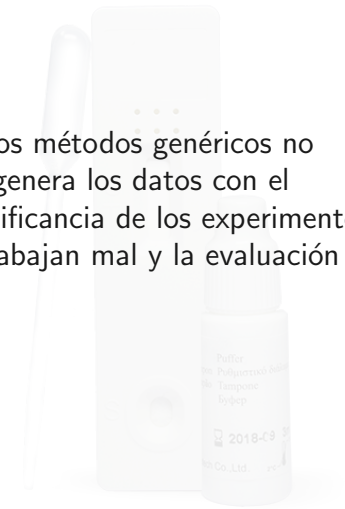
Unidad 4.2



El ecosistema de las teorías causales

Unidad 4.2

Cuando los datos son escasos o están contaminados, los métodos genéricos no alcanzan. La alternativa es especificar el proceso que genera los datos con el conocimiento experto. Lo vemos en tres casos: la significancia de los experimentos publicitarios, un test de Chagas con operadores que trabajan mal y la evaluación de tests diagnósticos sin gold standard.



Bibliografía Unidad 4.2

• Hui y Walter 1980. *Estimating the error rates of diagnostic tests*. Biometrics.

• Dendukuri y Joseph 2001. *Bayesian approaches to modeling the conditional dependence between multiple diagnostic tests*. Biometrics.

• Cheung y otros 2021. *Bayesian latent class analysis when the reference test is imperfect*. Rev. Sci. Tech. OIE.

• Umemneku Chikere y otros 2019. *Diagnostic test evaluation methodology: a systematic review of methods employed to evaluate diagnostic tests in the absence of gold standard*. PLoS One.

Inferencia causal en casos reales

¿Qué hacemos cuando los datos no alcanzan?

Inferencia causal en casos reales

- **Datos escasos**: los experimentos son costosos.

Inferencia causal en casos reales

- **Datos escasos**: los experimentos son costosos.
- **Datos contaminados**: errores de carga y de protocolo.

Inferencia causal en casos reales

- **Datos escasos**: los experimentos son costosos.
- **Datos contaminados**: errores de carga y de protocolo.
- **Sin referencia**: no observamos la verdad.

Inferencia causal en casos reales

- **Datos escasos**: los experimentos son costosos.
- **Datos contaminados**: errores de carga y de protocolo.
- **Sin referencia**: no observamos la verdad.

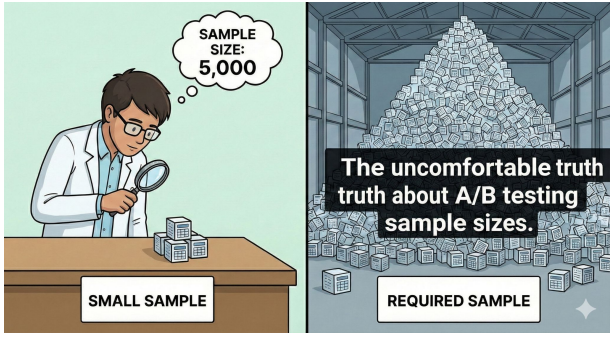
Especificar el proceso que genera los datos
con el **conocimiento experto**

Significancia de los experimentos causales

¿Cuántas ventas produce una campaña publicitaria?

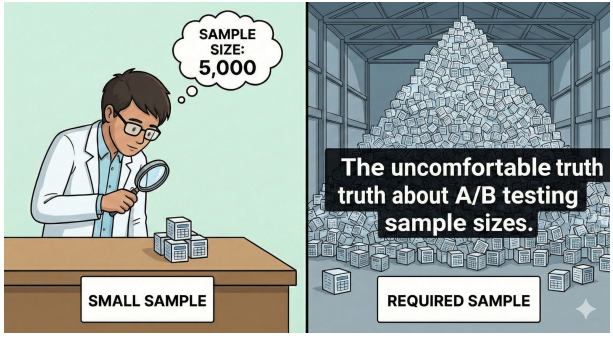
Experimentos causales

Tratamiento y control



Experimentos causales

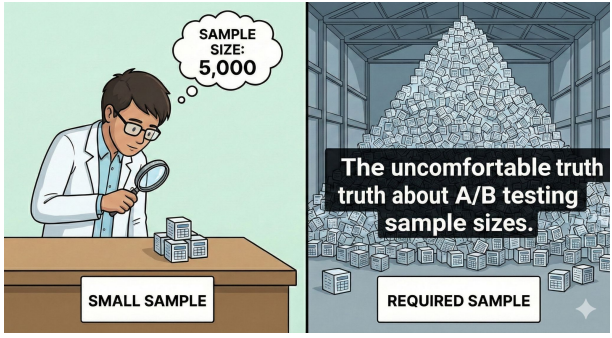
Tratamiento y control



Dividimos al azar: n_T conversiones de N_T y n_C conversiones de N_C.

Experimentos causales

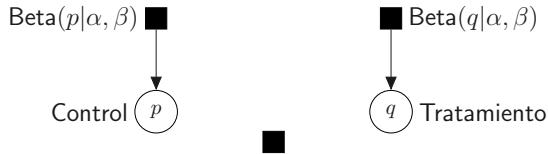
Tratamiento y control



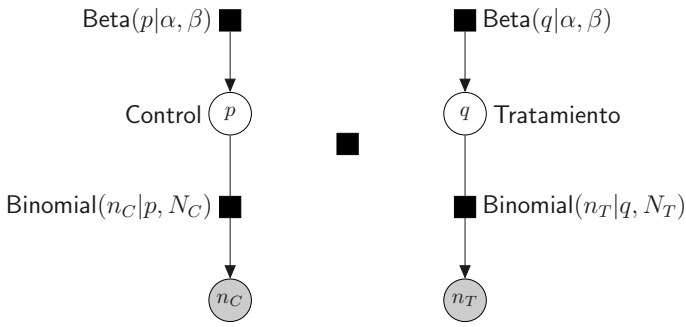
Dividimos al azar: n_T conversiones de N_T y n_C conversiones de N_C.

Los resultados **no suelen ser significativos**.

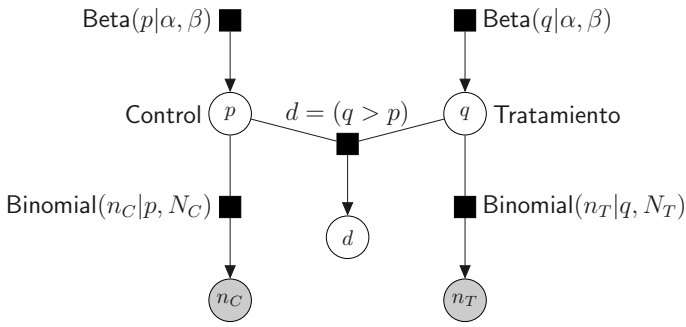
Modelo base



Modelo base

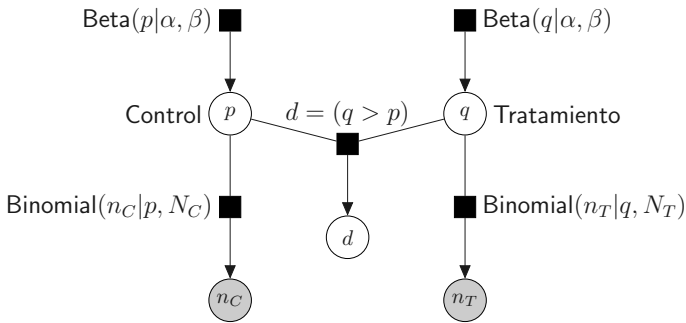

Beta$(p|\alpha,\beta)$
Control
p
Binomial$(n_C|p,N_C)$
n_C
Beta$(q|\alpha,\beta)$
q
Tratamiento
Binomial$(n_T|q,N_T)$
n_T

Modelo base


Beta$(p|\alpha,\beta)$
Beta$(q|\alpha,\beta)$
Control
p
$d = (q > p)$
q
Tratamiento
Binomial$(n_C|p, N_C)$
d
Binomial$(n_T|q, N_T)$
n_C
n_T

Modelo base

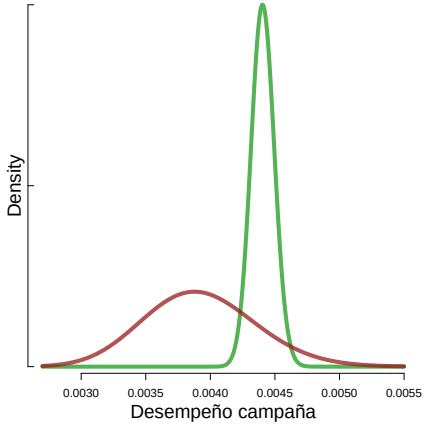
Solución analítica



$$\text{Beta}(p|\alpha,\beta)\,\text{Binomial}(n|p,N) \propto \text{Beta}(p|\alpha+n,\ \beta+N-n)$$

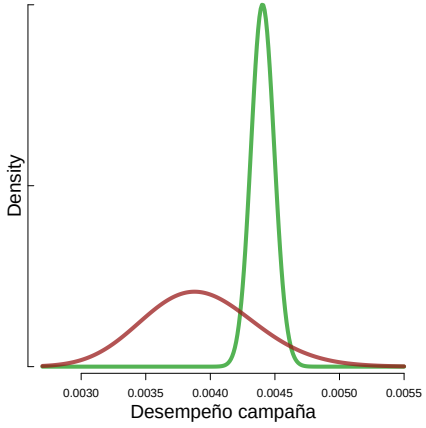
Modelo base

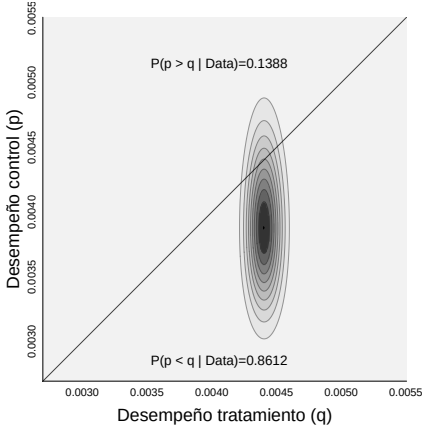
Enero de 2025



Modelo base

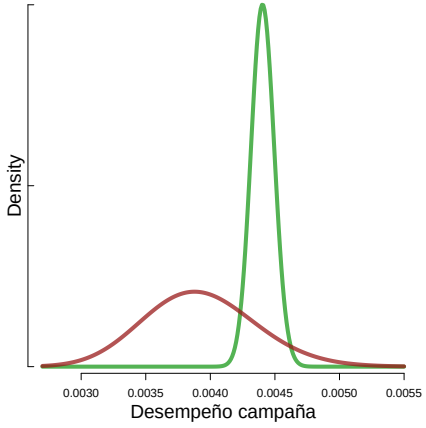
Enero de 2025

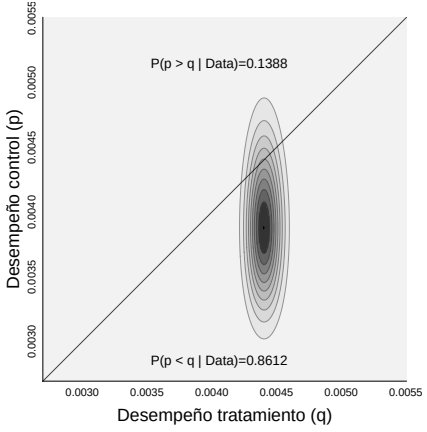




Modelo base

Enero de 2025





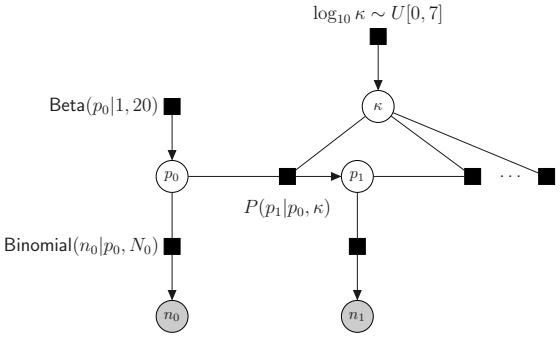
$P(q > p|\text{Datos}) \approx 0.86$: **no es significativo**, ningún mes

Modelo temporal

¿Y si conectamos los meses?

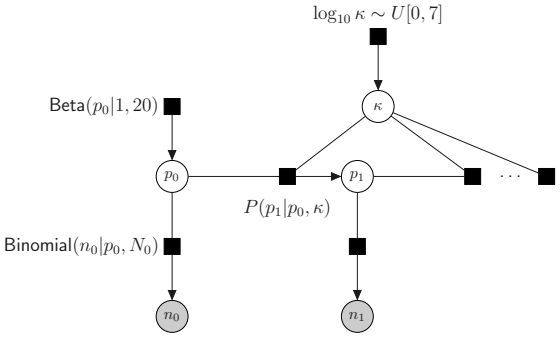
Modelo temporal

Cambio gradual del desempeño



Modelo temporal

Cambio gradual del desempeño

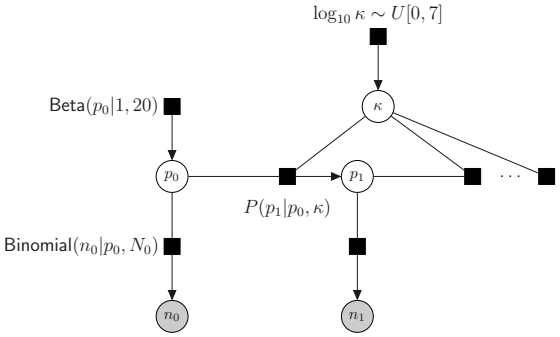


$$P(p_t|p_{t-1},\kappa) =$$

$$\text{Beta}\big(p_t \mid \kappa\, p_{t-1},\ \kappa\,(1-p_{t-1})\big)$$

Modelo temporal

Cambio gradual del desempeño



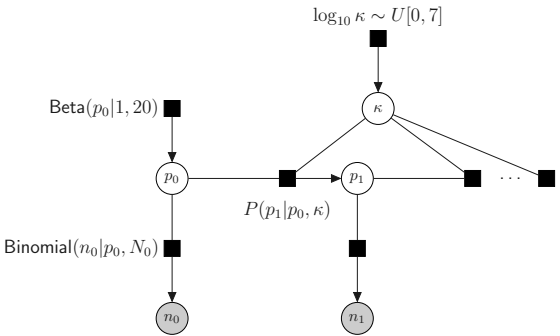
$$P(p_t|p_{t-1},\kappa) = \mathsf{Beta}\big(p_t \mid \kappa\, p_{t-1},\ \kappa\,(1-p_{t-1})\big)$$

$$\mathbb{E}[p_t|p_{t-1},\kappa] = p_{t-1}$$

$$\mathsf{Var}(p_t|p_{t-1},\kappa) = \frac{p_{t-1}(1-p_{t-1})}{\kappa+1}$$

Modelo temporal

Cambio gradual del desempeño



$$P(p_t|p_{t-1},\kappa) = \mathsf{Beta}\big(p_t \mid \kappa\, p_{t-1},\ \kappa\,(1-p_{t-1})\big)$$

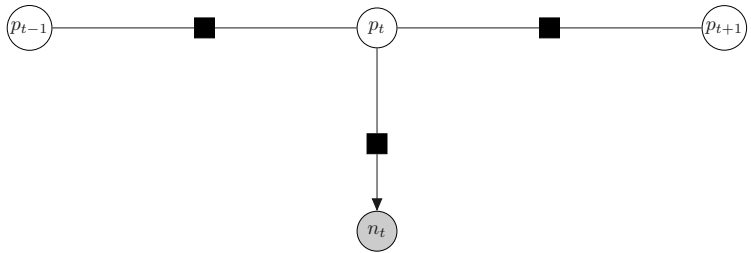
$$\mathbb{E}[p_t|p_{t-1},\kappa] = p_{t-1}$$

$$\mathsf{Var}(p_t|p_{t-1},\kappa) = \tfrac{p_{t-1}(1-p_{t-1})}{\kappa+1}$$

κ cumple el rol **inverso del ruido**

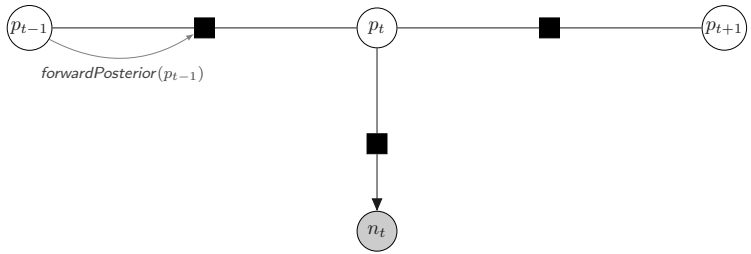
Pasaje de mensajes

Aproximación con descuento λ



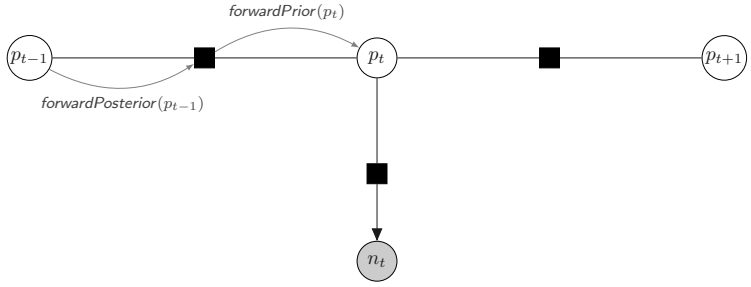
Pasaje de mensajes

Aproximación con descuento λ



Pasaje de mensajes

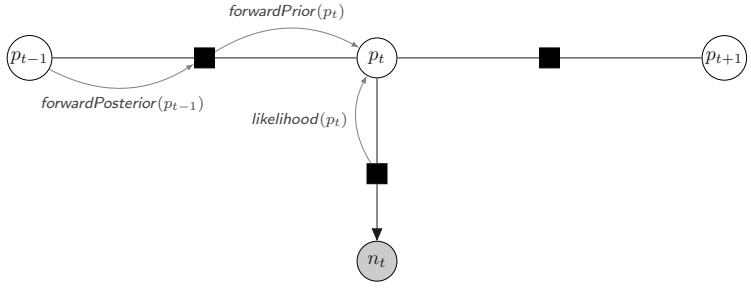
Aproximación con descuento λ



$$\mathit{forwardPrior}(p_t) = \lambda \cdot \mathit{forwardPosterior}(p_{t-1})$$

Pasaje de mensajes

Aproximación con descuento λ

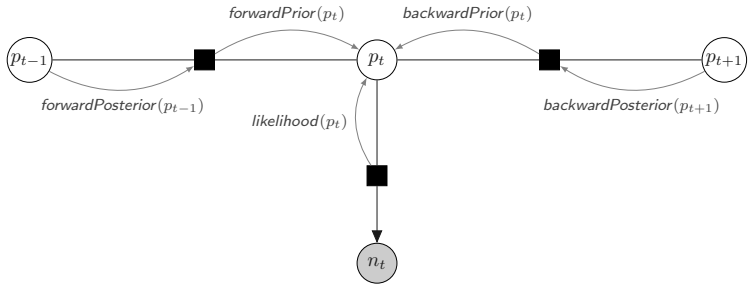


forwardPrior$(p_t) = \lambda \cdot$ *forwardPosterior*(p_{t-1})

likelihood$(p_t) = (n_t,\ N_t - n_t)$

Pasaje de mensajes

Aproximación con descuento λ



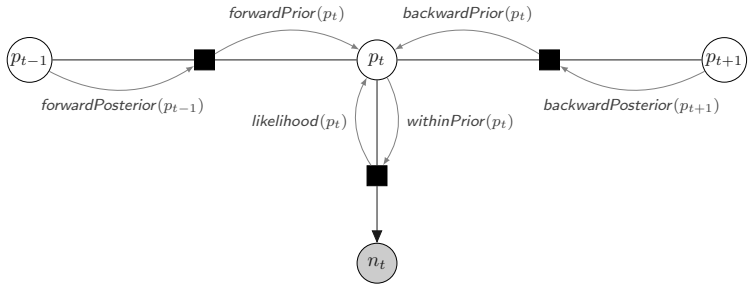
$\mathit{forwardPrior}(p_t) = \lambda \cdot \mathit{forwardPosterior}(p_{t-1})$

$\mathit{likelihood}(p_t) = (n_t,\ N_t - n_t)$

$\mathit{backwardPrior}(p_t) = \lambda \cdot \mathit{backwardPosterior}(p_{t+1})$

Pasaje de mensajes

Aproximación con descuento λ



$\mathit{forwardPrior}(p_t) = \lambda \cdot \mathit{forwardPosterior}(p_{t-1})$

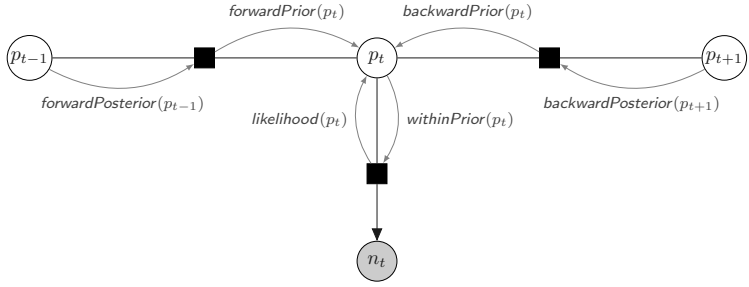
$\mathit{likelihood}(p_t) = (n_t,\ N_t - n_t)$

$\mathit{backwardPrior}(p_t) = \lambda \cdot \mathit{backwardPosterior}(p_{t+1})$

$\mathit{withinPrior}(p_t) = \mathit{forwardPrior}(p_t) + \mathit{backwardPrior}(p_t)$

Pasaje de mensajes

Aproximación con descuento λ



forwardPrior$(p_t) = \lambda \cdot$ *forwardPosterior*(p_{t-1})

likelihood$(p_t) = (n_t,\ N_t - n_t)$

backwardPrior$(p_t) = \lambda \cdot$ *backwardPosterior*(p_{t+1})

withinPrior$(p_t) =$ *forwardPrior*$(p_t) +$ *backwardPrior*(p_t)

posterior$(p_t) =$ *withinPrior*$(p_t) +$ *likelihood*(p_t)

Elección de λ

Evidencia leave-one-out

$$\mathit{withinPrior}(p_t) = \mathit{forwardPrior}(p_t) + \mathit{backwardPrior}(p_t)$$

Elección de λ

Evidencia leave-one-out

$$\underbrace{\textit{withinPrior}(p_t)}_{\substack{\text{Toda la red} \\ \text{salvo el mes } t}} = \textit{forwardPrior}(p_t) + \textit{backwardPrior}(p_t)$$

Elección de λ

Evidencia leave-one-out

$$\underbrace{\textit{withinPrior}(p_t)}_{\substack{\text{Toda la red} \\ \text{salvo el mes } t}} = \textit{forwardPrior}(p_t) + \textit{backwardPrior}(p_t)$$

$$P(n_t|N_t, \lambda) = \text{BetaBinomial}(n_t|N_t, \textit{withinPrior}(p_t))$$

Elección de λ

Evidencia leave-one-out

$$\underbrace{\textit{withinPrior}(p_t)}_{\substack{\text{Toda la red} \\ \text{salvo el mes } t}} = \textit{forwardPrior}(p_t) + \textit{backwardPrior}(p_t)$$

$$P(n_t|N_t, \lambda) = \text{BetaBinomial}(n_t|N_t, \textit{withinPrior}(p_t))$$

$$\log P(\text{Datos}|\lambda) = \sum_t \log P(n_t|N_t, \lambda)$$

Elección de λ

Evidencia leave-one-out

$$\underbrace{\textit{withinPrior}(p_t)}_{\substack{\text{Toda la red} \\ \text{salvo el mes } t}} = \textit{forwardPrior}(p_t) + \textit{backwardPrior}(p_t)$$

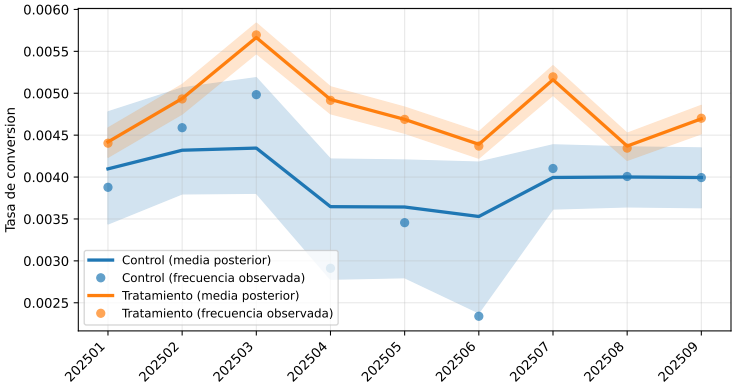
$$P(n_t|N_t, \lambda) = \text{BetaBinomial}(n_t|N_t, \textit{withinPrior}(p_t))$$

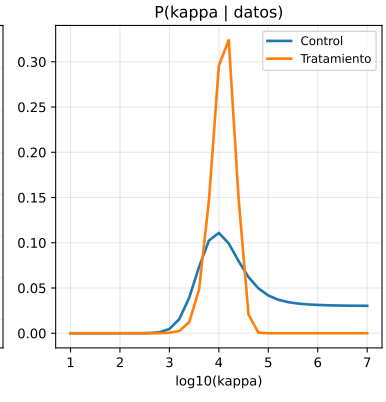
$$\log P(\text{Datos}|\lambda) = \sum_t \log P(n_t|N_t, \lambda)$$

Elegimos el λ que **mejor predice** cada mes **sin verlo**

Modelo temporal

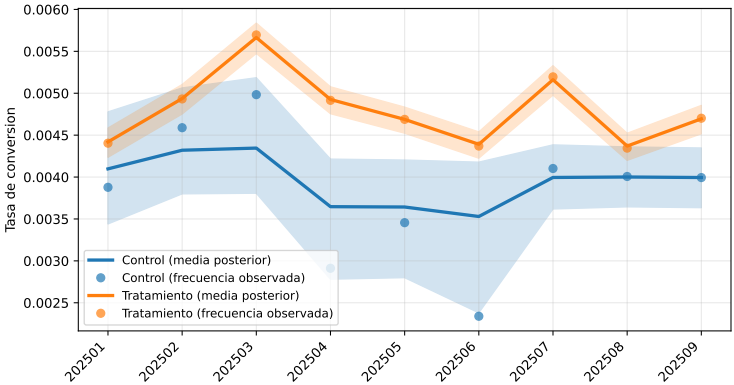
Enero a septiembre de 2025

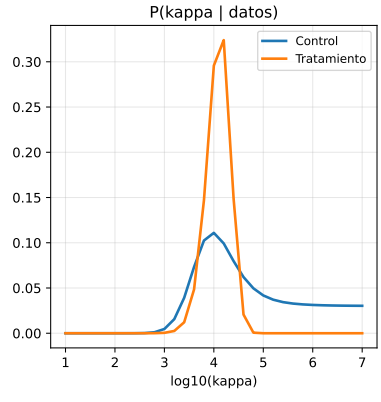




Modelo temporal

Enero a septiembre de 2025





Conectar los meses **separa tratamiento de control**

Datos escasos y contaminados

Desempeño de un test de Chagas ante distintas cepas

El experimento

Tres cepas y dos concentraciones



El experimento

Tres cepas y dos concentraciones



- **3 cepas** del parásito: DTU I, DTU II y DTU VI.

El experimento

Tres cepas y dos concentraciones



- **3 cepas** del parásito: DTU I, DTU II y DTU VI.
- **2 concentraciones**: 20 y 50 par.Eq/ml.

El experimento

Tres cepas y dos concentraciones



- **3 cepas** del parásito: DTU I, DTU II y DTU VI.
- **2 concentraciones**: 20 y 50 par.Eq/ml.
- **14 laboratorios**, 3 muestras por contexto.

El experimento

Tres cepas y dos concentraciones

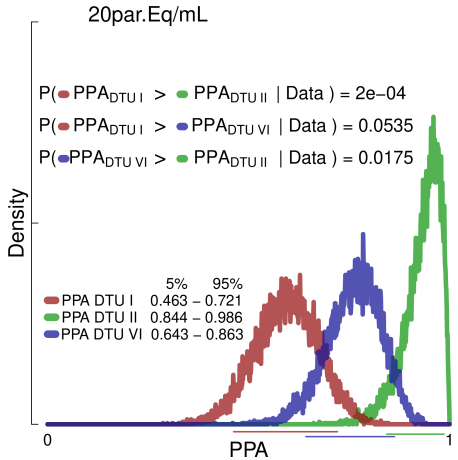


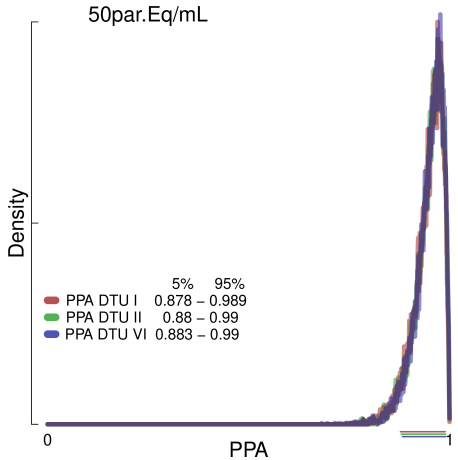
- **3 cepas** del parásito: DTU I, DTU II y DTU VI.
- **2 concentraciones**: 20 y 50 par.Eq/ml.
- **14 laboratorios**, 3 muestras por contexto.

Solo $14 \cdot 3 = \mathbf{42}$ datos por contexto

El experimento

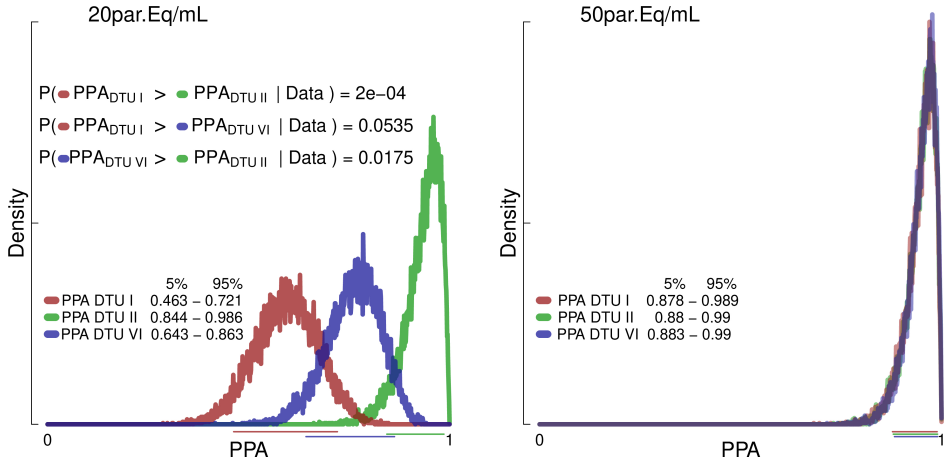
Resultado del grupo de investigación





El experimento

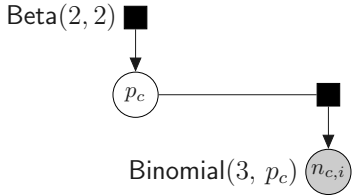
Resultado del grupo de investigación



Pero algunos operadores **trabajan mal**

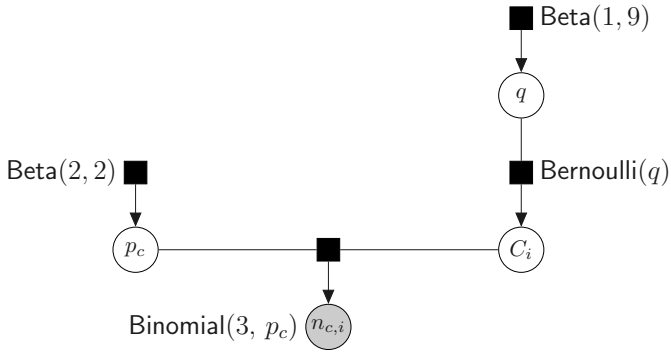
Modelo con operadores

Modelo base



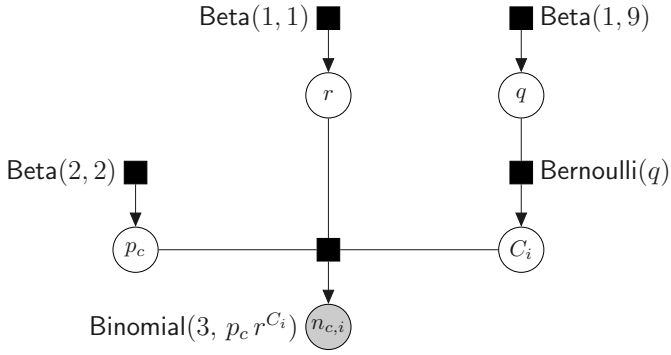
Modelo con operadores

Cada operador trabaja bien o mal



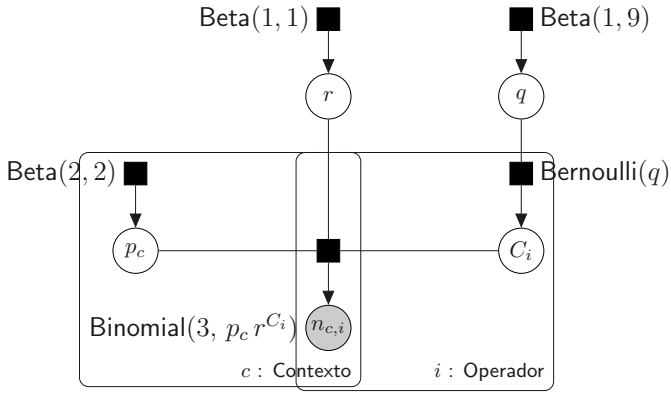
Modelo con operadores

Cada operador trabaja bien o mal



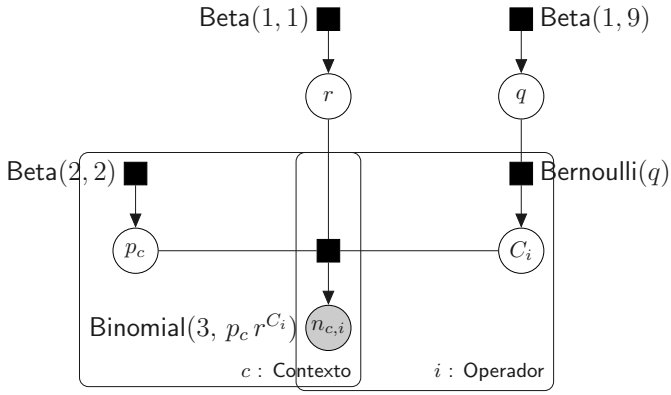
Modelo con operadores

Cada operador trabaja bien o mal



Modelo con operadores

Cada operador trabaja bien o mal



Un solo C_i: el operador queda **sospechoso en todos** los contextos

Modelo con operadores

Sumar sobre la variable discreta C_i

$$P(n_i|p,q,r) = \sum_{C_i} P(C_i|q) \prod_c P(n_{c,i}|p_c, r, C_i)$$

Modelo con operadores

Sumar sobre la variable discreta C_i

$$
\begin{aligned}
P(n_i|p,q,r) &= \sum_{C_i} P(C_i|q) \prod_c P(n_{c,i}|p_c, r, C_i) \\
&= (1-q) \prod_c \text{Binomial}(n_{c,i}|3, p_c) + q \prod_c \text{Binomial}(n_{c,i}|3, p_c\, r)
\end{aligned}
$$

Modelo con operadores

Sumar sobre la variable discreta C_i

$$P(n_i|p,q,r) = \sum_{C_i} P(C_i|q) \prod_c P(n_{c,i}|p_c, r, C_i)$$

$$= \underbrace{(1-q) \prod_c \text{Binomial}(n_{c,i}|3, p_c)}_{\text{Trabaja bien}} + \underbrace{q \prod_c \text{Binomial}(n_{c,i}|3, p_c\, r)}_{\text{Trabaja mal}}$$

Modelo con operadores

Sumar sobre la variable discreta C_i

$$P(n_i|p,q,r) = \sum_{C_i} P(C_i|q) \prod_c P(n_{c,i}|p_c, r, C_i)$$

$$= \underbrace{(1-q) \prod_c \text{Binomial}(n_{c,i}|3, p_c)}_{\text{Trabaja bien}} + \underbrace{q \prod_c \text{Binomial}(n_{c,i}|3, p_c\, r)}_{\text{Trabaja mal}}$$

$$P(C_i = 1|n_i, p, q, r) = \frac{q \prod_c \text{Binomial}(n_{c,i}|3, p_c\, r)}{P(n_i|p,q,r)}$$

Modelo con operadores

Sumar sobre la variable discreta C_i

$$P(n_i|p,q,r) = \sum_{C_i} P(C_i|q) \prod_c P(n_{c,i}|p_c, r, C_i)$$

$$= \underbrace{(1-q) \prod_c \text{Binomial}(n_{c,i}|3, p_c)}_{\text{Trabaja bien}} + \underbrace{q \prod_c \text{Binomial}(n_{c,i}|3, p_c\, r)}_{\text{Trabaja mal}}$$

$$P(C_i = 1|n_i, p, q, r) = \frac{q \prod_c \text{Binomial}(n_{c,i}|3, p_c\, r)}{P(n_i|p,q,r)}$$

NUTS solo muestrea variables continuas: **sumamos las discretas**

Comparación de modelos

El selector M

$$P(M|\text{Datos}) = \frac{P(\text{Datos}|M)\,P(M)}{P(\text{Datos})}$$

Comparación de modelos

El selector M

$$P(M|\text{Datos}) = \frac{P(\text{Datos}|M)\,P(M)}{P(\text{Datos})}$$

$$\propto P(\text{Datos}|M) \quad \text{(prior uniforme)}$$

Comparación de modelos

El selector M

$$P(M|\text{Datos}) = \frac{P(\text{Datos}|M)\,P(M)}{P(\text{Datos})}$$

$$\propto P(\text{Datos}|M) \quad \text{(prior uniforme)}$$

$$\log P(\text{Datos}|\text{Operadores}) - \log P(\text{Datos}|\text{Base}) \approx 6.5$$

Comparación de modelos

El selector M

$$P(M|\text{Datos}) = \frac{P(\text{Datos}|M)\,P(M)}{P(\text{Datos})}$$

$$\propto P(\text{Datos}|M) \quad \text{(prior uniforme)}$$

$$\log P(\text{Datos}|\text{Operadores}) - \log P(\text{Datos}|\text{Base}) \approx 6.5 \quad \Rightarrow \quad e^{6.5} \approx 665$$

Comparación de modelos

El selector M

$$P(M|\text{Datos}) = \frac{P(\text{Datos}|M)\,P(M)}{P(\text{Datos})}$$

$$\propto P(\text{Datos}|M) \quad \text{(prior uniforme)}$$

$$\log P(\text{Datos}|\text{Operadores}) - \log P(\text{Datos}|\text{Base}) \approx 6.5 \quad \Rightarrow \quad e^{6.5} \approx 665$$

¿Todos los operadores fallan **en la misma medida**?

¿Se relacionan las concentraciones **baja y alta**?

Evaluación de tests diagnósticos

sin gold standard

Desempeño de un test diagnóstico

Con gold standard

	Diagnóstico $= 1$	Diagnóstico $= 0$
Estado $= 1$		
Estado $= 0$		

Desempeño de un test diagnóstico

Con gold standard

	Diagnóstico $= 1$	Diagnóstico $= 0$
Estado $= 1$	**Sensibilidad** s	$1 - s$
Estado $= 0$	$1 - x$	**Especificidad** x

Desempeño de un test diagnóstico

Sin gold standard

	Diagnóstico $= 1$	Diagnóstico $= 0$
Estado $= 1$	**Sensibilidad** s	$1 - s$
Estado $= 0$	$1 - x$	**Especificidad** x

¿Y si no observamos el estado de las personas?

Desempeño de un test diagnóstico

Sin gold standard

	Diagnóstico $= 1$	Diagnóstico $= 0$
Estado $= 1$	**Sensibilidad** s	$1 - s$
Estado $= 0$	$1 - x$	**Especificidad** x

¿Y si no observamos el estado de las personas?

Variables ocultas: el **estado**, la **prevalencia** p, la sensibilidad s y la especificidad x

Desempeño de un test diagnóstico

Sin gold standard

	Diagnóstico $= 1$	Diagnóstico $= 0$
Estado $= 1$	**Sensibilidad** s	$1 - s$
Estado $= 0$	$1 - x$	**Especificidad** x

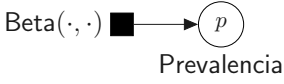
¿Y si no observamos el estado de las personas?

Variables ocultas: el **estado**, la **prevalencia** p, la sensibilidad s y la especificidad x

Bayesian Latent Class Analysis

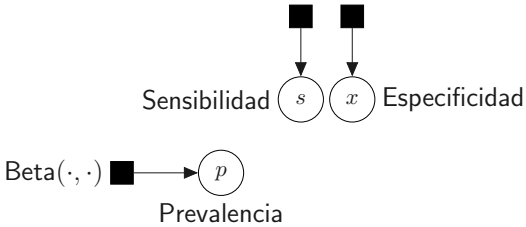
Modelo 0

Una población y un test



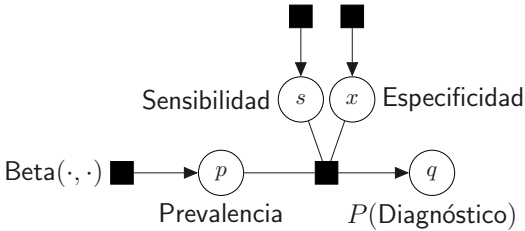
Modelo 0

Una población y un test



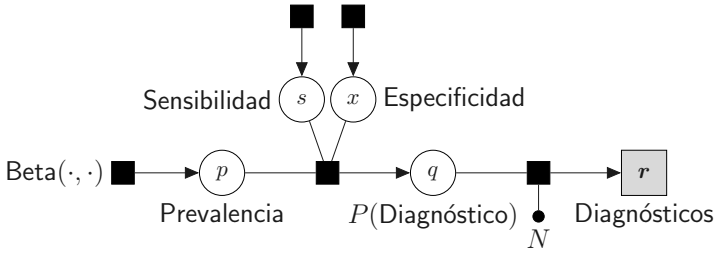
Modelo 0

Una población y un test



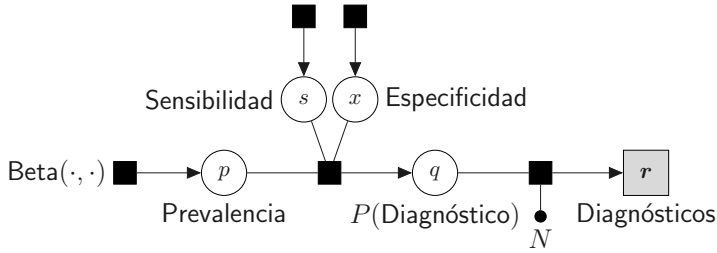
Modelo 0

Una población y un test



Modelo 0

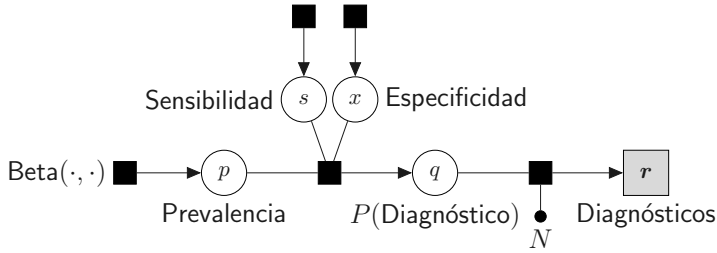
Una población y un test



$$q_1 = P(d=1) = \sum_e P(e)\, P(d=1|e)$$

Modelo 0

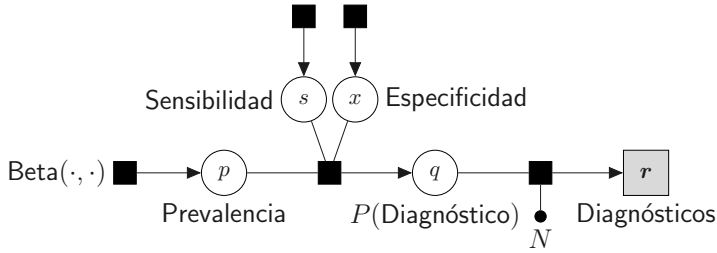
Una población y un test



$$q_1 = P(d=1) = \sum_e P(e)\, P(d=1|e) = p\, s + (1-p)\,(1-x)$$

Modelo 0

Una población y un test



$$q_1 = P(d=1) = \sum_e P(e)\,P(d=1|e) = p\,s + (1-p)\,(1-x)$$

¿Podemos recuperar p, s y x?

Modelo 0

No identificable

$$p = 0.5,\ s = 0.9,\ x = 0.9 \ \Rightarrow\ q_1 = 0.45 + 0.05 = 0.5$$

Modelo 0

No identificable

$$p = 0.5,\ s = 0.9,\ x = 0.9 \ \Rightarrow\ q_1 = 0.45 + 0.05 = 0.5$$
$$p = 0.5,\ s = 0.6,\ x = 0.6 \ \Rightarrow\ q_1 = 0.30 + 0.20 = 0.5$$

Modelo 0

No identificable

$$p = 0.5,\ s = 0.9,\ x = 0.9 \ \Rightarrow\ q_1 = 0.45 + 0.05 = 0.5$$
$$p = 0.5,\ s = 0.6,\ x = 0.6 \ \Rightarrow\ q_1 = 0.30 + 0.20 = 0.5$$
$$p = 0.25,\ s = 0.8,\ x = 0.6 \ \Rightarrow\ q_1 = 0.20 + 0.30 = 0.5$$

Modelo 0

No identificable

$$p = 0.5,\ s = 0.9,\ x = 0.9 \ \Rightarrow\ q_1 = 0.45 + 0.05 = 0.5$$
$$p = 0.5,\ s = 0.6,\ x = 0.6 \ \Rightarrow\ q_1 = 0.30 + 0.20 = 0.5$$
$$p = 0.25,\ s = 0.8,\ x = 0.6 \ \Rightarrow\ q_1 = 0.20 + 0.30 = 0.5$$

3 incógnitas (p, s, x) y 1 dato (q_1)

Modelo 0

No identificable

$$p = 0.5,\ s = 0.9,\ x = 0.9 \ \Rightarrow\ q_1 = 0.45 + 0.05 = 0.5$$
$$p = 0.5,\ s = 0.6,\ x = 0.6 \ \Rightarrow\ q_1 = 0.30 + 0.20 = 0.5$$
$$p = 0.25,\ s = 0.8,\ x = 0.6 \ \Rightarrow\ q_1 = 0.20 + 0.30 = 0.5$$

3 incógnitas (p, s, x) y 1 dato (q_1)

Más incógnitas que datos: no identificable

Modelo 1: Hui-Walter

Dos tests

$d_a\, d_b$	00	01	10	11
$\boldsymbol{r}$	n_{00}	n_{01}	n_{10}	n_{11}

Modelo 1: Hui-Walter

Dos tests

$d_a\, d_b$	00	01	10	11
$\boldsymbol{r}$	n_{00}	n_{01}	n_{10}	n_{11}

$$q_{00} = \sum_e P(e)\, P(d_a = 0, d_b = 0|e)$$

Modelo 1: Hui-Walter

Dos tests

$d_a\, d_b$	00	01	10	11
$\boldsymbol{r}$	n_{00}	n_{01}	n_{10}	n_{11}

$$q_{00} = \sum_e P(e)\, P(d_a = 0, d_b = 0|e)$$

$$\stackrel{*}{=} p\,(1 - s_a)\,(1 - s_b) + (1 - p)\,x_a\,x_b$$

Modelo 1: Hui-Walter

Dos tests

$d_a\, d_b$	00	01	10	11
$\boldsymbol{r}$	n_{00}	n_{01}	n_{10}	n_{11}

$$q_{00} = \sum_e P(e)\, P(d_a = 0, d_b = 0|e)$$

$$\stackrel{*}{=} p\,(1 - s_a)\,(1 - s_b) + (1 - p)\,x_a\,x_b$$

* Independencia condicional: $P(d_a, d_b|e) = P(d_a|e)\, P(d_b|e)$

Modelo 1: Hui-Walter

Dos tests

$d_a\, d_b$	00	01	10	11
$\boldsymbol{r}$	n_{00}	n_{01}	n_{10}	n_{11}

$$q_{00} = \sum_e P(e)\, P(d_a = 0, d_b = 0|e)$$

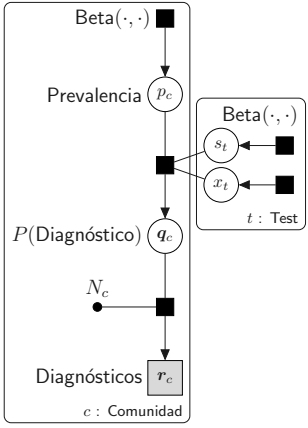
$$\stackrel{*}{=} p\,(1 - s_a)\,(1 - s_b) + (1 - p)\,x_a\,x_b$$

* Independencia condicional: $P(d_a, d_b|e) = P(d_a|e)\, P(d_b|e)$

$$P(\boldsymbol{r}|\boldsymbol{q}, N) = \text{Multinomial}(\boldsymbol{r}|\boldsymbol{q}, N)$$

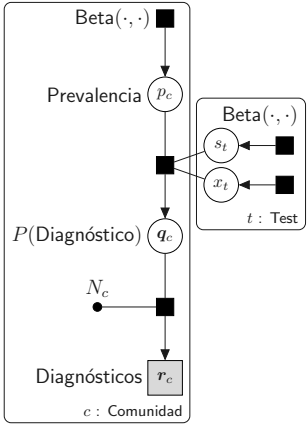
Modelo 1: Hui-Walter

Varias poblaciones



Modelo 1: Hui-Walter

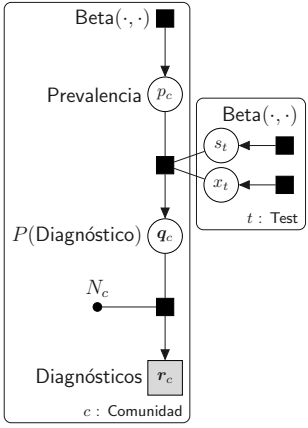
Varias poblaciones



- Por comunidad, 4 conteos que suman N_c: **3 datos**.

Modelo 1: Hui-Walter

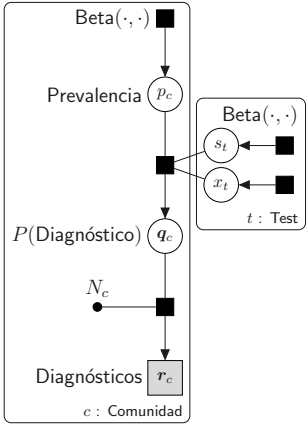
Varias poblaciones



- Por comunidad, 4 conteos que suman N_c: **3 datos**.
- Con 2 comunidades: **6 datos**.

Modelo 1: Hui-Walter

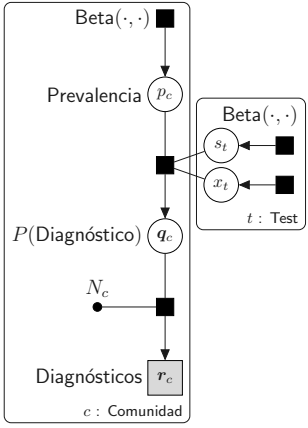
Varias poblaciones



- Por comunidad, 4 conteos que suman N_c: **3 datos**.
- Con 2 comunidades: **6 datos**.
- Incógnitas: p_1, p_2, s_a, s_b, x_a, x_b: **6**.

Modelo 1: Hui-Walter

Varias poblaciones



- Por comunidad, 4 conteos que suman N_c: **3 datos**.
- Con 2 comunidades: **6 datos**.
- Incógnitas: p_1, p_2, s_a, s_b, x_a, x_b: **6**.

Identificable

Modelo 1: Hui-Walter

Dependencia condicional

¿Y si dos tests detectan **lo mismo**?

Modelo 1: Hui-Walter
Dependencia condicional

¿Y si dos tests detectan **lo mismo**?

$$P(d_a, d_b|e) \neq P(d_a|e)\, P(d_b|e)$$

Modelo 1: Hui-Walter

Dependencia condicional

¿Y si dos tests detectan **lo mismo**?

$$P(d_a, d_b|e) \neq P(d_a|e)\, P(d_b|e)$$

El mismo antígeno, la misma muestra, el mismo laboratorio

Modelo 1: Hui-Walter

Dependencia condicional

¿Y si dos tests detectan **lo mismo**?

$$P(d_a, d_b|e) \neq P(d_a|e)\, P(d_b|e)$$

El mismo antígeno, la misma muestra, el mismo laboratorio

Hui-Walter **sobreestima** los desempeños

Covarianza

Variables binarias

$$\mathsf{cov}(X, Y) = \mathbb{E}[X\,Y] - \mathbb{E}[X]\,\mathbb{E}[Y]$$

Covarianza

Variables binarias

$$\mathsf{cov}(X, Y) = \mathbb{E}[X\,Y] - \mathbb{E}[X]\,\mathbb{E}[Y]$$

$$\mathbb{E}[X\,Y] = \sum_{x,y} P(x, y)\,x\,y = P(x = 1, y = 1)$$

Covarianza

Variables binarias

$$\mathsf{cov}(X, Y) = \mathbb{E}[X\,Y] - \mathbb{E}[X]\,\mathbb{E}[Y]$$

$$\mathbb{E}[X\,Y] = \sum_{x,y} P(x, y)\,x\,y = P(x = 1, y = 1)$$

$$\mathbb{E}[X] = \sum_{x} P(x)\,x = P(x = 1)$$

Covarianza

Variables binarias

$$\mathsf{cov}(X, Y) = \mathbb{E}[X\,Y] - \mathbb{E}[X]\,\mathbb{E}[Y]$$

$$\mathbb{E}[X\,Y] = \sum_{x,y} P(x, y)\,x\,y = P(x = 1, y = 1)$$

$$\mathbb{E}[X] = \sum_{x} P(x)\,x = P(x = 1)$$

$$\mathsf{cov}(X, Y) = P(x = 1, y = 1) - P(x = 1)\,P(y = 1)$$

Covarianza

Variables binarias

$$\mathsf{cov}(X, Y) = \mathbb{E}[X\,Y] - \mathbb{E}[X]\,\mathbb{E}[Y]$$

$$\mathbb{E}[X\,Y] = \sum_{x,y} P(x, y)\,x\,y = P(x = 1, y = 1)$$

$$\mathbb{E}[X] = \sum_{x} P(x)\,x = P(x = 1)$$

$$\mathsf{cov}(X, Y) = P(x = 1, y = 1) - P(x = 1)\,P(y = 1)$$

$$P(x = 1, y = 1) = P(x = 1)\,P(y = 1) + \mathsf{cov}(X, Y)$$

Covarianza

Reconstrucción de la conjunta

	$x = 0$	$x = 1$	
$y = 0$			$1 - P_y$
$y = 1$			P_y
	$1 - P_x$	P_x	1

Covarianza

Reconstrucción de la conjunta

	$x = 0$	$x = 1$	
$y = 0$			$1 - P_y$
$y = 1$		$P_x P_y + c$	P_y
	$1 - P_x$	P_x	1

Covarianza

Reconstrucción de la conjunta

	$x = 0$	$x = 1$	
$y = 0$			$1 - P_y$
$y = 1$	$(1 - P_x)P_y - c$	$P_x P_y + c$	P_y
	$1 - P_x$	P_x	1

Covarianza

Reconstrucción de la conjunta

	$x = 0$	$x = 1$	
$y = 0$		$P_x(1 - P_y) - c$	$1 - P_y$
$y = 1$	$(1 - P_x)P_y - c$	$P_xP_y + c$	P_y
	$1 - P_x$	P_x	1

Covarianza

Reconstrucción de la conjunta

	$x=0$	$x=1$	
$y=0$	$(1-P_x)(1-P_y)+c$	$P_x(1-P_y)-c$	$1-P_y$
$y=1$	$(1-P_x)P_y-c$	P_xP_y+c	P_y
	$1-P_x$	P_x	1

Covarianza

Reconstrucción de la conjunta

	$x=0$	$x=1$	
$y=0$	$(1-P_x)(1-P_y)+c$	$P_x(1-P_y)-c$	$1-P_y$
$y=1$	$(1-P_x)P_y-c$	P_xP_y+c	P_y
	$1-P_x$	P_x	1

Cada celda tiene que ser ≥ 0

Covarianza

Reconstrucción de la conjunta

	$x = 0$	$x = 1$	
$y = 0$	$(1 - P_x)(1 - P_y) + c$	$P_x(1 - P_y) - c$	$1 - P_y$
$y = 1$	$(1 - P_x)P_y - c$	$P_xP_y + c$	P_y
	$1 - P_x$	P_x	1

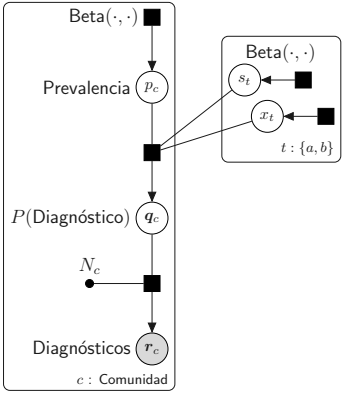
Cada celda tiene que ser ≥ 0

$$(P_x - 1)(1 - P_y) \leq c \leq \min(P_x, P_y) - P_xP_y$$

Cota inferior válida cuando $P_x, P_y > 0.5$, como la sensibilidad y la especificidad.

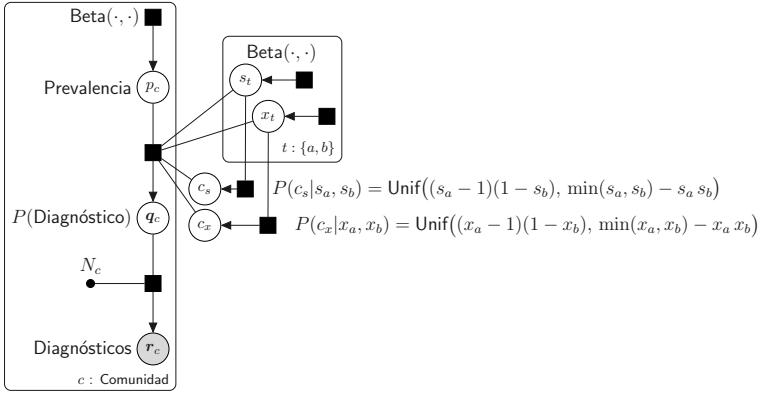
Modelo 2: Dendukuri

Con una covarianza



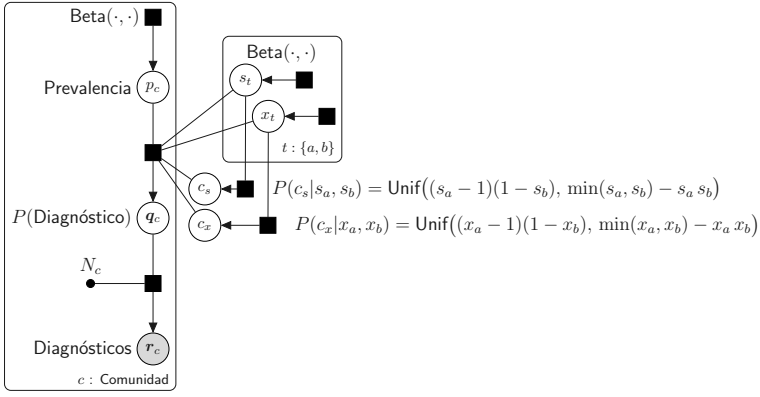
Modelo 2: Dendukuri

Con una covarianza



Modelo 2: Dendukuri

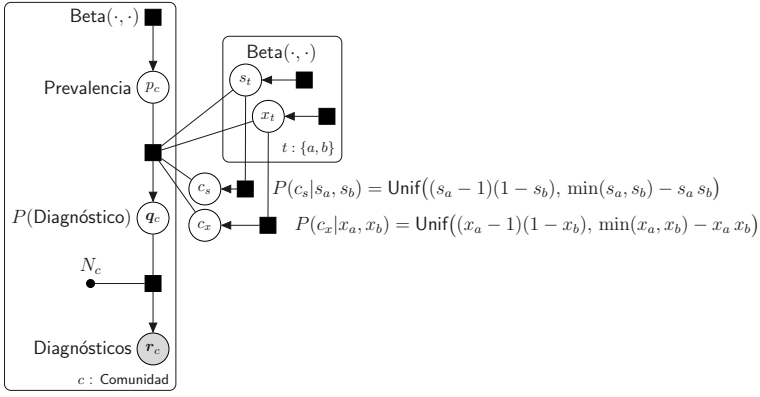
Con una covarianza



$$q_{11} = p\,(s_a\,s_b + c_s) + (1-p)\,\big((1-x_a)(1-x_b) + c_x\big)$$

Modelo 2: Dendukuri

Con una covarianza



$$q_{11} = p\,(s_a\,s_b + c_s) + (1-p)\,\big((1-x_a)(1-x_b) + c_x\big)$$

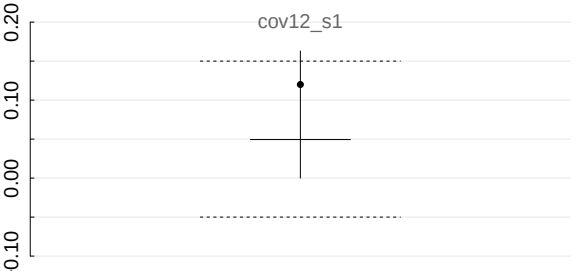
Una conjunta **con enfermedad** y otra **sin enfermedad**

Modelo 2: Dendukuri

Par de tests 1 y 2 (cov $= 0.12$)

$$s_1 = 0.80 \quad s_2 = 0.75 \quad s_3 = 0.70$$

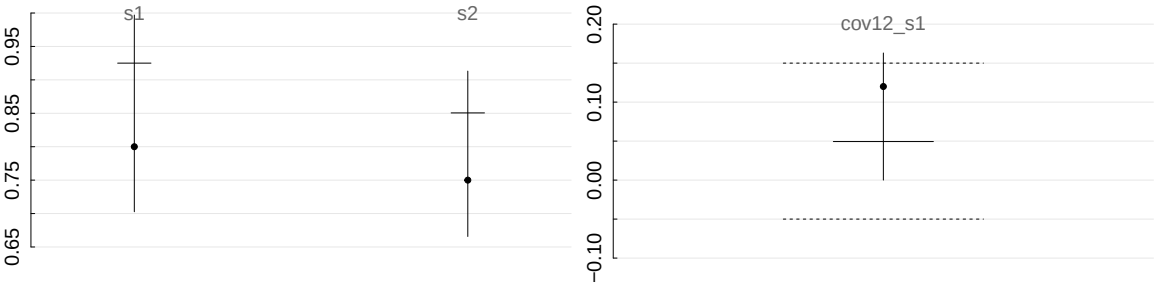




Modelo 2: Dendukuri

Par de tests 1 y 2 (cov $= 0.12$)

$s_1 = 0.80 \quad s_2 = 0.75 \quad s_3 = 0.70$

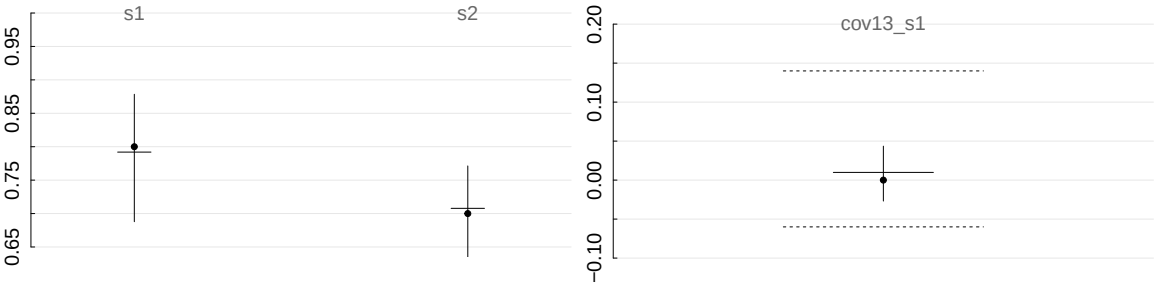


Punto: valor verdadero. Cruz: mediana e intervalo de credibilidad.

Modelo 2: Dendukuri

Par de tests 1 y 3 (cov $= 0$)

$$s_1 = 0.80 \quad s_2 = 0.75 \quad s_3 = 0.70$$

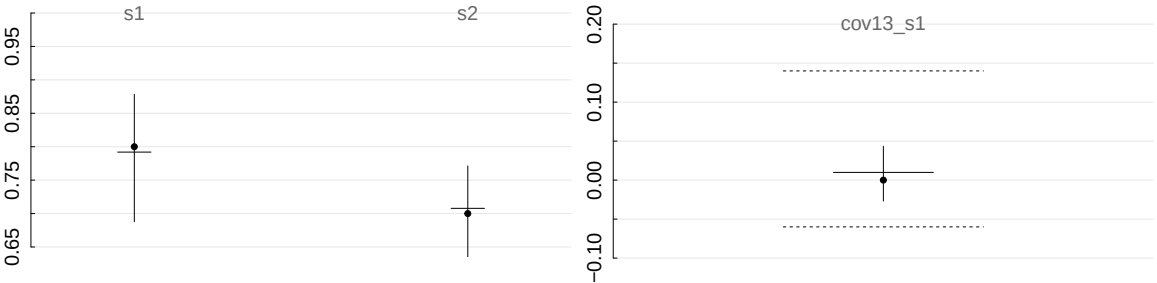


Punto: valor verdadero. Cruz: mediana e intervalo de credibilidad.

Modelo 2: Dendukuri

Par de tests 1 y 3 (cov $= 0$)

$$s_1 = 0.80 \quad s_2 = 0.75 \quad s_3 = 0.70$$



Punto: valor verdadero. Cruz: mediana e intervalo de credibilidad.

Los intervalos **contienen la verdad**

Modelo 3: Harmony

Red europea COST CA18208

La función `template_huiwalter()` del paquete `runjags` extiende Dendukuri a 3 tests

```
# Test1- Test2- Test3- en un enfermo
se_prob[1,p] <- prev[p] * ((1-se[1])*(1-se[2])*(1-se[3]) +covse12 +covse13 +covse23)
# Test1+ Test2- Test3- en un enfermo
se_prob[2,p] <- prev[p] * (se[1]*(1-se[2])*(1-se[3]) -covse12 -covse13 +covse23)
```

Modelo 3: Harmony

Red europea COST CA18208

La función `template_huiwalter()` del paquete `runjags` extiende Dendukuri a 3 tests

```
# Test1- Test2- Test3- en un enfermo
se_prob[1,p] <- prev[p] * ((1-se[1])*(1-se[2])*(1-se[3]) +covse12 +covse13 +covse23)
# Test1+ Test2- Test3- en un enfermo
se_prob[2,p] <- prev[p] * (se[1]*(1-se[2])*(1-se[3]) -covse12 -covse13 +covse23)
```

$$P\Big(\bigwedge_i X_i = v_i\Big) = \prod_i P(X_i = v_i) + \sum_{i<j} (-1)^{\mathbb{I}(v_i \neq v_j)} \,\mathsf{cov}(X_i, X_j)$$

Modelo 3: Harmony

Red europea COST CA18208

La función `template_huiwalter()` del paquete `runjags` extiende Dendukuri a 3 tests

```
# Test1- Test2- Test3- en un enfermo
se_prob[1,p] <- prev[p] * ((1-se[1])*(1-se[2])*(1-se[3]) +covse12 +covse13 +covse23)
# Test1+ Test2- Test3- en un enfermo
se_prob[2,p] <- prev[p] * (se[1]*(1-se[2])*(1-se[3]) -covse12 -covse13 +covse23)
```

$$P\Big(\bigwedge_i X_i = v_i\Big) = \prod_i P(X_i = v_i) + \sum_{i<j} (-1)^{\mathbb{I}(v_i \neq v_j)} \,\mathsf{cov}(X_i, X_j)$$

¿Es **correcta** esta extensión?

Modelo 3: Harmony

Grados de libertad

- $P(x, y, z)$: 8 celdas que suman 1, **7 grados de libertad**.

Modelo 3: Harmony

Grados de libertad

- $P(x, y, z)$: 8 celdas que suman 1, **7 grados de libertad**.
- Marginales y covarianzas: $3 + 3 =$ **6 datos**.

Modelo 3: Harmony

Grados de libertad

- $P(x, y, z)$: 8 celdas que suman 1, **7 grados de libertad**.
- Marginales y covarianzas: $3 + 3 =$ **6 datos**.

Infinitas conjuntas compatibles

Modelo 3: Harmony

Grados de libertad

- $P(x, y, z)$: 8 celdas que suman 1, **7 grados de libertad**.
- Marginales y covarianzas: $3 + 3 =$ **6 datos**.

Infinitas conjuntas compatibles

Esto dificulta identificar las variables ocultas,
pero **no prueba** que el modelo sea incorrecto

Modelo 3: Harmony

Marginalizar z

$$P(x = 1, y = 1) = P(1, 1, 0) + P(1, 1, 1)$$

Modelo 3: Harmony

Marginalizar z

$$
\begin{aligned}
P(x=1, y=1) &= P(1,1,0) + P(1,1,1) \\
&= P_x P_y (1 - P_z) + C_{xy} - C_{xz} - C_{yz} \\
&\quad + P_x P_y P_z + C_{xy} + C_{xz} + C_{yz}
\end{aligned}
$$

Modelo 3: Harmony

Marginalizar z

$$
\begin{aligned}
P(x=1, y=1) &= P(1,1,0) + P(1,1,1) \\
&= P_x P_y (1 - P_z) + C_{xy} \cancel{- C_{xz}} \cancel{- C_{yz}} \\
&\quad + P_x P_y P_z + C_{xy} \cancel{+ C_{xz}} \cancel{+ C_{yz}}
\end{aligned}
$$

Modelo 3: Harmony

Marginalizar z

$$
\begin{aligned}
P(x=1, y=1) &= P(1,1,0) + P(1,1,1) \\
&= P_x P_y (1 - P_z) + C_{xy} \cancel{- C_{xz}} \cancel{- C_{yz}} \\
&\quad + P_x P_y P_z + C_{xy} \cancel{+ C_{xz}} \cancel{+ C_{yz}} \\
&= P_x P_y + \mathbf{2}\, C_{xy}
\end{aligned}
$$

Modelo 3: Harmony

Marginalizar z

$$
\begin{aligned}
P(x=1, y=1) &= P(1,1,0) + P(1,1,1) \\
&= P_x P_y (1 - P_z) + C_{xy} - \cancel{C_{xz}} - \cancel{C_{yz}} \\
&\quad + P_x P_y P_z + C_{xy} + \cancel{C_{xz}} + \cancel{C_{yz}} \\
&= P_x P_y + \mathbf{2}\, C_{xy}
\end{aligned}
$$

Pero $P(x=1, y=1) = P_x P_y + C_{xy}$

Modelo 3: Harmony

Marginalizar z

$$
\begin{aligned}
P(x=1, y=1) &= P(1,1,0) + P(1,1,1) \\
&= P_x P_y (1 - P_z) + C_{xy} - C_{xz} - C_{yz} \\
&\quad + P_x P_y P_z + C_{xy} + C_{xz} + C_{yz} \\
&= P_x P_y + \mathbf{2}\, C_{xy}
\end{aligned}
$$

Pero $P(x=1, y=1) = P_x P_y + C_{xy}$

Ni siquiera respeta las marginales

Modelo 3: Harmony

Evaluación empírica

P_{xy0}	$x=0$	$x=1$
$y=0$	0.045	0.03
$y=1$	0.015	0.21

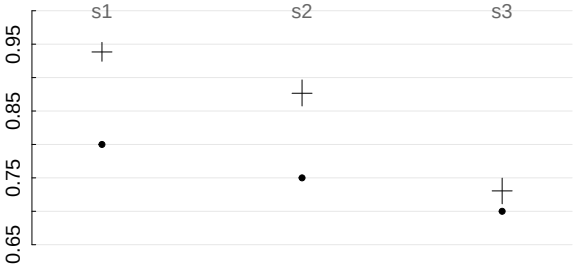
P_{xy1}	$x=0$	$x=1$
$y=0$	0.125	0.05
$y=1$	0.015	0.51

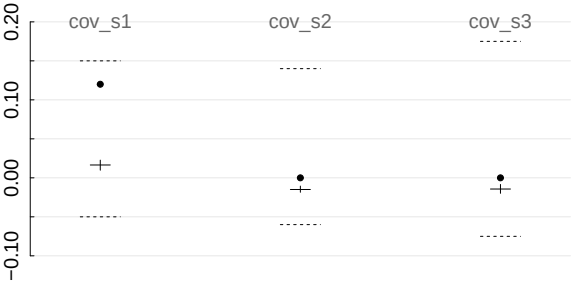
Conjunta de los diagnósticos en los enfermos, con $\text{cov}_{12} = 0.12$

4 comunidades, 3000 pacientes por comunidad

Modelo 3: Harmony

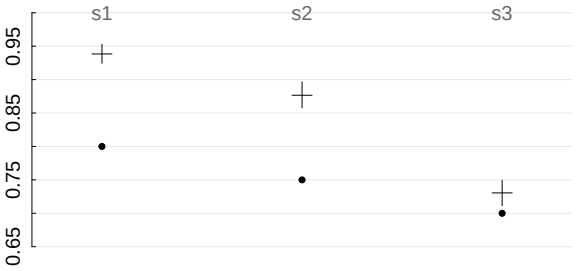
Evaluación empírica

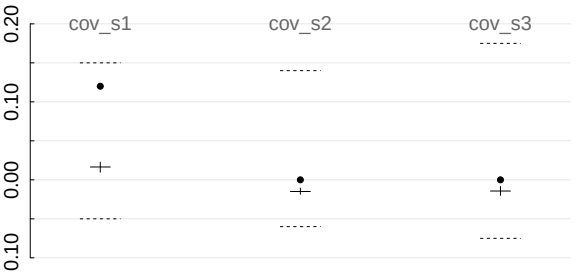




Modelo 3: Harmony

Evaluación empírica

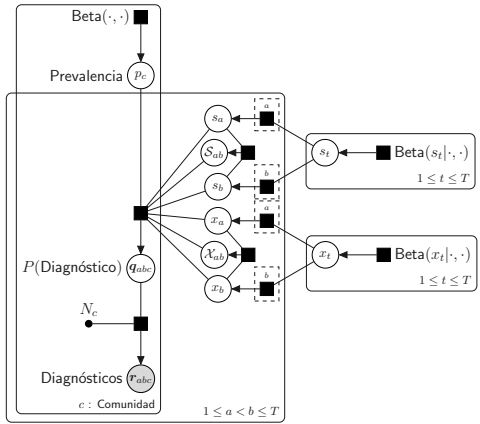




La verdad **queda afuera** de los intervalos

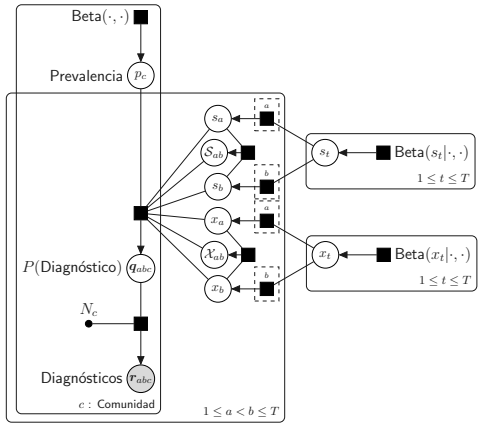
Modelo 4: Dendukuri para todos los pares

Un solo modelo



Modelo 4: Dendukuri para todos los pares

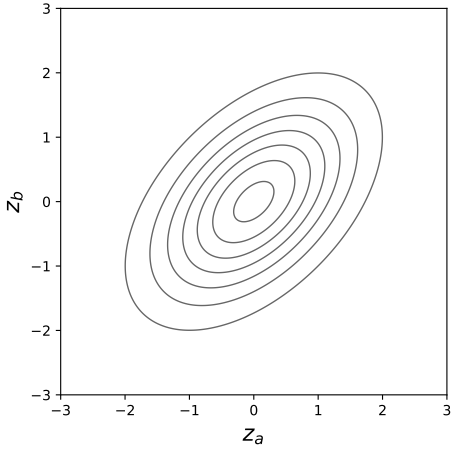
Un solo modelo



Desempeños **compartidos**, covarianzas **por par**

Simulación

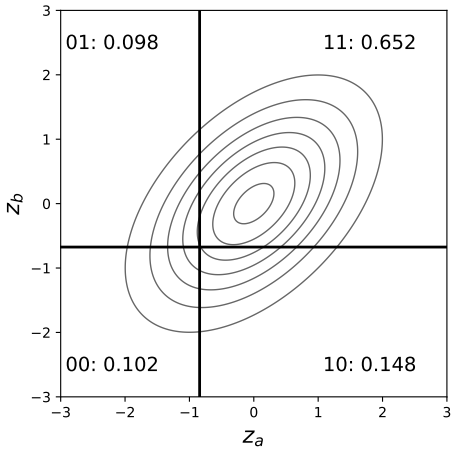
Cópula gaussiana



- $(z_a, z_b) \sim \mathcal{N}(\mathbf{0}, \Sigma)$, con correlación 0.5

Simulación

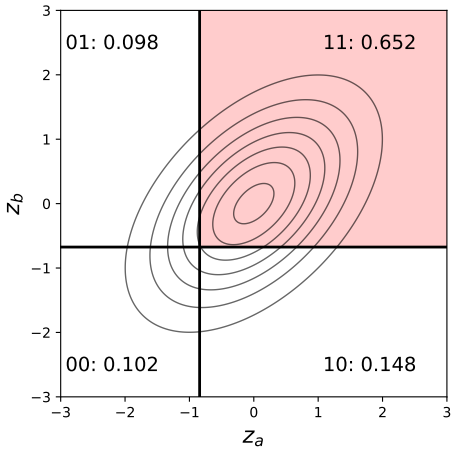
Cópula gaussiana



- $(z_a, z_b) \sim \mathcal{N}(\mathbf{0}, \Sigma)$, con correlación 0.5
- $d_a = \mathbb{I}(z_a > u_a)$, con $P(d_a = 1) = s_a = 0.80$

Simulación

Cópula gaussiana

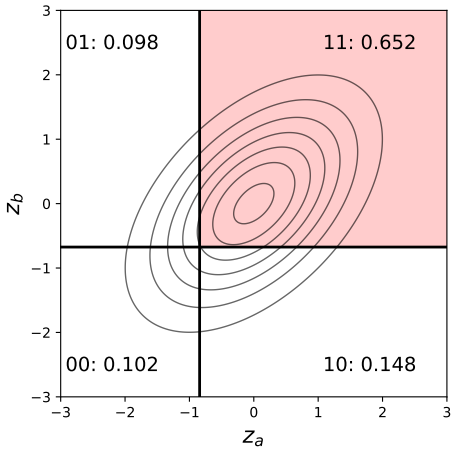


- $(z_a, z_b) \sim \mathcal{N}(\mathbf{0}, \Sigma)$, con correlación 0.5
- $d_a = \mathbb{I}(z_a > u_a)$, con $P(d_a = 1) = s_a = 0.80$
- $P(1,1) = 0.652$ y $s_a\, s_b = 0.6$

  $\Rightarrow$ cov $= 0.052$

Simulación

Cópula gaussiana



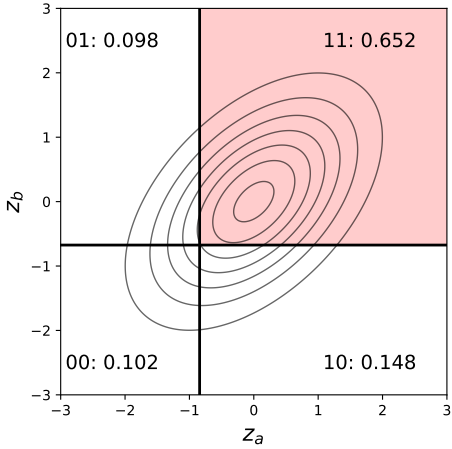
- $(z_a, z_b) \sim \mathcal{N}(\mathbf{0}, \Sigma)$, con correlación 0.5
- $d_a = \mathbb{I}(z_a > u_a)$, con $P(d_a = 1) = s_a = 0.80$
- $P(1,1) = 0.652$ y $s_a\, s_b = 0.6$

  $\Rightarrow$ cov $= 0.052$
- Correlación **latente** 0.5

  $\Rightarrow$ covarianza **binaria** 0.052

Simulación

Cópula gaussiana



- $(z_a, z_b) \sim \mathcal{N}(\mathbf{0}, \Sigma)$, con correlación 0.5
- $d_a = \mathbb{I}(z_a > u_a)$, con $P(d_a = 1) = s_a = 0.80$
- $P(1,1) = 0.652$ y $s_a\, s_b = 0.6$

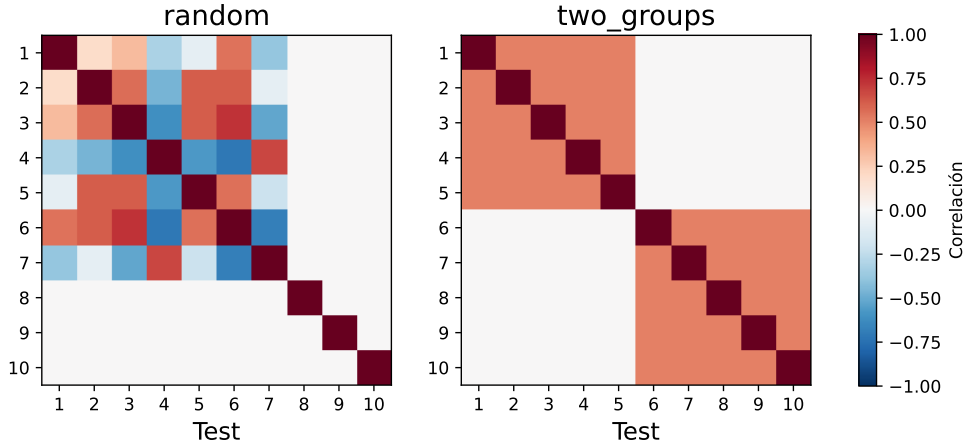
  $\Rightarrow$ cov $= 0.052$
- Correlación **latente** 0.5

  $\Rightarrow$ covarianza **binaria** 0.052

Covarianzas **compatibles** con una conjunta genuina

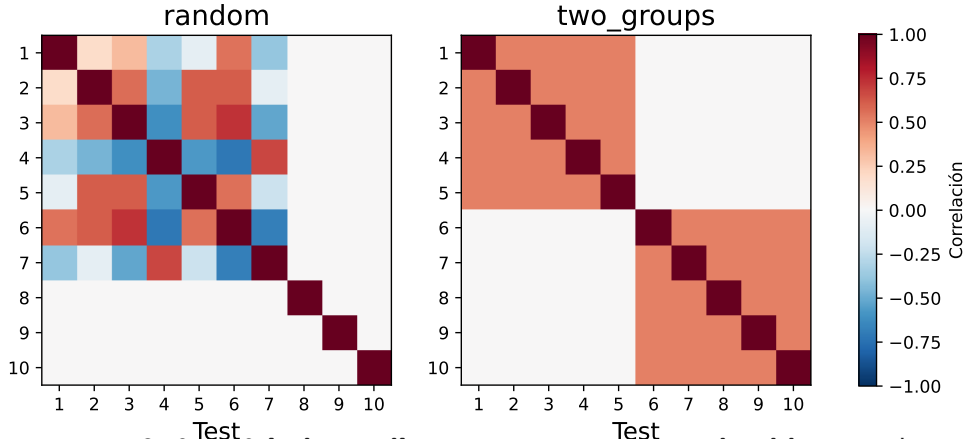
Escenarios simulados

10 tests, 5 comunidades, 3000 personas por comunidad



Escenarios simulados

10 tests, 5 comunidades, 3000 personas por comunidad



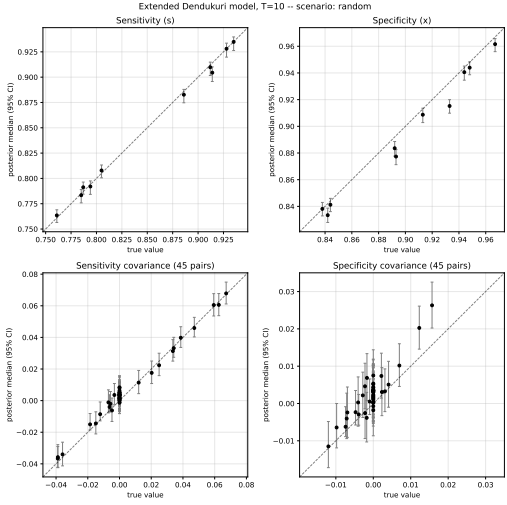
`random`: tests 8, 9 y 10 **independientes**. `two_groups`: **dos bloques** de 5 tests.

Modelo 4: resultados

Escenario `random`

Eje horizontal: valor verdadero.

Eje vertical: mediana e intervalo del 95%.

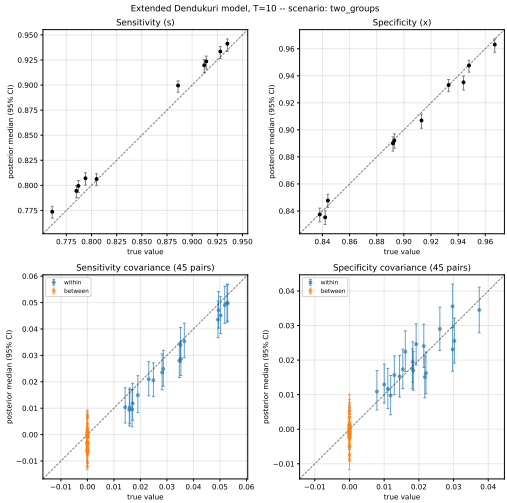


Modelo 4: resultados

Escenario `two_groups`

Eje horizontal: valor verdadero.

Eje vertical: mediana e intervalo del 95%.

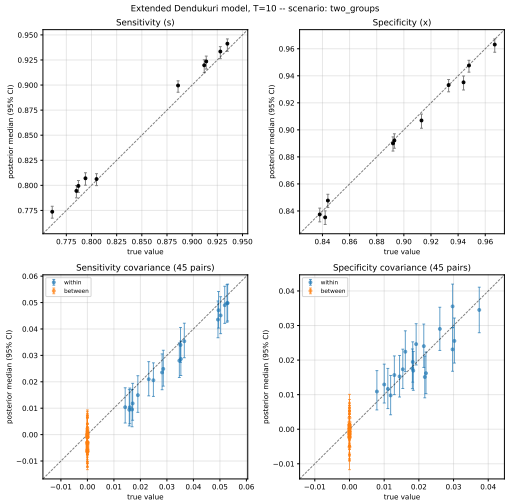


Modelo 4: resultados

Escenario `two_groups`

Eje horizontal: valor verdadero.

Eje vertical: mediana e intervalo del 95%.



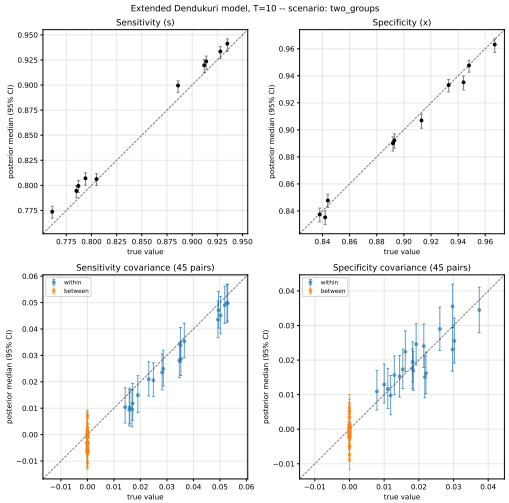
- Pares independientes **cerca de 0**.

Modelo 4: resultados

Escenario `two_groups`

Eje horizontal: valor verdadero.

Eje vertical: mediana e intervalo del 95%.



- Pares independientes **cerca de 0**.
- Intervalos **angostos**: cobertura imperfecta.

El modelo que genera los datos

Cópula gaussiana con clase latente

$$P(\boldsymbol{d}) = p\, P(\boldsymbol{d}|e=1) + (1-p)\, P(\boldsymbol{d}|e=0)$$

El modelo que genera los datos

Cópula gaussiana con clase latente

$$P(\boldsymbol{d}) = p\, P(\boldsymbol{d}|e=1) + (1-p)\, P(\boldsymbol{d}|e=0)$$

$$P(\boldsymbol{d}|e=1) = P(\boldsymbol{z} \in \text{ortante}(\boldsymbol{d})), \quad \boldsymbol{z} \sim \mathcal{N}(\mathbf{0}, C_s)$$

El modelo que genera los datos

Cópula gaussiana con clase latente

$$P(\boldsymbol{d}) = p\,P(\boldsymbol{d}|e=1) + (1-p)\,P(\boldsymbol{d}|e=0)$$

$$P(\boldsymbol{d}|e=1) = P(\boldsymbol{z} \in \text{ortante}(\boldsymbol{d})), \quad \boldsymbol{z} \sim \mathcal{N}(\mathbf{0}, C_s)$$

Probabilidad de un ortante: **sin solución analítica**

El modelo que genera los datos

Cópula gaussiana con clase latente

$$P(\boldsymbol{d}) = p\,P(\boldsymbol{d}|e=1) + (1-p)\,P(\boldsymbol{d}|e=0)$$

$$P(\boldsymbol{d}|e=1) = P(\boldsymbol{z} \in \text{ortante}(\boldsymbol{d})), \quad \boldsymbol{z} \sim \mathcal{N}(\mathbf{0}, C_s)$$

Probabilidad de un ortante: **sin solución analítica**

- Aproximarla (GHK) y muestrear con NUTS.

El modelo que genera los datos

Cópula gaussiana con clase latente

$$P(\boldsymbol{d}) = p\,P(\boldsymbol{d}|e=1) + (1-p)\,P(\boldsymbol{d}|e=0)$$

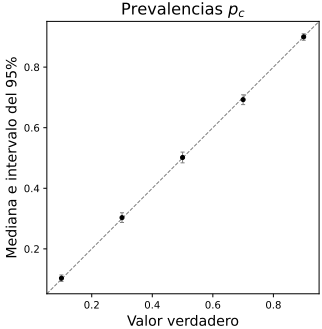
$$P(\boldsymbol{d}|e=1) = P(\boldsymbol{z} \in \text{ortante}(\boldsymbol{d})), \quad \boldsymbol{z} \sim \mathcal{N}(\mathbf{0}, C_s)$$

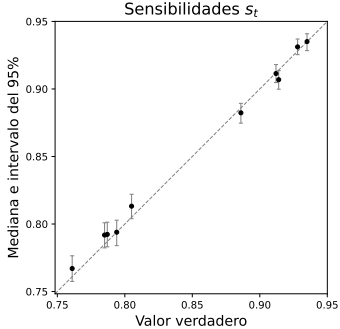
Probabilidad de un ortante: **sin solución analítica**

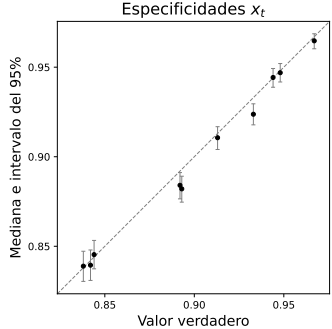
- Aproximarla (GHK) y muestrear con NUTS.
- Inferencia basada en simulaciones (SBI).

El modelo que genera los datos: resultados

NUTS en el escenario `random`

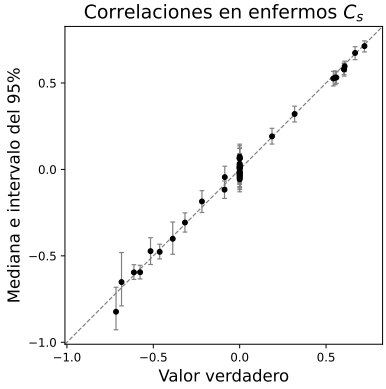


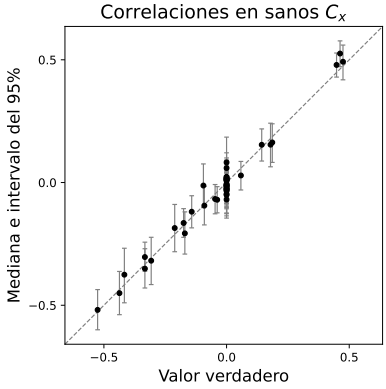




El modelo que genera los datos: resultados

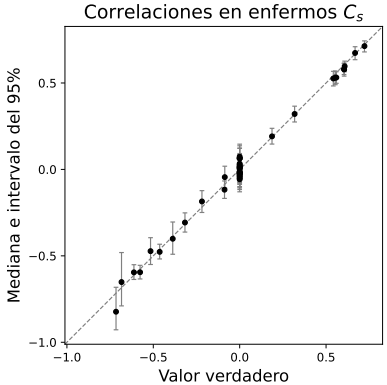
NUTS en el escenario `random`

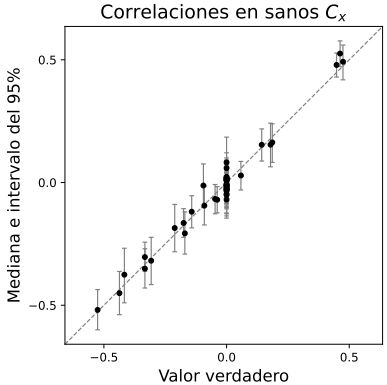




El modelo que genera los datos: resultados

NUTS en el escenario `random`





Recupera las **correlaciones latentes**: cobertura del 96% y 98%

Algoritmos de diagnóstico

Dos tests y uno de desempate

- Positivo si a y b dan positivo. Si no coinciden, **desempata** c.

Algoritmos de diagnóstico

Dos tests y uno de desempate

- Positivo si a y b dan positivo. Si no coinciden, **desempata** c.

$$P(\mathsf{Alg} = 1 | e = 1) = P(1, 1, \cdot) + P(1, 0, 1) + P(0, 1, 1)$$

Algoritmos de diagnóstico

Dos tests y uno de desempate

- Positivo si a y b dan positivo. Si no coinciden, **desempata** c.

$$P(\mathsf{Alg} = 1|e = 1) = P(1, 1, \cdot) + P(1, 0, 1) + P(0, 1, 1)$$

$$= P_{ab} + P_{ac} + P_{bc} - 2\,P_{abc}$$

Algoritmos de diagnóstico

Dos tests y uno de desempate

- Positivo si a y b dan positivo. Si no coinciden, **desempata** c.

$$P(\mathsf{Alg} = 1 | e = 1) = P(1, 1, \cdot) + P(1, 0, 1) + P(0, 1, 1)$$

$$= P_{ab} + P_{ac} + P_{bc} - 2\, P_{abc}$$

- P_{abc}: probabilidad de un **ortante** de $\mathcal{N}(\mathbf{0}, C_s)$ en 3 dimensiones, que se calcula exacta.

Algoritmos de diagnóstico

Dos tests y uno de desempate

- Positivo si a y b dan positivo. Si no coinciden, **desempata** c.

$$P(\mathsf{Alg} = 1 | e = 1) = P(1, 1, \cdot) + P(1, 0, 1) + P(0, 1, 1)$$

$$= P_{ab} + P_{ac} + P_{bc} - 2\, P_{abc}$$

- P_{abc}: probabilidad de un **ortante** de $\mathcal{N}(\mathbf{0}, C_s)$ en 3 dimensiones, que se calcula exacta.

- Especificidad: lo mismo con x_t y C_x.

Algoritmos de diagnóstico

Dos tests y uno de desempate

- Positivo si a y b dan positivo. Si no coinciden, **desempata** c.

$$P(\mathsf{Alg} = 1 | e = 1) = P(1, 1, \cdot) + P(1, 0, 1) + P(0, 1, 1)$$
$$= P_{ab} + P_{ac} + P_{bc} - 2\, P_{abc}$$

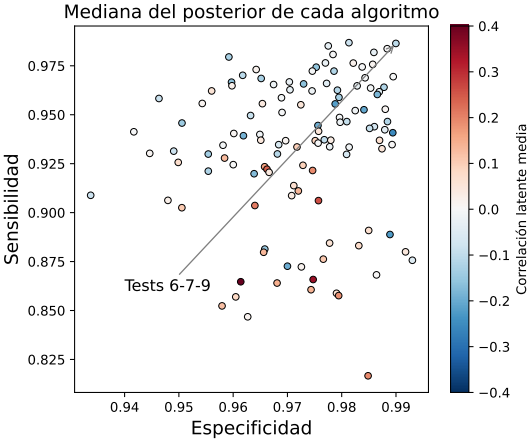
- P_{abc}: probabilidad de un **ortante** de $\mathcal{N}(\mathbf{0}, C_s)$ en 3 dimensiones, que se calcula exacta.

- Especificidad: lo mismo con x_t y C_x.

Es la **mayoría de tres**: el orden cambia el costo, no el desempeño

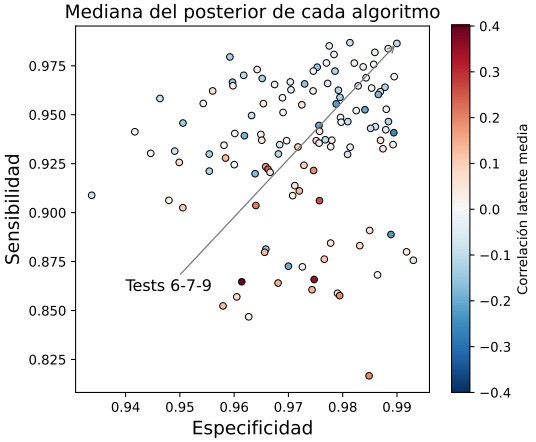
Ranking de algoritmos

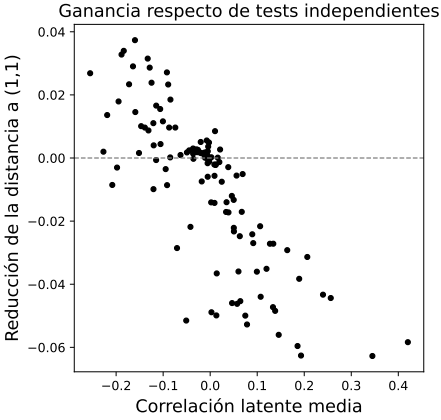
Los 120 algoritmos con el posterior de NUTS (`random`)



Ranking de algoritmos

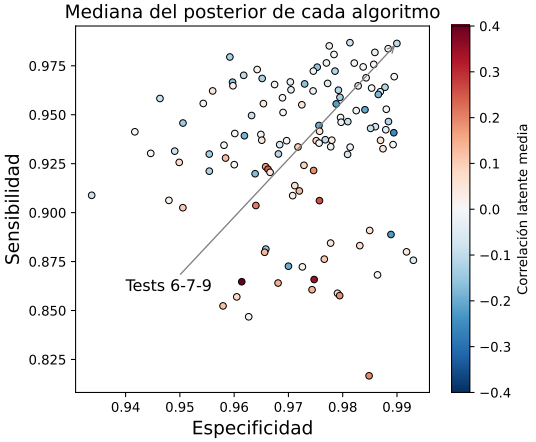
Los 120 algoritmos con el posterior de NUTS (`random`)

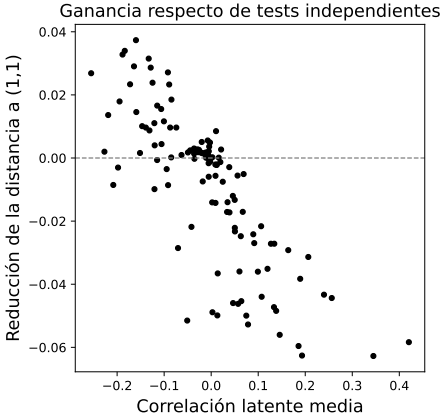




Ranking de algoritmos

Los 120 algoritmos con el posterior de NUTS (`random`)



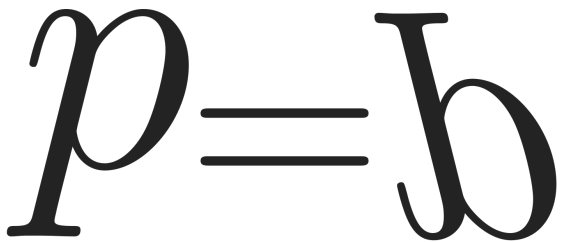


Los mejores combinan tests **poco correlacionados**

Práctica: modelos para casos reales

Los tres problemas de la clase (**Entrega 2.2**)

1. Significancia de los experimentos causales.
   a. Implementar el pasaje de mensajes y elegir λ por evidencia.
   b. Calcular $P(q_t > p_t|\text{Datos})$ mes a mes.
2. Datos escasos y contaminados.
   a. Especificar un modelo causal alternativo al de operadores.
   b. Opcional: implementarlo y compararlo con `comparacion_modelos.py`.
3. Tests diagnósticos sin gold standard.
   a. Implementar Hui-Walter, Dendukuri y Harmony con 3 tests.
   b. Implementar Dendukuri para todos los pares en `random` y `two_groups`.
   c. Opcional: el modelo que genera los datos o SBI.



Laboratorios de Métodos Bayesianos