

Inferencia Bayesiana Causal

IBC1.2026.2

Profesor: Gustavo Landfried

Ayudantes: Gerardo Toboso, Lucas Barreiro

1. Centro de Inteligencia Artificial Interdisciplinaria - UNSAM.

2. Laboratorios de Métodos Bayesianos

3. Bayes Plurinacional

Correspondencia: `glandfried@dc.uba.ar`

4 de agosto de 2026

Todas las ciencias con datos desarrollan argumentos causales para explicar y predecir el mundo. La evaluación de hipótesis causales atrae cada vez más el interés de las industrias, que necesitan medir el impacto real de sus acciones. La ventaja de los modelos causales radica en su capacidad predictiva, que se adapta naturalmente a los cambios del contexto como son las intervenciones humanas. Además sabemos que si los argumentos causales se corresponden con la realidad causal subyacente ningún modelo de inteligencia artificial, por más complejo que sea, puede mejorar su desempeño.

En este curso revisaremos los fundamentos de la evaluación de modelos causales alternativos M dado los datos D , $P(M|D)$, tanto con y sin intervenciones. Además revisaremos los métodos para hacer predicciones de las hipótesis H internas a los modelos M , $P(H|D, M)$, tanto para evaluar efectos causales out-of-sample como para predecir el impacto de acciones alternativas contrafactuales. Finalmente abordaremos el problema de tomar decisiones óptimas como un problema de inferencia en el que se revisa que ninguna de las decisiones contrafactuales alternativas mejoren el resultado de la variable objetivo.

Ante el vértigo de una IA plagada de herramientas efímeras, este curso prioriza los fundamentos inmutables. A pesar de todos los avances, desde el siglo 18 hasta ahora no se ha propuesto un nuevo sistema para razonar bajo incertidumbre. Si algún día las máquinas superan a los humanos, deberán hacer ciencia aplicando estrictamente las reglas de probabilidad para evaluar teorías causales. Para alcanzar verdades (intersubjetivas) en contextos de incertidumbre, simplemente hay que saber aplicar y preservar el principio universal de no mentir: no afirmar más de lo que se sabe, sin ocultar lo que sí se sabe. Así se obtienen las distribuciones de creencia óptima dada la información disponible, inmejorables en términos prácticos.

Al final siempre es bueno recordar que la verdadera inteligencia no es ni artificial ni humana, sino que está en todas las formas de vida que son capaces de sobrevivir en el tiempo. Especialmente las plantas que son 83 % de la biomasa, no molestan a nadie y dan vida.

Objetivos

Este curso está enfocado en la evaluación de argumentos causales alternativos mediante la (aproximación a) la aplicación estricta de las reglas de la probabilidad (enfoque bayesiano), el sistema de razonamiento en contextos de incertidumbre. El principal objetivo es revisar los métodos desarrollados en las últimas décadas para:

- **Modelos causales.** Especificar matemáticamente los argumentos causales expresados en lenguaje natural mediante métodos gráficos intuitivos
- **Flujo de inferencia.** Entender cuándo se abre y se cierra el flujo de inferencia en las estructuras causales, para separar la influencia espuria de la influencia causal.
- **Estimación de efectos causales.** Aplicar métodos de Aprendizaje Automático para identificar el efecto causal entre pares de variables a partir de datos observados sin intervenciones.
- **Predicciones contrafactuales.** Especificación de distribuciones de probabilidad conjunta entre factuales y contrafactuales, y razonamiento generativos de las consecuencias contrafactuales.
- **Toma de decisiones en el tiempo.** Seleccionar decisiones óptimas en ciclos de acción-percepción con una naturaleza oculta (simulada).

Sobre el docente

Gustavo Landfried es profesor de Inferencia Bayesiana Causal en la Escuela de Ciencia y Técnica de la Universidad Nacional de San Martín. Luego de obtener la licenciatura en Antropología Social, Gustavo se doctoró en Ciencias de la Computación por la Universidad de Buenos Aires bajo la supervisión de los directores del Laboratorio de Inteligencia Artificial Aplicada (Diego Slezak) y del Laboratorio interdisciplinarios de Cómputo de Alto Rendimiento (Esteban Mocsos). Allí se especializó en el análisis de habilidad de la industria del video juego, basado en métodos bayesianos, lo que lo llevo a desarrollar y mantener los paquetes estado-del-arte en Python, Julia y R (TrueSkill Through Time). Gustavo trabaja actualmente en la industria (Muttdata) como Data Scientist desarrollando proyectos de inferencia bayesiana e inferencia causal para grandes empresas transnacionales de América Latina. Además es cofundador y coordinador de la comunidad bayesplurinacional.org.



Unidades

1. Especificación y evaluación de argumentos causales.	3
1.1. Argumentos causales alternativos e incertidumbre.	3
1.2. Sorpresa: el problema de la comunicación con la realidad.	4

2. Métodos de inferencia y programación probabilística.	4
2.1. Inferencia exacta y pasaje de mensajes.	4
2.2. Olvido: hacer inferencia en la realidad compleja.	4
3. Predicciones causales.	5
3.1. Flujo de inferencia y eliminación de la influencia espuria.	5
3.2. Estimandos, Do-Calculus.	5
4. Inferencia causal en la práctica.	6
4.1. El zoológico de algoritmos.	6
4.2. El ecosistema de las teorías causales.	6
5. Contrafactuales y toma de decisiones.	6
5.1. El choque de los paradigmas de inferencia causal.	7
5.2. Toma de decisiones en el tiempo.	7
6. Intervenciones socioeconómicas	7
6.1. Instituciones exitosas en la administración de bienes comunes.	7
6.2. Instrumento financiero productivo	8
7. Bibliografía	8

Todas las sub-unidades tienen entregas y al finalizar toda una unidad se realiza una evaluación basada en multiple-choice con distribución de creencias.

1. Especificación y evaluación de argumentos causales.

Sistema de razonamiento en contextos de incertidumbre, especificación gráfica de argumentos causales y evaluación de modelos causales alternativos con y sin intervenciones.

1.1. Argumentos causales alternativos e incertidumbre.

Verdad y mentira. Acuerdos intersubjetivos: máxima incertidumbre dada la información disponible. Distribución de creencias honesta entre los universos paralelos de los argumentos causales. Preservación de la creencia previa compatible con el dato y predicción como suma de universos paralelos compatibles con lo que se quiere predecir. Sistema de razonamiento en contextos de incertidumbre: las reglas de la probabilidad. Métodos gráficos de especificación matemática de argumentos causales probabilísticos: redes bayesianas. Las propiedades básicas de los modelos gráficos: estructura, independencia y factorización. Medición de incertidumbre sobre espacio de hipótesis internas a los modelos, $P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$. La evaluación de argumentos causales alternativos en datos observados sin intervenciones, $P(\text{Modelo}|\text{Datos})$. La evidencia, $P(\text{Datos}|\text{Modelo})$, y sus transformaciones (media geométrica y logaritmo).

Entrega 1.1: Especificación y evaluación de modelos Monty Hall y Base.

Bibliografía teórica 1.1: Capítulos 2 y 3 (hasta el final de la sección 3.2) de libro de Daphne Koller (2009) *Probabilistic Graphical Models* [3].

Bibliografía práctica 1.1: Capítulo 2 del libro de McElreath (2020) *Statistical rethinking* [8] y capítulo 2 del libro de Winn (2023) *Model Based Machine Learning* [9].

1.2. Sorpresa: el problema de la comunicación con la realidad.

Los elementos fundamentales del sistema de razonamiento bajo incertidumbre (axiomas de Kolmogorov y Rényi). La estructura invariante del dato empírico. Su isomorfismo con los sistemas de comunicación con la realidad. La sorpresa como fuente de información. La equivalencia entre la media geométrica de la predicción, $P(\text{Datos}|\text{Modelo})$ y la entropía cruzada. La ventaja de los modelos causales que se corresponden con la realidad causal subyacente. La definición matemática del principio de no-mentir: máxima entropía dada información disponible. Especificación de modelos causales para contextos con datos corrompidos. Mecanismos causales adaptativos al contexto: do-operator y gates. Especificación de argumentos causales mediante factor graphs. Identificación de modelos causales con y sin intervenciones. Evaluación de procedimientos alternativos de medición.

Entrega 1.2: Especificación y evaluación de modelo Monty Hall con datos corrompidos.

Bibliografía teórica 1.2: Secciones 1.1, 2.4-6, 4.1 del libro de MacKay (2003) *Information theory, inference and learning algorithms* [4].

Bibliografía práctica 1.2: Capítulo 3 y 10 del libro de McElreath (2020) *Statistical rethinking* [8].

2. Métodos de inferencia y programación probabilística.

Métodos de inferencia exacta a través de pasaje de mensajes entre los nodos de la red causal e inferencia aproximada analítica y por sorteo a través de lenguajes de programación probabilística.

2.1. Inferencia exacta y pasaje de mensajes.

Inferencia exacta. El algoritmo de eliminación de variables. Descomposición de las reglas de la probabilidad como mensajes que se envían entre sí los nodos de las redes causales: algoritmo suma-producto. El caso del modelo Monty Hall extendido. Distribuciones conjugadas. Modelo Beta-Bernoulli y sus aplicaciones en medicina y marketing. Modelo gaussianos unidimensionales y la solución exacta al modelo de estimación de habilidad. Modelo gaussianos multidimensionales: posterior y evidencia. Regresión lineal bayesiana. Selección arbitraria de hipótesis mediante máxima verosimilitud. Interpretación de los parámetros estimados bajo realidades causales conocidas. Evaluación de modelos lineales de complejidad creciente. La ausencia de overfitting mediante la aplicación estricta de las reglas de la probabilidad. Predicción basada en ensambles de modelos, $P(\text{Datos})$.

Entrega 2.1: Evaluación de modelos lineales de complejidad creciente.

2.2. Olvido: hacer inferencia en la realidad compleja.

Métodos analíticos de aproximación. Divergencia KL e inferencia aproximada por expectation propagation. El caso de la estimación de habilidad en la industria del video juego. Divergencia KL invertida e inferencia aproximada por variational inference. El caso de la versión bayesiana del sistema de recomendación ganador de la competencia de Netflix. El lenguaje de programación probabilística `pyro`. Métodos de aproximación por sorteo. Inferencia aproximada por Monte Carlo: metropolis-hasting, Hamiltonian Monte Carlo y Sequential

Monte Carlo. Lenguajes de programación probabilística `pymc`, `stan`, `turinglang`. El caso de la evaluación de instrumentos alternativos de medición, y el p-valor bayesiano. Métodos generativos de aproximación. Computación Bayesiana Aproximada (ABC): inferencia libre de verosimilitud mediante estadísticos de resumen y métricas de distancia. Métodos actuales de estimación de la distribución conjunta mediante redes neuronales a partir de datos simulados (SBI) e inferencia eficiente.

Entrega 2.2: Implementación de metropolis Hasting: el agricultor desmemoriado.

3. Predicciones causales.

Eliminación de la influencia espuria de las predicciones y los pasos de la inferencia causal: 1) especificación de la estructura causal, 2) identificación del estimando, 3) estimación del efecto causal.

3.1. Flujo de inferencia y eliminación de la influencia espuria.

Flujo de inferencia en redes causales. Apertura y cierre de flujo de inferencia en las estructuras básicas: pipe, fork y collider. Apertura y cierre del flujo de inferencia en caminos de cualquier longitud: d-separation. Eliminación de influencia espuria de las predicciones: controles backdoor. Buenos y malos controles. Controles neutrales y efectos causales heterogéneos. Uso de la regresión lineal para estimación de efectos causales no lineales. Interpretación de los coeficientes estimados. The Table 2 Fallacy. Los pasos de la inferencia causal: 1) especificación de la estructura causal, 2) identificación del estimando, 3) estimación del efecto causal. Descubrimiento de estructuras causales compatibles con las distribuciones de probabilidad conjunta estimadas de los datos.

Entrega 3.1 Predicciones causales en diversas realidades causales subyacentes.

3.2. Estimandos, Do-Calculus.

El estimando del efecto causal general: adjustment formula y propensity score. La característica fundamental de los experimentos aleatorizados: independencia entre el tratamiento y sus resultados potenciales contrafactuales. La analogía “ignorabilidad condicional” como criterio para seleccionar variables de control en el enfoque previo de inferencia causal basado en resultados potenciales contrafactuales. Estimando del efectos causales bajo ignorabilidad condicional y consistencia determinista. Las 3 reglas del Do-calculus: Regla 1, Ignorar una observación; Regla 2, Intervención como observación; Regla 3. Ignorar una intervención. Estimando alternativo en casos de que haya controles ocultos: frontdoor formula. Estimando alternativo cuando fallan los experimentos aleatorios: instrumental variables.

Entrega 3.2. Estimación de efectos causales: general, frontdoor e instrumentales.

Evaluación parcial

4. Inferencia causal en la práctica.

De las primeras estrategias hasta los modelos de aprendizaje supervisado de última generación con probada capacidad para la estimación de efectos causales heterogéneos en

contextos de alta dimensionalidad.

4.1. El zoológico de algoritmos.

Métodos tradicionales de estimación de efectos: Matching, Propensity Score e Inverse Probability Weighting (IPW). La solución del Causal Machine Learning (CausalML): algoritmos de alta capacidad predictiva para estimar efectos causales heterogéneos (CATE). El ecosistema de inferencia causal en Python: DoWhy, EconML y CausalML. El concepto de Meta-Learners (estrategias generales): S-Learner y T-Learner. El impacto de la falta de “positividad” en las predicciones causales. Las competencias de inferencia causal de la Atlantic Causal Inference Conference. El problema de la regularización en la estimación del efecto causal y la estrategia de estimación bajo modelos parcialmente lineales: Doubly Machine Learning. Algoritmos basados en ensambles de árboles: Causal Forest y Bayesian Causal Forest. El problema de los intervalos de confianza en las competencias de datos y posibles soluciones. Los límites de la estimación de efectos causales entre pares de variables: ejemplos reales.

Entrega 4.1. Predicciones causales bajo diferentes grados de positividad y competencia de inferencia causal ACIC 2022.

4.2. El ecosistema de las teorías causales.

Inferencia causal mediante teorías causales basadas en el conocimiento experto. Primer ejemplo: la solución de Google para la medición del impacto de las inversiones publicitarias sobre las ventas. Especificación completa del modelo causal en base a conceptos relevantes en el proceso de Marketing: arrastre, saturación, geografía, estacionalidad, factores externos. La estrategia para medir el impacto causal y predecir contrafactuales. Segundo ejemplo: evaluación de procedimientos alternativos de detección de enfermedades raras (sin test de referencia) y creación de protocolos de medición internacionales. Especificación de los modelos clásicos (Hui-Walter, Dendukuri) en base a conceptos claves en el procedimiento de generación de los datos observados: la prevalencia, el estado infeccioso oculto, la sensibilidad y especificidad de los test, la correlación, y el diagnóstico. Simulación de datos sintéticos con correlaciones y filtro imperfecto de las muestras. El error del consorcio europeo y la generalizaciones de los modelos clásicos. Predicción contrafactual del desempeño del protocolo propuesto.

Entrega 4.2. Desarrollo de protocolo para el diagnóstico de Chagas en América latina.

5. Contrafactuales y toma de decisiones.

Especificación de modelos con contrafactuales, equivalencia entre enfoques de inferencia causal, y descomposición de efectos totales en efectos naturales directo e indirecto mediante mediation formula.

5.1. El choque de los paradigmas de inferencia causal.

La escalera del razonamiento causal. La especificación de modelos causales con contrafactuales: Twin Networks. Predicción de contrafactuales usando la información factual, el ejemplo del Monty Hall. Las restricciones actuales de los paradigmas de inferencia causal (Structural Causal Models, SCM): una variable exógena por cada variable endógena, independientes entre variables exógenas y determinismo de las variables endógenas. El propuesta

de contraejemplo de Pearl y la correcta respuesta de Robins. Las herramientas actuales de evaluación de la equivalencia entre los paradigmas de inferencia causal: merged Twin Networks y Single World Intervention Graphs (SWIGs). Generalización de ambos paradigmas mediante la eliminación del determinismo de las variables endógenas: consistencia probabilística y ruptura de la SWIGs. La Twin Networks Generativas como herramienta valida de evaluación. Generalización del paradigma Estructural mediante la eliminación del requerimiento que haya una variable exógena por cada variable endógena y contraejemplo al paradigma de Resultados Potenciales bajo una redes bayesiana causal completa simple.

Entrega 5.1. Uso de Twin Networks Generativas para predecir valores contrafactuales usando información factual.

5.2. Toma de decisiones en el tiempo.

Sistemas de interacción con la realidad: acción-percepción. La teoría de utilidad esperada de Von Neumann. La crítica de John L. Kelly a Von Neumann. Juegos de apuestas. La equivalencia estructural entre los juegos de apuestas, la evaluación de hipótesis en probabilidad y la selección de formas de vida en evolución. La ventaja de la diversificación individual (entropía negativa). Las propiedades emergentes de las formas de la materia y la ventaja de la reducción de fluctuaciones por cooperación. La falacia del dilema del prisionero y la tragedia de los comunes. La ventaja de la especialización cooperativa. El criterio Kelly: cooperar con uno mismo. Fractional Kelly. La corrección temporal de la teoría de toma de decisiones: teoría de utilidad ergódica. Predicción por máxima incertidumbre y selección de acciones por mínima incertidumbre. Decisión factual óptima como ausencia de alternativas contrafactuales superiores.

Entrega 5.2: Simulación de los diferentes escenarios del juego de apuestas.

6. Intervenciones socioeconómicas

Historia del giro colonial-moderno, gobernanza de los bienes comunes, análisis de casos actuales, diseño de instrumento financiero-productivo en todos sus niveles (ahorro, ordenamiento territorial, servicios básicos, acceso a la vivienda, reproducción del ciclo).

6.1. Instituciones exitosas en la administración de bienes comunes.

El desarrollo de la cultura y la agricultura. Los 6 centros de innovación de la humanidad. El giro colonial-moderno: pandemia feudal, plata americana, y tecnología china. Deficit comercial de europa y las guerras del opio. La era de los genocidios y la pérdida de diversidad cultural. La profundización de la crisis ecológica actual y la incapacidad de la ciencia metropolitana moderna para resolverlo. Las características de los sistemas institucionales exitosos en la administración de los bienes comunes. Egipto, distribución de la tierra, productividad agrícola, densidad poblacional y dinámica demográfica. Argentina, distribución de la tierra, productividad agrícola, densidad poblacional y dinámica demográfica.

Entrega 6.1: Reporte: análisis sobre los datos de Argentina y Egipto; estimaciones, conclusiones y propuestas de acción.

6.2. Instrumento financiero productivo

Sistemas financieros-productivos en la Argentina actual: tasa de interés, riesgo y liquidez. Fuente de valor real: el agua, la tierra y la vida. Instrumento financiero de ahorro-productivo pool de siembra basado en agricultura intensiva y urbanización de la ruralidad. Los tres actores del sistema: ahorristas, habitantes y administración. Ahorro basado en pools de compra de tierra rural (bloques de más de 100 ha), y tasa de interés acorde al valor del alquiler rural. Ordenamiento general de la tierra: caminos, vivienda, agricultura de quintas, y espacios comunes. Ordenamiento específico de los sectores y tamaño mínimo de las zona rural (quintas de 2000m²) y de las viviendas (250m²). Desarrollo de servicios básicos: agua, cloaca, cimientos y área común. Los requisitos de los habitantes para adquirir la propiedad: costo total y tiempos para la cancelación de la deuda. El ciclo completo para la reproducción del proceso. Capacidades y velocidad estimada de crecimiento potencial.

Entrega 6.2: Redacción del reporte técnico y el resumen ejecutivo del instrumento financiero productivo.

Evaluación final

7. Bibliografía

Fundamentos

- [1] Bishop, C.M. *Pattern Recognition and Machine Learning*. Springer (2006)
- [2] Jaynes, E.T. *Probability Theory: The Logic of Science*. Cambridge University Press (2003)
- [3] Koller, D., Friedman, N. *Probabilistic Graphical Models: Principles and Techniques*. MIT press (2009)
- [4] MacKay, D.J. *Information Theory, Inference and Learning Algorithms*. Cambridge University Press (2003)
- [5] Pearl, J. *Causality*. Cambridge University Press (2009)
- [6] Pearl, J., Mackenzie, D. *The Book of Why*. Basic books (2018)
- [7] Peters, J., Janzing, D., Schölkopf, B. *Elements of Causal Inference: Foundations and Learning Algorithms*. The MIT Press (2017)

Práctica

- [8] McElreath, R. *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. CRC Press (2020)
- [9] Winn, J., Bishop, C.M., Diethe, T., Zaykov, Y. *Model-Based Machine Learning* (2023)

Lenguajes de programación probabilística

- [10] Bingham, E., Chen, J.P., Jankowiak, M., Obermeyer, F., Pradhan, N., Karaletsos, T., Singh, R., Szerlip, P., Horsfall, P., Goodman, N.D. *Pyro: Deep universal probabilistic programming*. Journal of Machine Learning Research 20(28), 1–6 (2019), <https://pyro.ai/>
- [11] Fjelde, T.E., Xu, K., Widmann, D., Tarek, M., Pfiffer, C., Trapp, M., Axen, S.D., Sun, X., Hauru, M., Yong, P., et al. *Turing.jl: a general-purpose probabilistic programming language*. ACM Transactions on Probabilistic Machine Learning (2025), <https://turinglang.org/>
- [12] Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fonnesbeck, C.J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C.C., Martin, O.A., et al. *PyMC: a modern, and comprehensive probabilistic programming framework in Python*. PeerJ Computer Science 9, e1516 (2023), <https://www.pymc.io>
- [13] Carpenter, B., Gelman, A., Hoffman, M.D., Lee, D., Goodrich, B., Betancourt, M., Brubaker, M., Guo, J., Li, P., Riddell, A. *Stan: A probabilistic programming language*. Journal of Statistical Software 76, 1–32 (2017), <https://mc-stan.org/>

Otros textos claves

- [14] Bishop, C.M., Bishop, H. *Deep Learning: Foundations and Concepts*. Springer Nature (2023)
- [15] Frank, S.A. The common patterns of nature. Journal of evolutionary biology 22(8), 1563–1585 (2009)
- [16] Halpern, J.Y. Reasoning about uncertainty. MIT press, 2nd edn. (2017)
- [17] Levine, S. Reinforcement learning and control as probabilistic inference: Tutorial and review. arXiv preprint arXiv:1805.00909 (2018), <https://arxiv.org/pdf/1805.00909.pdf>
- [18] Parr, T., Pezzulo, G., Friston, K.J. Active inference: the free energy principle in mind, brain, and behavior. MIT Press (2022)
- [19] Popper, K. The logic of scientific discovery (Logik der Forschung, 1934). Routledge (1968)
- [20] Poundstone, W. Fortune’s formula: The untold story of the scientific betting system that beat the casinos and Wall Street. Hill and Wang (2010)
- [21] Rényi, A. On a new axiomatic theory of probability. Acta Mathematica Hungarica 6(3-4), 285–335 (1955)
- [22] Samaja, J. Epistemología y metodología: elementos para una teoría de la investigación científica. EUDEBA (1999)